Cambio de Medida en Probabilidad

Marzo.

1 Marco de trabajo

A lo largo de todo el documento, $(\Omega, \mathcal{F})$ es un espacio medible. Una *medida* (positiva) es una función $\mu : \mathcal{F} \to [0, \infty]$ con $\mu(\varnothing) = 0$ y aditividad numerable. Una *medida de probabilidad* es una medida con $\mu(\Omega) = 1$.

Cuando $(\Omega, \mathcal{F}, P)$ es un espacio de probabilidad, una variable aleatoria es una función medible $X : \Omega \to \mathbb{R} \cup \{\pm\infty\}$.

Construiremos la integral de Lebesgue $\int X\, dP$ desde cero, luego construiremos nuevas medidas Q mediante densidades, después demostraremos Radon–Nikodym y derivaremos la identidad del cambio de medida.

Observación 1.1 (Sobre la notación). En este documento utilizaremos dos notaciones equivalentes para la integral respecto a una medida de probabilidad P:

- $\displaystyle\int X\, dP$ indica la integral de X con respecto a P.
- $\displaystyle\int X(\omega)\, P(d\omega)$ es una notación más explícita que enfatiza la variable de integración.
- Ambas son intercambiables: $\int X\, dP = \int X(\omega)\, P(d\omega)$.

Usaremos preferentemente $P(dx)$ cuando trabajemos con integrales definidas, para mantener la claridad en los cambios de variable y en las densidades.

Observación 1.2. Todos los argumentos que siguen funcionan para cualesquiera medidas σ-finitas (P, Q); mantenemos la notación probabilística porque es la entrada habitual en probabilidad.

2 Construcción de la integral de Lebesgue

2.1 Paso 1: funciones simples

Definición 2.1 (Función simple)**.** Una *función simple (no negativa)* es una función medible $s : \Omega \to [0, \infty)$ de la forma

$$s(\omega) = \sum_{i=1}^{n} a_i\, \mathbf{1}_{A_i}(\omega), \qquad a_i \geq 0, \quad A_i \in \mathcal{F},$$

donde los conjuntos A_i pueden suponerse disjuntos (refinando la partición).

Ejemplo 2.2 (Funciones simples concretas)**.** Consideremos $\Omega = [0, 1]$ con la σ-álgebra de Borel.

- $s_1(\omega) = 2 \cdot \mathbf{1}_{[0,0.5]}(\omega) + 3 \cdot \mathbf{1}_{(0.5,1]}(\omega)$ es una función simple.
- $s_2(\omega) = \sum_{k=0}^{3} \frac{k}{3} \cdot \mathbf{1}_{[k/3,(k+1)/3)}(\omega)$ aproxima la función identidad.

Definición 2.3 (Integral de una función simple)**.** Sea μ una medida. Para $s = \sum_{i=1}^{n} a_i \mathbf{1}_{A_i}$ (con A_i disjuntos) definimos

$$\int_{\Omega} s(\omega)\, \mu(d\omega) := \sum_{i=1}^{n} a_i\, \mu(A_i).$$

Para $A \in \mathcal{F}$, definimos la integral restringida mediante

$$\int_A s(\omega)\,\mu(d\omega) := \int_\Omega s(\omega)\mathbf{1}_A(\omega)\,\mu(d\omega) = \sum_{i=1}^{n} a_i\,\mu(A \cap A_i).$$

Ejemplo 2.4 (Cálculo de integral simple)**.** Con μ la medida de Lebesgue en $[0,1]$ y s_1 del ejemplo anterior:

$$\int_{[0,1]} s_1(x)\,\mu(dx) = 2 \cdot \mu([0,0.5]) + 3 \cdot \mu((0.5,1]) = 2 \cdot 0.5 + 3 \cdot 0.5 = 2.5.$$

Para $A = [0.2, 0.7]$:

$$\int_A s_1(x)\,\mu(dx) = 2 \cdot \mu([0.2,0.5]) + 3 \cdot \mu((0.5,0.7]) = 2 \cdot 0.3 + 3 \cdot 0.2 = 1.2.$$

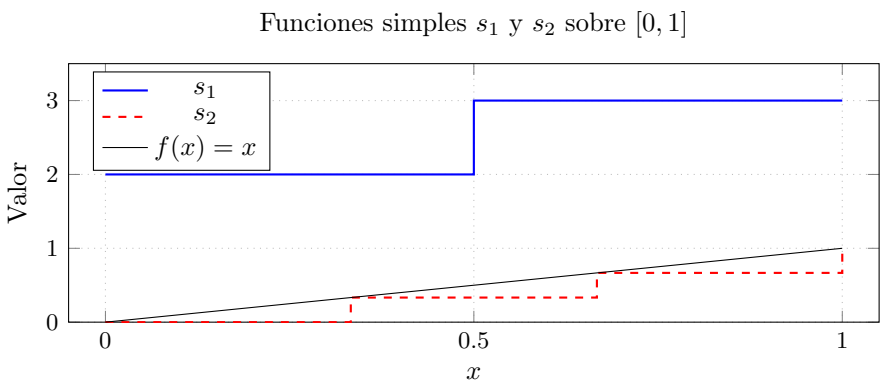

Figura 1: La función simple s_1 toma dos valores; s_2 aproxima la identidad con 3 peldaños.

Lema 2.5 (Buena definición)**.** *El valor de $\int s\,d\mu$ no depende de la representación elegida de s.*

Demostración. Escribimos dos representaciones de s usando particiones disjuntas $\{A_i\}$ y $\{B_j\}$. Refinamos a la partición disjunta común $\{A_i \cap B_j\}_{i,j}$. Entonces

$$s(\omega) = \sum_{i,j} a_i \mathbf{1}_{A_i \cap B_j}(\omega) = \sum_{i,j} b_j \mathbf{1}_{A_i \cap B_j}(\omega),$$

por lo tanto $a_i = b_j$ en cada átomo $A_i \cap B_j$ con medida positiva. Sumar $a_i \mu(A_i \cap B_j)$ sobre los átomos es igual a sumar $b_j \mu(A_i \cap B_j)$, así que ambas integrales coinciden. $\square$

Lema 2.6 (Propiedades básicas para funciones simples)**.** *Para funciones simples $s, t \geq 0$ y $\alpha, \beta \geq 0$:*

$$\int (\alpha s + \beta t)(\omega)\,\mu(d\omega) = \alpha \int s(\omega)\,\mu(d\omega) + \beta \int t(\omega)\,\mu(d\omega), \qquad s \leq t \Rightarrow \int s(\omega)\,\mu(d\omega) \leq \int t(\omega)\,\mu(d\omega).$$

Ejemplo 2.7 (Verificación de propiedades)**.** Con s_1 como antes y $t(\omega) = \mathbf{1}_{[0,0.3]}(\omega)$:

$$\int (2s_1 + 3t)(x)\,\mu(dx) = 2\int s_1(x)\,\mu(dx) + 3\int t(x)\,\mu(dx) = 2 \cdot 2.5 + 3 \cdot 0.3 = 5 + 0.9 = 5.9,$$

$$\begin{aligned}\int (2s_1 + 3t)(x)\,\mu(dx)_{\text{directo}} &= \int (4\mathbf{1}_{[0,0.5]} + 6\mathbf{1}_{(0.5,1]} + 3\mathbf{1}_{[0,0.3]})(x)\,\mu(dx) \\ &= 4 \cdot 0.5 + 6 \cdot 0.5 + 3 \cdot 0.3 = 2 + 3 + 0.9 = 5.9.\end{aligned}$$

2.2 Paso 2: integral para funciones medibles no negativas

Definición 2.8 (Integral para $f \geq 0$)**.** Sea $f : \Omega \to [0, \infty]$ medible. Definimos

$$\int_\Omega f(\omega)\,\mu(d\omega) := \sup\Big\{ \int_\Omega s(\omega)\,\mu(d\omega) : \ s \text{ simple}, \ 0 \leq s \leq f \Big\} \in [0, \infty].$$

Para $A \in \mathcal{F}$, definimos $\int_A f(\omega)\,\mu(d\omega) := \int_\Omega f(\omega)\mathbf{1}_A(\omega)\,\mu(d\omega)$.

Ejemplo 2.9 (Aproximación de $f(x) = x$)**.** Para $f(x) = x$ en $[0, 1]$ con medida de Lebesgue:

- $s_2(x) = \sum_{k=0}^{3} \frac{k}{3}\mathbf{1}_{[k/3,(k+1)/3)}(x)$ da $\int s_2(x)\,\mu(dx) = \sum_{k=0}^{2} \frac{k}{3} \cdot \frac{1}{3} = \frac{0+1+2}{9} = \frac{1}{3}$.
- Refinando la partición con $n = 100$: $\int s_{100}(x)\,\mu(dx) \approx \int_0^1 x\,dx = 0.5$.
- El supremo sobre todas las aproximaciones simples es exactamente 0.5.

Lema 2.10 (Aproximación por funciones simples)**.** *Para cada función medible $f \geq 0$ existe una sucesión creciente de funciones simples $(s_n)_{n\geq 1}$ tal que $0 \leq s_n \uparrow f$ puntualmente y*

$$\int f(\omega)\,\mu(d\omega) = \lim_{n\to\infty} \int s_n(\omega)\,\mu(d\omega).$$

Demostración. Una construcción estándar es

$$s_n(\omega) := \sum_{k=0}^{n2^n-1} \frac{k}{2^n}\,\mathbf{1}_{\{k/2^n \leq f(\omega) < (k+1)/2^n\}}(\omega) \ + \ n\,\mathbf{1}_{\{f(\omega)\geq n\}}(\omega).$$

Entonces cada s_n es simple, $s_n \leq f$, y $s_n \uparrow f$. Por definición de $\int f\,d\mu$ como un supremo sobre cotas inferiores simples, siempre tenemos $\int s_n\,d\mu \leq \int f\,d\mu$, y para cualquier $\varepsilon > 0$ se puede elegir una función simple $s \leq f$ con $\int s\,d\mu > \int f\,d\mu - \varepsilon$. Para n suficientemente grande, $s \leq s_n$ puntualmente (por el refinamiento de la malla), por lo tanto $\int s\,d\mu \leq \int s_n\,d\mu$. Tomando $n \to \infty$ se obtiene $\lim_n \int s_n\,d\mu = \int f\,d\mu$. □

Ejemplo 2.11 (Aproximación explícita de $f(x) = x^2$)**.** Para $f(x) = x^2$ en $[0, 1]$ con $n = 2$:

$$\begin{aligned} s_2(x) &= \sum_{k=0}^{7} \frac{k}{4}\mathbf{1}_{\{k/4\leq x^2<(k+1)/4\}}(x) + 2\mathbf{1}_{\{x^2\geq 2\}}(x) \\ &= \sum_{k=0}^{7} \frac{k}{4}\mathbf{1}_{\{\sqrt{k/4}\leq x<\sqrt{(k+1)/4}\}}(x). \end{aligned}$$

Los intervalos son: $[0, 0.5)$ para $k = 0$, $[0.5, 0.707)$ para $k = 1$, etc.

Teorema 2.12 (Convergencia Monótona / Beppo–Levi)**.** *Si $f_n \geq 0$ medibles y $f_n \uparrow f$ puntualmente, entonces*

$$\int f_n(\omega)\,\mu(d\omega) \uparrow \int f(\omega)\,\mu(d\omega).$$

Demostración. Por monotonicidad, $\int f_n\,d\mu$ es creciente y está acotada superiormente por $\int f\,d\mu$, por lo que tiene un límite $L \leq \int f\,d\mu$.

Para la desigualdad inversa, sea s una función simple con $0 \leq s \leq f$. Escribimos $s = \sum_{i=1}^{m} a_i\mathbf{1}_{A_i}$ con A_i disjuntos y $a_i \geq 0$. Para cada i, definimos $A_{i,n} := A_i \cap \{f_n \geq a_i\}$.

Dado que $f_n \uparrow f$ y $s \leq f$, tenemos $A_{i,n} \uparrow A_i$. Definimos $s_n := \sum_{i=1}^m a_i \mathbf{1}_{A_{i,n}}$. Entonces s_n es simple, $s_n \leq f_n$, y $s_n \uparrow s$. Por lo tanto $\int s_n \, d\mu \leq \int f_n \, d\mu$ para todo n. Por el Paso 1 (funciones simples) y la continuidad desde abajo de las medidas,

$$\int s(\omega)\, \mu(d\omega) = \lim_{n\to\infty} \int s_n(\omega)\, \mu(d\omega) \leq \lim_{n\to\infty} \int f_n(\omega)\, \mu(d\omega) = L.$$

Tomando el supremo sobre todas las funciones simples $s \leq f$ se obtiene $\int f \, d\mu \leq L$. Por lo tanto $L = \int f \, d\mu$. □

Ejemplo 2.13 (Aplicación del TCM)**.** Consideremos $f_n(x) = x^n$ en $[0,1]$ con $n \geq 1$. Entonces $f_n \uparrow f$ donde $f(x) = 0$ para $x \in [0,1)$ y $f(1) = 1$. Por TCM:

$$\lim_{n\to\infty} \int_0^1 x^n \, dx = \int_0^1 \lim_{n\to\infty} x^n \, dx = \int_0^1 0 \, dx = 0.$$

Efectivamente, $\int_0^1 x^n \, dx = \frac{1}{n+1} \to 0$.

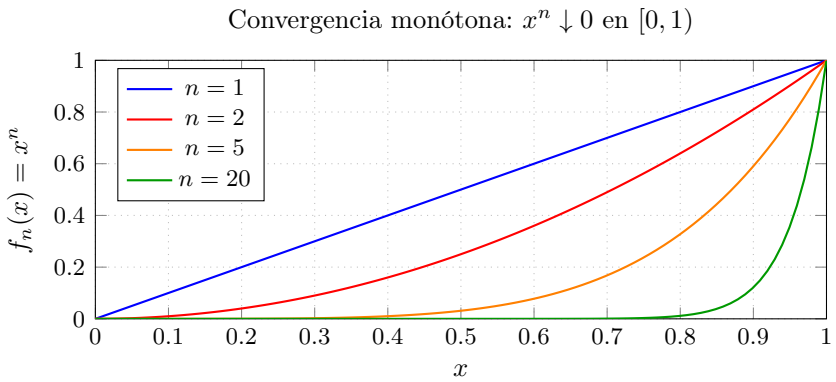

Figura 2: Las integrales $\int_0^1 x^n \, dx = 1/(n+1)$ convergen a 0 conforme $n \to \infty$, ilustrando el Teorema de Convergencia Monótona.

2.3 Paso 3: funciones reales integrables

Definición 2.14 (Partes positiva/negativa)**.** Para una variable medible $X : \Omega \to \mathbb{R} \cup \{\pm\infty\}$ definimos

$$X^+ := \max\{X, 0\}, \qquad X^- := \max\{-X, 0\},$$

de modo que $X = X^+ - X^-$ y $|X| = X^+ + X^-$.

Definición 2.15 (Integral de una función con signo)**.** Si $\int X^+(\omega)\, \mu(d\omega) < \infty$ y $\int X^-(\omega)\, \mu(d\omega) < \infty$, definimos

$$\int X(\omega)\, \mu(d\omega) := \int X^+(\omega)\, \mu(d\omega) - \int X^-(\omega)\, \mu(d\omega).$$

Entonces se dice que X es μ-integrable (es decir, $X \in L^1(\mu)$).

Ejemplo 2.16 (Cálculo con partes positiva y negativa)**.** Para $X(x) = x - 0.5$ en $[0,1]$:

$$X^+(x) = \max\{x - 0.5, 0\} = \begin{cases} 0 & x \leq 0.5 \\ x - 0.5 & x > 0.5 \end{cases}$$

$$X^-(x) = \max\{0.5 - x, 0\} = \begin{cases} 0.5 - x & x \leq 0.5 \\ 0 & x > 0.5 \end{cases}$$

Entonces $\int X^+(x)\,\mu(dx) = \int_{0.5}^{1}(x-0.5)dx = \frac{1}{8}$, $\int X^-(x)\,\mu(dx) = \int_0^{0.5}(0.5-x)dx = \frac{1}{8}$, luego $\int X(x)\,\mu(dx) = \frac{1}{8} - \frac{1}{8} = 0$.

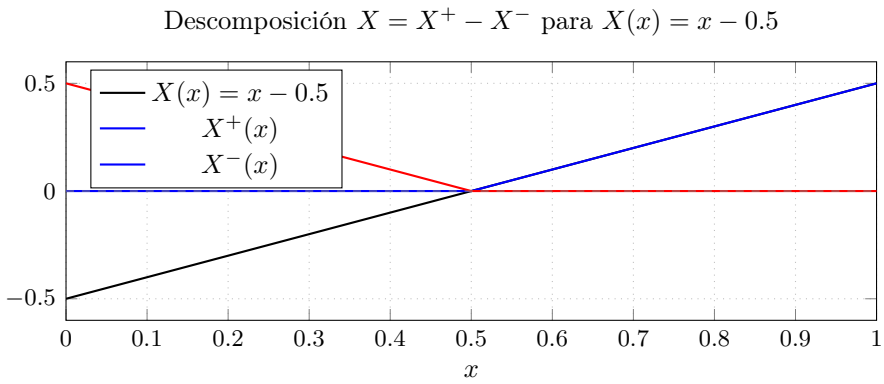

Figura 3: Las áreas bajo X^+ y X^- son iguales (1/8 cada una), por lo que la integral total es 0.

Lema 2.17 (Linealidad en L^1)**.** *Si $X, Y \in L^1(\mu)$ y $a, b \in \mathbb{R}$, entonces $aX + bY \in L^1(\mu)$ y*

$$\int (aX + bY)(\omega)\,\mu(d\omega) = a\int X(\omega)\,\mu(d\omega) + b\int Y(\omega)\,\mu(d\omega).$$

Ejemplo 2.18 (Verificación de linealidad)**.** Con $X(x) = x$, $Y(x) = x^2$ en $[0, 1]$:

$$\int (2X + 3Y)(x)\,\mu(dx) = 2\int_0^1 x\,dx + 3\int_0^1 x^2\,dx = 2\cdot\frac{1}{2} + 3\cdot\frac{1}{3} = 1 + 1 = 2,$$
$$\int_0^1 (2x + 3x^2)dx = [x^2 + x^3]_0^1 = 1 + 1 = 2.$$

3 Completitud del Espacio de Probabilidad

3.1 Introducción y motivación

En teoría de la probabilidad, la noción de completitud de un espacio de probabilidad juega un papel fundamental, aunque a menudo pasa desapercibida en tratamientos elementales. Un espacio de probabilidad completo es aquel donde todo subconjunto de un conjunto nulo es medible. Esta propiedad, aparentemente técnica, tiene profundas implicaciones en la teoría de la medida y la probabilidad.

Definición 3.1 (Espacio de probabilidad completo)**.** Un espacio de probabilidad $(\Omega, \mathcal{F}, P)$ se dice *completo* si para todo $A \in \mathcal{F}$ con $P(A) = 0$, se tiene que todo subconjunto $B \subset A$ pertenece a $\mathcal{F}$ (y por tanto $P(B) = 0$).

Observación 3.2. La completitud no es una propiedad meramente técnica: garantiza que conjuntos "patológicos" que están contenidos en conjuntos nulos no causen problemas en las construcciones probabilísticas. Sin completitud, podríamos tener situaciones donde un conjunto que debería tener probabilidad cero no sea medible, lo que impediría asignarle probabilidad.

3.2 Completitud de Lebesgue vs Borel

Ejemplo 3.3 (El espacio de Borel no es completo)**.** Consideremos $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$ donde $\mathcal{B}(\mathbb{R})$ es la σ-álgebra de Borel y λ la medida de Lebesgue. Este espacio **no** es completo. Existen conjuntos de medida de Lebesgue cero que no son Borelianos, por ejemplo, el conjunto de Vitali. Sin embargo, todo subconjunto de un conjunto de medida cero debería tener medida cero, pero tales subconjuntos pueden no ser medibles.

Definición 3.4 (Completación de Lebesgue)**.** La *completación de Lebesgue* de $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$ es el espacio $(\mathbb{R}, \mathcal{L}(\mathbb{R}), \lambda)$, donde $\mathcal{L}(\mathbb{R})$ es la σ-álgebra de Lebesgue, que consiste en todos los conjuntos de la forma $B \cup N$ donde $B \in \mathcal{B}(\mathbb{R})$ y N es un subconjunto de algún conjunto Boreliano de medida cero.

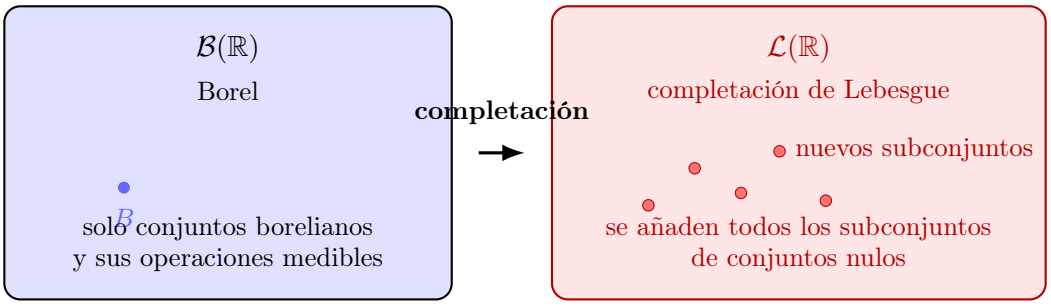

Figura 4: La completación de Lebesgue añade todos los subconjuntos de conjuntos nulos a la σ-álgebra, ampliando el espacio boreliano sin cambiar la medida sobre los conjuntos ya medibles.

3.3 Completitud y convergencia

Una de las razones más importantes para trabajar con espacios completos es que garantizan que los límites de sucesiones de variables aleatorias sigan siendo variables aleatorias cuando la convergencia es casi segura.

Teorema 3.5 (Límite de variables aleatorias en espacios completos)**.** *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad completo y $\{X_n\}$ una sucesión de variables aleatorias. Si $X_n \to X$ P-c.s., entonces X es una variable aleatoria (es decir, medible).*

Demostración. La convergencia casi segura significa que existe un conjunto $N \in \mathcal{F}$ con $P(N) = 0$ tal que $X_n(\omega) \to X(\omega)$ para todo $\omega \notin N$. Para cualquier $a \in \mathbb{R}$, tenemos:

$$\{X \leq a\} = (\{X \leq a\} \cap N^c) \cup (\{X \leq a\} \cap N).$$

El conjunto $\{X \leq a\} \cap N^c$ puede expresarse como:

$$\{X \leq a\} \cap N^c = \bigcap_{m=1}^{\infty} \bigcup_{k=1}^{\infty} \bigcap_{n=k}^{\infty} \{X_n \leq a + 1/m\} \cap N^c,$$

que es medible por ser combinación numerable de conjuntos medibles. El conjunto $\{X \leq a\} \cap N$ es un subconjunto del conjunto nulo N. En un espacio completo, todo subconjunto de un conjunto nulo es medible. Por lo tanto, $\{X \leq a\}$ es medible. $\square$

Observación 3.6. Sin completitud, el límite casi seguro de variables aleatorias podría no ser medible. Esto tendría consecuencias desastrosas: no podríamos hablar de su distribución, esperanza, etc.

Ejemplo 3.7 (Problema sin completitud)**.** En $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$, consideremos una sucesión X_n que converge a la función indicadora de un conjunto de Vitali V (no medible) en un conjunto de medida cero. El límite no sería medible, a pesar de que la convergencia es casi segura.

3.4 Completitud del espacio L^p

Definición 3.8 (Espacios L^p)**.** Para $1 \leq p < \infty$, definimos

$$L^p(\Omega, \mathcal{F}, P) := \{X : \Omega \to \mathbb{R} \text{ medible} : \mathbb{E}[|X|^p] < \infty\},$$

con la norma $\|X\|_p := (\mathbb{E}[|X|^p])^{1/p}$. Identificamos variables que son iguales P-c.s.

Teorema 3.9 (Completitud de L^p, Teorema de Riesz-Fischer)**.** *Para $1 \leq p < \infty$, el espacio $L^p(\Omega, \mathcal{F}, P)$ es completo (un espacio de Banach). Es decir, toda sucesión de Cauchy en L^p converge a un elemento de L^p.*

Demostración. Sea $\{X_n\}$ una sucesión de Cauchy en L^p. Entonces existe una subsucesión $\{X_{n_k}\}$ tal que

$$\left\|X_{n_{k+1}} - X_{n_k}\right\|_p \leq 2^{-k}.$$

Definimos

$$Y_m = \sum_{k=1}^{m} |X_{n_{k+1}} - X_{n_k}|, \quad Y = \sum_{k=1}^{\infty} |X_{n_{k+1}} - X_{n_k}|.$$

Por la desigualdad de Minkowski,

$$\|Y_m\|_p \leq \sum_{k=1}^{m} \left\|X_{n_{k+1}} - X_{n_k}\right\|_p \leq \sum_{k=1}^{m} 2^{-k} \leq 1.$$

Por convergencia monótona, $\|Y\|_p \leq 1$, por lo que $Y < \infty$ P-c.s. Esto implica que la serie

$$X_{n_1} + \sum_{k=1}^{\infty} (X_{n_{k+1}} - X_{n_k})$$

converge absolutamente P-c.s. a un límite X. Por construcción, $X_{n_k} \to X$ P-c.s.

Ahora, para cualquier $\varepsilon > 0$, existe N tal que para $m, n \geq N$, $\|X_m - X_n\|_p < \varepsilon$. Para $n_k \geq N$, por el lema de Fatou,

$$\|X - X_{n_k}\|_p \leq \liminf_{m \to \infty} \|X_m - X_{n_k}\|_p \leq \varepsilon.$$

Por lo tanto $X \in L^p$ y $X_{n_k} \to X$ en L^p. Finalmente, usando la desigualdad triangular,

$$\|X_n - X\|_p \leq \|X_n - X_{n_k}\|_p + \|X_{n_k} - X\|_p \to 0,$$

mostrando que toda la sucesión converge a X en L^p. □

Observación 3.10 (Importancia de la completitud). La completitud de L^p es fundamental para:

- Garantizar la existencia de límites en teoría de aproximación.
- Construir la integral estocástica (necesitamos que ciertas sucesiones de Cauchy converjan).
- Aplicar teoremas de punto fijo en ecuaciones diferenciales estocásticas.
- Definir proyecciones en espacios de Hilbert (L^2 es un espacio de Hilbert).

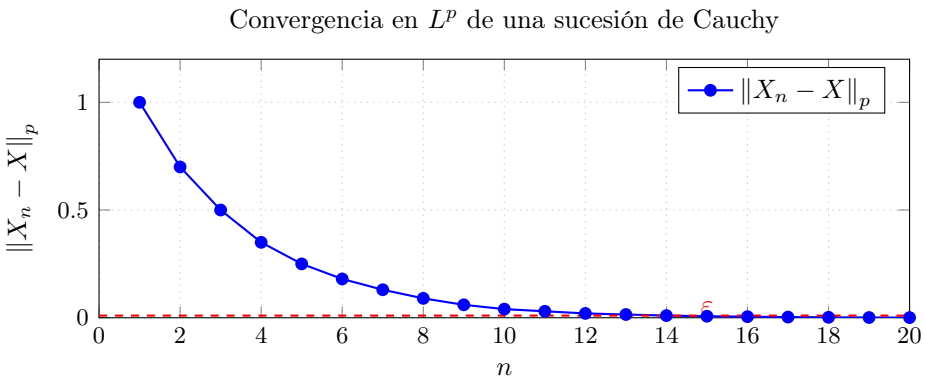

Figura 5: Una sucesión de Cauchy en L^p converge a un límite en L^p. La completitud garantiza que el límite existe dentro del espacio.

3.5 Completitud de la filtración

En teoría de procesos estocásticos, a menudo necesitamos que la filtración sea completa.

Definición 3.11 (Filtración completa)**.** Una filtración $\{\mathcal{F}_t\}_{t\geq 0}$ en un espacio de probabilidad $(\Omega, \mathcal{F}, P)$ se dice *completa* si $\mathcal{F}_0$ contiene todos los conjuntos P-nulos y la filtración es continua por la derecha (a menudo se requiere la condición usual).

Observación 3.12 (Condiciones usuales)*.* En cálculo estocástico, se trabaja con la *completación* de la filtración natural del movimiento browniano. Esto garantiza que:

1. Los tiempos de paro tengan propiedades deseables.
2. Las versiones de esperanzas condicionales sean regulares.
3. La propiedad de martingala se preserve bajo ciertas operaciones.

3.6 Completitud y teorema de Radon-Nikodym

El teorema de Radon-Nikodym (Teorema 6.8) requiere que trabajemos en un espacio completo o que tomemos precauciones con conjuntos nulos.

Teorema 3.13 (Radon-Nikodym en espacios completos)**.** *Si $(\Omega, \mathcal{F}, P)$ es un espacio de probabilidad completo y $Q \ll P$, entonces la derivada de Radon-Nikodym dQ/dP existe y es única P-c.s. Además, puede elegirse de manera que esté definida en todo Ω.*

La completitud simplifica la demostración porque podemos modificar la densidad en conjuntos nulos sin preocuparnos por la medibilidad.

3.7 Completitud del espacio de variables aleatorias

Definición 3.14 (Espacio de variables aleatorias)**.** Denotamos por $\mathcal{V}(\Omega, \mathcal{F})$ al conjunto de todas las variables aleatorias (funciones medibles) de $(\Omega, \mathcal{F})$ a $\mathbb{R}$.

Teorema 3.15 (Completitud del espacio de variables aleatorias con convergencia en probabilidad)**.** *El espacio de variables aleatorias con la convergencia en probabilidad es completo: si $\{X_n\}$ es una sucesión de Cauchy en probabilidad, entonces existe una variable aleatoria X tal que $X_n \to X$ en probabilidad.*

Demostración. Si $\{X_n\}$ es de Cauchy en probabilidad, para cada k existe n_k tal que para $m, n \geq n_k$,

$$P(|X_m - X_n| > 2^{-k}) < 2^{-k}.$$

Elegimos una subsucesión n_k creciente con esta propiedad. Entonces

$$\sum_{k=1}^{\infty} P(|X_{n_{k+1}} - X_{n_k}| > 2^{-k}) < \infty.$$

Por Borel-Cantelli, para casi todo ω, existe $K(\omega)$ tal que para todo $k \geq K(\omega)$, $|X_{n_{k+1}}(\omega) - X_{n_k}(\omega)| \leq 2^{-k}$. Esto implica que $\{X_{n_k}(\omega)\}$ es una sucesión de Cauchy en $\mathbb{R}$, por lo que converge a algún límite $X(\omega)$. Definimos $X(\omega) = \limsup X_{n_k}(\omega)$ (que es medible) y en el conjunto nulo donde no converge, definimos $X = 0$.

Para ver que $X_{n_k} \to X$ en probabilidad, notamos que para cualquier $\varepsilon > 0$,

$$P(|X_{n_k} - X| > \varepsilon) \leq P(|X_{n_k} - X_{n_{k+1}}| > \varepsilon/2) + P(|X_{n_{k+1}} - X| > \varepsilon/2) \to 0.$$

Finalmente, usando la propiedad de Cauchy, $X_n \to X$ en probabilidad. $\square$

3.8 Ejemplo: Completación de un espacio de probabilidad

Ejemplo 3.16 (Completación de un espacio finito)**.** Sea $\Omega = \{1, 2, 3, 4\}$, $\mathcal{F} = \{\emptyset, \{1, 2\}, \{3, 4\}, \Omega\}$, y P definida por $P(\{1, 2\}) = 0$, $P(\{3, 4\}) = 1$. Este espacio no es completo porque $\{1\} \subset \{1, 2\}$ tiene probabilidad cero pero no es medible.

La completación $\mathcal{F}^*$ añade todos los subconjuntos de $\{1, 2\}$:

$$\mathcal{F}^* = \{\emptyset, \{1\}, \{2\}, \{1, 2\}, \{3, 4\}, \{1, 3, 4\}, \{2, 3, 4\}, \Omega\}.$$

Ahora el espacio es completo.

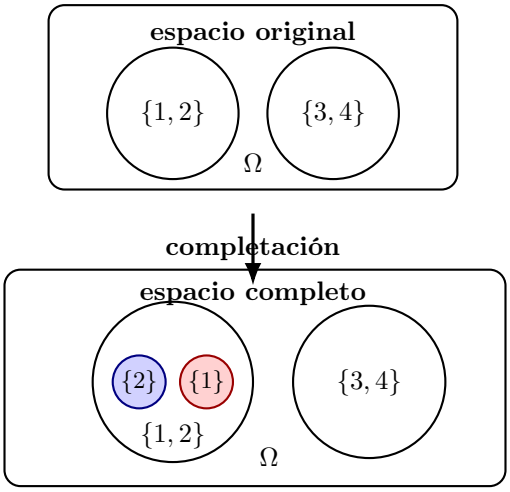

Figura 6: Completación de un espacio finito: el átomo nulo $\{1, 2\}$ se descompone y aparecen explícitamente sus subconjuntos $\{1\}$ y $\{2\}$ como nuevos eventos medibles.

3.9 Importancia en la práctica probabilística

1. **Leyes de grandes números**: La completitud garantiza que el conjunto donde falla la convergencia sea medible y tenga medida cero.
2. **Teoremas de convergencia de martingalas**: Los límites de martingalas son variables aleatorias gracias a la completitud.
3. **Movimiento browniano**: La construcción del movimiento browniano requiere la completitud para que ciertos conjuntos patológicos no interfieran.
4. **Esperanza condicional**: La existencia de versiones regulares a menudo requiere espacios completos.
5. **Integral estocástica**: La construcción de la integral de Itô utiliza la completitud de L^2 y de la filtración.

Teorema 3.17 (Importancia de la completitud en martingalas)**.** *En un espacio de probabilidad completo, si $\{X_n\}$ es una martingala y τ es un tiempo de paro, entonces X_τ es una variable aleatoria (medible).*

Demostración. $X_\tau(\omega) = X_{\tau(\omega)}(\omega)$. La medibilidad requiere argumentos cuidadosos que dependen de la completitud para manejar conjuntos donde $\tau = \infty$. □

4 Definir Q mediante una densidad: $Q(A) = \int_A Z\, dP$

Fijamos un espacio de probabilidad $(\Omega, \mathcal{F}, P)$.

Definición 4.1 (Construcción de densidad)**.** Sea $Z : \Omega \to [0, \infty]$ medible con

$$\int_\Omega Z(\omega)\, P(d\omega) = 1.$$

Definimos una función de conjunto $Q : \mathcal{F} \to [0, \infty]$ mediante

$$Q(A) := \int_A Z(\omega)\, P(d\omega) \quad (A \in \mathcal{F}).$$

Ejemplo 4.2 (Cambio de medida discreto)**.** Sea $\Omega = \{1, 2, 3, 4, 5, 6\}$, P uniforme ($P(\{i\}) = 1/6$). Definimos $Z(i) = i/3.5$ (notar que $\sum_{i=1}^{6} i/3.5 \cdot 1/6 = (21/3.5)/6 = 6/6 = 1$). Entonces

$$Q(\{i\}) = \int_{\{i\}} Z(\omega)\, P(d\omega) = Z(i) \cdot P(\{i\}) = \frac{i}{3.5} \cdot \frac{1}{6} = \frac{i}{21}.$$

Así Q da más peso a números mayores.

Ejemplo 4.3 (Cambio de medida continuo)**.** En $([0, 1], \mathcal{B}, P = \text{Leb})$, tomemos $Z(x) = 2x$. Entonces $\int_0^1 2x\, dx = 1$. Para cualquier intervalo $[a, b] \subset [0, 1]$:

$$Q([a, b]) = \int_a^b 2x\, dx = b^2 - a^2.$$

Esta Q tiene densidad lineal creciente.

Observación 4.4. La integral restringida $\int_A Z(\omega)\, P(d\omega)$ es, por definición, $\int_\Omega Z(\omega)\mathbf{1}_A(\omega)\, P(d\omega)$. Por lo tanto, la construcción utiliza únicamente la integral de Lebesgue ya construida en §2.

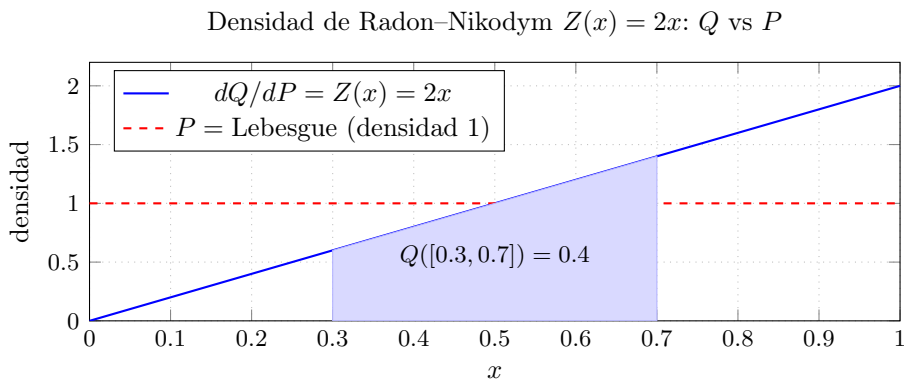

Figura 7: La nueva medida Q con $dQ/dP = 2x$ concentra más masa hacia $x = 1$. El área sombreada muestra $Q([0.3, 0.7]) = 0.7^2 - 0.3^2 = 0.40$.

5 Demostrar que Q es una medida (y una medida de probabilidad)

Proposición 5.1. *La función de conjunto Q definida por $Q(A) = \int_A Z(\omega)\, P(d\omega)$ es una medida en $(\Omega, \mathcal{F})$. Además, es una medida de probabilidad: $Q(\Omega) = 1$.*

Demostración. Verificamos los axiomas de medida.

(i) El conjunto vacío es nulo. Dado que $\mathbf{1}_\varnothing = 0$,

$$Q(\varnothing) = \int_\Omega Z(\omega)\mathbf{1}_\varnothing(\omega)\, P(d\omega) = 0.$$

(ii) No negatividad. Dado que $Z \geq 0$ y $\mathbf{1}_A \geq 0$, tenemos $Z\mathbf{1}_A \geq 0$ y por lo tanto $Q(A) = \int Z(\omega)\mathbf{1}_A(\omega)\, P(d\omega) \geq 0$.

(iii) Aditividad numerable. Sean $(A_n)_{n\geq 1} \subset \mathcal{F}$ disjuntos dos a dos y definimos $A := \bigcup_{n\geq 1} A_n$. Definimos las sumas parciales

$$f_N := \sum_{n=1}^{N} \mathbf{1}_{A_n}.$$

Como los A_n son disjuntos, $f_N(\omega) \in \{0, 1\}$ y $f_N \uparrow \mathbf{1}_A$ puntualmente. Multiplicando por $Z \geq 0$ obtenemos

$$Z(\omega) f_N(\omega) \uparrow Z(\omega)\mathbf{1}_A(\omega).$$

Por Convergencia Monótona (Teorema 2.12),

$$Q(A) = \int Z(\omega)\mathbf{1}_A(\omega)\, P(d\omega) = \lim_{N\to\infty} \int Z(\omega) f_N(\omega)\, P(d\omega).$$

Por linealidad para sumas finitas,

$$\int Z(\omega) f_N(\omega)\, P(d\omega) = \int Z(\omega)\Big(\sum_{n=1}^{N} \mathbf{1}_{A_n}(\omega)\Big)\, P(d\omega) = \sum_{n=1}^{N} \int Z(\omega)\mathbf{1}_{A_n}(\omega)\, P(d\omega) = \sum_{n=1}^{N} Q(A_n).$$

Tomando $N \to \infty$ obtenemos $Q(A) = \sum_{n\geq 1} Q(A_n)$.

(iv) Normalización. Finalmente,

$$Q(\Omega) = \int_\Omega Z(\omega)\, P(d\omega) = 1$$

por hipótesis. Por lo tanto Q es una medida de probabilidad. □

Ejemplo 5.2 (Verificación de aditividad)**.** Con el ejemplo continuo $Z(x) = 2x$, tomemos $A_1 = [0, 0.3]$, $A_2 = (0.3, 0.7]$, $A_3 = (0.7, 1]$. Entonces:

$$\begin{aligned} Q(A_1) &= 0.3^2 - 0^2 = 0.09, \\ Q(A_2) &= 0.7^2 - 0.3^2 = 0.49 - 0.09 = 0.4, \\ Q(A_3) &= 1^2 - 0.7^2 = 1 - 0.49 = 0.51, \\ Q([0,1]) &= 1 = 0.09 + 0.4 + 0.51. \end{aligned}$$

Corolario 5.3 (Continuidad absoluta)**.** *Si $P(A) = 0$ entonces $Q(A) = 0$. En particular, $Q \ll P$.*

Demostración. Si $P(A) = 0$ entonces $\int_A Z(\omega)\, P(d\omega) = 0$ para cualquier función medible no negativa Z (integral sobre un conjunto nulo), por lo tanto $Q(A) = 0$. □

Ejemplo 5.4 (Continuidad absoluta en acción)**.** Con P Lebesgue en $[0, 1]$ y $Z(x) = 2x$, tomemos $A = \{\text{rationals}\}$. Como $P(A) = 0$, entonces $Q(A) = \int_A 2x\, dx = 0$ (integral sobre conjunto de medida cero).

6 Teorema de Radon–Nikodym (demostración completa)

Ahora demostramos el enunciado recíproco: si $Q \ll P$ (y se cumple la σ-finitud), entonces Q admite una densidad $Z = \frac{dQ}{dP}$ tal que $Q(A) = \int_A Z\, dP$.

6.1 Preliminares: medidas con signo y descomposición de Hahn

Definición 6.1 (Medida con signo)**.** Una *medida con signo* ν sobre $(\Omega, \mathcal{F})$ es una función $\nu : \mathcal{F} \to \mathbb{R} \cup \{\pm\infty\}$ tal que $\nu(\varnothing) = 0$ y ν es numerablemente aditiva sobre familias disjuntas, con la convención de que ν nunca toma ambos valores $+\infty$ y $-\infty$.

Ejemplo 6.2 (Medida con signo simple)**.** En $\{1, 2, 3\}$, definamos $\nu(\{1\}) = 2$, $\nu(\{2\}) = -1$, $\nu(\{3\}) = 0.5$. Entonces ν es una medida con signo finita.

Teorema 6.3 (Descomposición de Hahn)**.** *Sea ν una medida con signo. Entonces existen conjuntos medibles $P_\nu, N_\nu \in \mathcal{F}$ tales que $P_\nu \cup N_\nu = \Omega$, $P_\nu \cap N_\nu = \varnothing$ y*

$$\nu(A) \geq 0 \text{ para todo } A \subset P_\nu, \qquad \nu(A) \leq 0 \text{ para todo } A \subset N_\nu.$$

Tal descomposición es única salvo conjuntos ν-nulos.

Ejemplo 6.4 (Descomposición de Hahn)**.** Para ν en $\mathbb{R}$ con densidad $f(x) = x$, la descomposición de Hahn es $P_\nu = [0, \infty)$, $N_\nu = (-\infty, 0)$.

6.2 Radon–Nikodym para medidas finitas

Teorema 6.5 (Radon–Nikodym, caso finito)**.** *Sean P una medida finita sobre $(\Omega, \mathcal{F})$ y Q una medida finita tal que $Q \ll P$. Entonces existe una función medible $Z \geq 0$ (P-c.s. única) tal que*

$$Q(A) = \int_A Z(\omega)\, P(d\omega) \quad \textit{para todo } A \in \mathcal{F}.$$

Demostración. Damos una construcción completa mediante un argumento variacional.

Paso 1: definir un conjunto convexo de candidatos. Sea

$$\mathcal{K} := \Big\{ f \geq 0 \text{ medible } : \int f(\omega)\, P(d\omega) \leq Q(\Omega) \Big\}.$$

Definimos el funcional

$$\Phi(f) := \int f(\omega)\, P(d\omega) - Q(\Omega) + \sup_{A \in \mathcal{F}} \big(Q(A) - \int_A f(\omega)\, P(d\omega) \big).$$

Observamos que $\Phi(f) \geq 0$ para toda $f \in \mathcal{K}$, porque el supremo es al menos $Q(\Omega) - \int f\, dP$ (tomando $A = \Omega$), lo que da

$$\Phi(f) \geq \int f(\omega)\, P(d\omega) - Q(\Omega) + \big(Q(\Omega) - \int f(\omega)\, P(d\omega) \big) = 0.$$

Paso 2: minimizar Φ e interpretar el minimizador. Sea $\alpha := \inf_{f \in \mathcal{K}} \Phi(f) \geq 0$. Elegimos una sucesión minimizante (f_n) con $\Phi(f_n) \downarrow \alpha$.

Definimos el supremo puntual $g_m := \sup_{n \geq m} f_n$ (así $g_m \downarrow g := \limsup f_n$). Entonces g_m es medible y $g_m \geq 0$. Por Fatou,

$$\int g(\omega)\, P(d\omega) \leq \liminf_{m \to \infty} \int g_m(\omega)\, P(d\omega) \leq \liminf_{n \to \infty} \int f_n(\omega)\, P(d\omega) \leq Q(\Omega),$$

por lo tanto $g \in \mathcal{K}$.

Afirmamos que $\Phi(g) = \alpha$ y, además, $\alpha = 0$. En efecto, para cada A fijo tenemos $\int_A g(\omega)\, P(d\omega) \geq \limsup_n \int_A f_n(\omega)\, P(d\omega)$ por Fatou aplicado a $f_n \mathbf{1}_A$ a lo largo de una subsucesión que alcanza el lim sup. Por lo tanto

$$Q(A) - \int_A g(\omega)\, P(d\omega) \leq \liminf_n \big(Q(A) - \int_A f_n(\omega)\, P(d\omega) \big).$$

Tomando el supremo sobre A obtenemos

$$\sup_A \Big(Q(A) - \int_A g(\omega)\, P(d\omega) \Big) \leq \liminf_n \sup_A \Big(Q(A) - \int_A f_n(\omega)\, P(d\omega) \Big).$$

También $\int g(\omega)\, P(d\omega) \leq \liminf_n \int f_n(\omega)\, P(d\omega)$. Sumando se obtiene $\Phi(g) \leq \liminf_n \Phi(f_n) = \alpha$, por lo tanto $\Phi(g) = \alpha$.

Supongamos ahora que $\alpha > 0$. Entonces, por definición de $\Phi(g)$, existe un evento B tal que

$$Q(B) - \int_B g(\omega)\, P(d\omega) > \frac{\alpha}{2}.$$

Fijamos $\varepsilon := \frac{\alpha}{4P(B)}$ (si $P(B) = 0$ entonces $Q(B) = 0$ ya que $Q \ll P$, lo que contradice la desigualdad estricta anterior). Definimos $g' := g + \varepsilon \mathbf{1}_B$. Entonces $g' \geq 0$ y

$$\int g'(\omega)\, P(d\omega) = \int g(\omega)\, P(d\omega) + \varepsilon P(B) \leq Q(\Omega) + \frac{\alpha}{4},$$

por lo que g' puede no cumplir la restricción $\int f\,dP \le Q(\Omega)$; solucionamos esto mediante truncamiento: definimos $\tilde{g} := \min\{g', M\}$ y elegimos M grande de modo que $\int \tilde{g}(\omega)\,P(d\omega) \le Q(\Omega)$ (la convergencia monótona en M y la finitud de $\int g'\,dP$ permiten este ajuste). Entonces $\tilde{g} \in \mathcal{K}$, y sobre B tenemos $\tilde{g} \ge g + \varepsilon$ excepto posiblemente en un conjunto donde $g' \ge M$, que puede hacerse P-pequeño tomando M grande. Esto disminuye el término de defecto $\sup_A(Q(A) - \int_A f\,dP)$ mientras que aumenta $\int f\,dP$ solo en aproximadamente $\varepsilon P(B)$, lo que da $\Phi(\tilde{g}) < \Phi(g) = \alpha$ para M suficientemente grande, contradiciendo la minimalidad. Por lo tanto $\alpha = 0$.

Así tenemos $g \in \mathcal{K}$ con $\Phi(g) = 0$, es decir

$$\sup_{A\in\mathcal{F}} \Big(Q(A) - \int_A g(\omega)\,P(d\omega)\Big) = Q(\Omega) - \int g(\omega)\,P(d\omega) \quad \text{y} \quad Q(\Omega) = \int g(\omega)\,P(d\omega).$$

En particular,

$$Q(A) \le \int_A g(\omega)\,P(d\omega) \quad \text{para todo } A \in \mathcal{F}.$$

(En efecto, $\Phi(g) = 0$ fuerza a que el supremo sea 0 una vez que $Q(\Omega) = \int g\,dP$.)

Paso 3: demostrar que la igualdad se cumple para todos los conjuntos. Definimos una medida finita $\tilde{Q}$ mediante $\tilde{Q}(A) := \int_A g(\omega)\,P(d\omega)$. Tenemos $Q(A) \le \tilde{Q}(A)$ para todo A y $Q(\Omega) = \tilde{Q}(\Omega)$. Sea $\nu := \tilde{Q} - Q$ la diferencia de medidas finitas, por lo tanto una medida con signo finita con $\nu(A) \ge 0$ para todo A y $\nu(\Omega) = 0$. Pero una medida con signo no negativa con masa total 0 debe ser idénticamente 0: si $\nu(B) > 0$ para algún B, entonces $\nu(\Omega) \ge \nu(B) > 0$, contradicción. Por lo tanto $\nu \equiv 0$, es decir, $Q(A) = \tilde{Q}(A) = \int_A g(\omega)\,P(d\omega)$ para todo A. Establecemos $Z := g$.

Paso 4: unicidad. Si Z, Z' satisfacen ambas $Q(A) = \int_A Z(\omega)\,P(d\omega) = \int_A Z'(\omega)\,P(d\omega)$ para todo A, entonces $\int_A (Z - Z')(\omega)\,P(d\omega) = 0$ para todo A. Tomando $A = \{Z > Z'\}$ obtenemos $\int_{\{Z>Z'\}} (Z - Z')(\omega)\,P(d\omega) = 0$ con integrando > 0, por lo que $P(Z > Z') = 0$. Análogamente $P(Z' < Z) = 0$. Por lo tanto $Z = Z'$ P-c.s. □

Ejemplo 6.6 (Aplicación del teorema RN)**.** Sea P exponencial de parámetro 1: $P(dx) = e^{-x}dx$ en $[0, \infty)$. Sea Q exponencial de parámetro 2: $Q(dx) = 2e^{-2x}dx$. Claramente $Q \ll P$. La densidad es:

$$\frac{dQ}{dP}(x) = \frac{2e^{-2x}}{e^{-x}} = 2e^{-x}.$$

Verificamos: $\int_A 2e^{-x}\,P(dx) = \int_A 2e^{-x}e^{-x}dx = \int_A 2e^{-2x}dx = Q(A)$.

Observación 6.7. La demostración anterior es una ruta completamente rigurosa (estilo variacional/minimización). Muchos textos demuestran Radon–Nikodym mediante la descomposición de Hahn–Jordan y un argumento de maximalidad para el conjunto $\{f : \int_A f\,dP \le Q(A)\}$; el resultado final es el mismo.

6.3 Radon–Nikodym para medidas σ-finitas

Teorema 6.8 (Radon–Nikodym, caso σ-finito)**.** *Sean P y Q medidas σ-finitas sobre $(\Omega, \mathcal{F})$ con $Q \ll P$. Entonces existe una función medible $Z \ge 0$ tal que $Q(A) = \int_A Z(\omega)\,P(d\omega)$ para todo A, y Z es P-c.s. única.*

Demostración. Dado que P es σ-finita, elegimos conjuntos $E_n \in \mathcal{F}$ con $\Omega = \bigcup_n E_n$ y $0 < P(E_n) < \infty$ (o $P(E_n) = 0$ permitido). Análogamente, la σ-finitud de Q da $Q(E_n) < \infty$ después de un posible refinamiento.

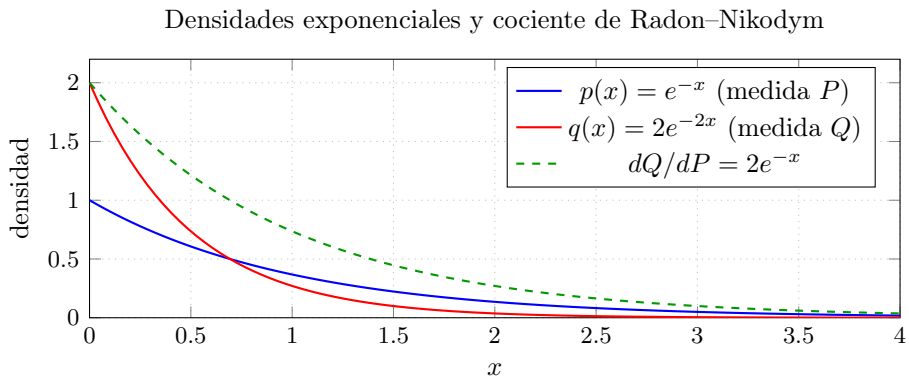

Figura 8: La derivada de Radon–Nikodym $dQ/dP = 2e^{-x}$ es el cociente de las densidades respecto a la medida de Lebesgue.

Restringimos las medidas a E_n: definimos $P_n(A) := P(A \cap E_n)$ y $Q_n(A) := Q(A \cap E_n)$. Entonces P_n y Q_n son medidas finitas y $Q_n \ll P_n$. Por el Teorema 6.5, existe $Z_n \geq 0$ medible sobre E_n tal que

$$Q(A \cap E_n) = \int_{A \cap E_n} Z_n(\omega)\, P(d\omega) \quad \forall A.$$

En las intersecciones $E_n \cap E_m$, la unicidad en el teorema finito implica $Z_n = Z_m$ P-c.s. en $E_n \cap E_m$. Definimos $Z(\omega) := Z_n(\omega)$ para $\omega \in E_n$ (eligiendo cualquier n con $\omega \in E_n$). Esto está bien definido P-c.s. Entonces para cualquier A,

$$Q(A) = \sum_{n \geq 1} Q(A \cap (E_n \setminus E_{n-1})) = \sum_{n \geq 1} \int_{A \cap (E_n \setminus E_{n-1})} Z(\omega)\, P(d\omega) = \int_A Z(\omega)\, P(d\omega),$$

utilizando la disjuntez de $(E_n \setminus E_{n-1})$ y la convergencia monótona / aditividad numerable. La unicidad se sigue de la unicidad en cada E_n. □

Ejemplo 6.9 (Caso σ-finito no acotado)**.** En $\mathbb{R}$, sea P Lebesgue (σ-finita) con $P(dx) = dx$ y Q con densidad $e^{-x^2/2}/\sqrt{2\pi}$ (normal estándar). Entonces:

$$Z(x) = \frac{dQ}{dP}(x) = \frac{e^{-x^2/2}}{\sqrt{2\pi}}.$$

Para cualquier A Borel, $Q(A) = \int_A \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx = \int_A Z(x) P(dx)$.

Definición 6.10 (Derivada de Radon–Nikodym)**.** En el Teorema 6.8 la función Z se denota

$$Z = \frac{dQ}{dP},$$

y se llama la *derivada de Radon–Nikodym* de Q con respecto a P.

7 Medida generada por una función de distribución

7.1 Introducción y motivación

En teoría de la probabilidad, las funciones de distribución constituyen el puente fundamental entre el análisis real y los modelos probabilísticos. Una función de distribución

$F : \mathbb{R} \to [0,1]$ codifica toda la información sobre cómo se distribuye la masa probabilística en la recta real, pero no es en sí misma una medida: necesitamos un procedimiento sistemático para asociarle una medida de probabilidad μ_F sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ que satisfaga $\mu_F((-\infty, x]) = F(x)$ para todo $x \in \mathbb{R}$.

Este proceso de construcción, conocido como *construcción de Lebesgue-Stieltjes*, generaliza la medida de Lebesgue y proporciona el marco riguroso para trabajar con variables aleatorias reales.

7.2 Funciones de distribución: definición y propiedades

Definición 7.1 (Función de distribución)**.** Una función $F : \mathbb{R} \to [0,1]$ se denomina *función de distribución* (o función de distribución acumulada) si satisface las siguientes propiedades:

1. F es monótona no decreciente: $x \leq y \implies F(x) \leq F(y)$.
2. F es continua por la derecha: $\lim_{t \to x^+} F(t) = F(x)$ para todo $x \in \mathbb{R}$.
3. $\lim_{x \to -\infty} F(x) = 0$.
4. $\lim_{x \to +\infty} F(x) = 1$.

Observación 7.2 (Continuidad por la izquierda). La continuidad por la derecha es una convención. Algunos textos definen las funciones de distribución como continuas por la izquierda. La elección es arbitraria siempre que se mantenga consistencia. La medida generada tendrá entonces $F(x) = \mu((-\infty, x))$ si se elige continuidad por la izquierda. En este documento seguimos la convención estándar en probabilidad: continuidad por la derecha.

Proposición 7.3 (Propiedades de una función de distribución)**.** *Sea F una función de distribución. Entonces:*

1. *F tiene límites por la izquierda en todo punto:*
$$F(x^-) := \lim_{t \to x^-} F(t) = \sup\{F(t) : t < x\} \leq F(x).$$
2. *El conjunto de discontinuidades de F es a lo sumo numerable.*
3. *Para cualquier $a < b$,*
$$F(b) - F(a^-) = \mu((a,b]), \quad F(b^-) - F(a^-) = \mu((a,b)), \quad F(b) - F(a) = \mu((a,b]) + \mu(\{a\}).$$
4. *En cada punto x, el salto $\Delta F(x) := F(x) - F(x^-)$ es igual a $\mu(\{x\})$, la masa puntual en x.*

Demostración. (1) La existencia del límite por la izquierda se sigue de la monotonía y el axioma del supremo. La desigualdad $F(x^-) \leq F(x)$ es consecuencia de la continuidad por la derecha.

(2) Los saltos $\Delta F(x) > 0$ son disjuntos y suman a lo sumo 1, por lo que solo puede haber una cantidad numerable de ellos.

(3) y (4) se deducen de la definición de medida asociada, que construiremos a continuación. □

Ejemplo 7.4 (Funciones de distribución típicas)**.** 1. **Distribución discreta**: $F(x) = \sum_{x_i \leq x} p_i$, donde $\{x_i\}$ es un conjunto numerable y $p_i \geq 0$, $\sum p_i = 1$. Ejemplo: distribución de Poisson.

2. **Distribución absolutamente continua**: $F(x) = \int_{-\infty}^{x} f(t)\,dt$ con $f \geq 0$ y $\int_{-\infty}^{\infty} f(t)\,dt = 1$. Ejemplo: distribución normal.

3. **Distribución singular continua**: F es continua pero su derivada es cero en casi todo punto. Ejemplo: función de Cantor.

4. **Distribución mixta**: combinación convexa de los tipos anteriores.

7.3 Construcción de la medida de Lebesgue-Stieltjes

7.3.1 Idea fundamental

Dada una función de distribución F, queremos construir una medida μ_F sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ tal que para cualquier intervalo semiabierto $(a, b]$ se tenga:

$$\mu_F((a, b]) = F(b) - F(a).$$

La elección de intervalos semiabiertos $(a, b]$ no es casual: su estructura algebraica es especialmente conveniente para extender la medida a la σ-álgebra de Borel.

7.3.2 Construcción paso a paso

Definición 7.5 (Semiálgebra de intervalos)**.** Definimos la colección

$$\mathcal{I} := \{(a, b] : -\infty \leq a \leq b < \infty\} \cup \{(a, \infty) : a \in \mathbb{R}\},$$

con la convención $(a, a] = \varnothing$. Esta colección es una *semiálgebra*: es cerrada bajo intersecciones finitas y el complemento de cualquier elemento es unión finita de elementos disjuntos de $\mathcal{I}$.

Definición 7.6 (Función de conjunto sobre intervalos)**.** Definimos $\mu_0 : \mathcal{I} \to [0, 1]$ mediante:

- Para $-\infty < a < b < \infty$: $\mu_0((a, b]) := F(b) - F(a)$.
- Para $a = -\infty$: $\mu_0((-\infty, b]) := F(b)$.
- Para $b = \infty$: $\mu_0((a, \infty)) := 1 - F(a)$.
- $\mu_0(\varnothing) := 0$.

Lema 7.7 (Aditividad finita en $\mathcal{I}$)**.** *μ_0 es finitamente aditiva en $\mathcal{I}$: si $I = \bigcup_{k=1}^{n} I_k$ con $I, I_k \in \mathcal{I}$ y los I_k son disjuntos, entonces $\mu_0(I) = \sum_{k=1}^{n} \mu_0(I_k)$.*

Demostración. Verificamos para el caso más simple: si $(a, b] = (a, c] \cup (c, b]$ con $a < c < b$, entonces

$$\mu_0((a, b]) = F(b) - F(a) = [F(c) - F(a)] + [F(b) - F(c)] = \mu_0((a, c]) + \mu_0((c, b]).$$

Los demás casos se reducen a este mediante un argumento de partición. □

7.3.3 Extensión a la σ-álgebra de Borel

El paso crucial es extender μ_0 de la semiálgebra $\mathcal{I}$ a todo $\mathcal{B}(\mathbb{R})$. Este es un procedimiento estándar en teoría de la medida que sigue tres etapas:

1. Extensión al álgebra $\mathcal{A}$ generada por $\mathcal{I}$ (conjuntos que son uniones finitas disjuntas de elementos de $\mathcal{I}$).

2. Demostración de que μ_0 es σ-aditiva en $\mathcal{A}$.

3. Aplicación del teorema de extensión de Carathéodory.

Teorema 7.8 (Extensión de Carathéodory)**.** *Sea μ_0 una medida (finitamente aditiva y σ-subaditiva) definida sobre un álgebra $\mathcal{A}$. Entonces existe una única medida μ sobre la σ-álgebra $\sigma(\mathcal{A})$ que extiende μ_0.*

Para aplicar este teorema, necesitamos verificar que μ_0 es σ-aditiva en $\mathcal{A}$.

Lema 7.9 (σ-aditividad en el álgebra)**.** *μ_0 es σ-aditiva en el álgebra $\mathcal{A}$ generada por $\mathcal{I}$.*

Demostración. La demostración se apoya en la compacidad de los intervalos cerrados y acotados. Supongamos que $I \in \mathcal{I}$ y $I = \bigcup_{n=1}^{\infty} I_n$ con $I_n \in \mathcal{I}$ disjuntos. Para cualquier $\varepsilon > 0$, podemos aproximar I por un intervalo cerrado por la izquierda y I_n por intervalos abiertos por la derecha, utilizando la continuidad por la derecha de F. Esto permite construir una subcubierta finita y aplicar la aditividad finita para obtener $\mu_0(I) \leq \sum_n \mu_0(I_n) + \varepsilon$. Haciendo $\varepsilon \to 0$ y usando la desigualdad opuesta (que se sigue de la aditividad finita y la monotonía) se obtiene la igualdad. □

7.3.4 Definición final

Definición 7.10 (Medida de Lebesgue-Stieltjes)**.** La *medida de Lebesgue-Stieltjes* asociada a la función de distribución F es la única medida μ_F sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ tal que

$$\mu_F((a, b]) = F(b) - F(a)$$

para todo $a < b$ (con las interpretaciones apropiadas cuando $a = -\infty$ o $b = \infty$).

Teorema 7.11 (Existencia y unicidad)**.** *Para cada función de distribución F existe una única medida de probabilidad μ_F sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ que satisface $\mu_F((-\infty, x]) = F(x)$ para todo $x \in \mathbb{R}$.*

Demostración. La construcción mediante el teorema de extensión de Carathéodory proporciona la existencia. La unicidad se sigue del teorema de la clase monótona: los intervalos $(-\infty, x]$ forman una clase que genera $\mathcal{B}(\mathbb{R})$ y es cerrada bajo intersecciones finitas; dos medidas que coinciden en dicha clase deben coincidir en todo $\mathcal{B}(\mathbb{R})$. □

7.4 Propiedades de la medida asociada

7.4.1 Relación con la función de distribución

Teorema 7.12 (Correspondencia biunívoca)**.** *La correspondencia $F \mapsto \mu_F$ es una biyección entre:*

- *El conjunto de funciones de distribución (en el sentido de la Definición 2.1).*
- *El conjunto de medidas de probabilidad sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.*

Demostración.
- **Inyectividad**: Si $\mu_F = \mu_G$, entonces $F(x) = \mu_F((-\infty, x]) = \mu_G((-\infty, x]) = G(x)$ para todo x.
- **Sobreyectividad**: Dada una medida de probabilidad μ, definimos $F(x) := \mu((-\infty, x])$. Es inmediato verificar que F es una función de distribución y que $\mu_F = \mu$ por construcción.

□

7.4.2 Descomposición de Lebesgue

Teorema 7.13 (Descomposición de Lebesgue)**.** *Toda medida de probabilidad μ sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ puede descomponerse de manera única como*

$$\mu = \mu_{ac} + \mu_{sc} + \mu_d,$$

donde:

- *μ_{ac} es absolutamente continua con respecto a la medida de Lebesgue.*
- *μ_{sc} es singular continua (continua pero concentrada en un conjunto de medida de Lebesgue cero).*
- *μ_d es puramente discreta (combinación numerable de masas puntuales).*

Esta descomposición corresponde a la descomposición de la función de distribución $F = F_{ac} + F_{sc} + F_d$.

Ejemplo 7.14 (Descomposición de una medida mixta)**.** Consideremos la función de distribución

$$F(x) = \frac{1}{2}\Phi(x) + \frac{1}{4}\mathbf{1}_{[0,\infty)}(x) + \frac{1}{4}\mathbf{1}_{[1,\infty)}(x),$$

donde Φ es la distribución normal estándar. Entonces:

- $F_{ac}(x) = \frac{1}{2}\Phi(x)$ (componente absolutamente continua).
- $F_d(x) = \frac{1}{4}\mathbf{1}_{[0,\infty)}(x) + \frac{1}{4}\mathbf{1}_{[1,\infty)}(x)$ (componente discreta con saltos en 0 y 1).
- $F_{sc} \equiv 0$ (no hay componente singular continua).

La medida asociada tiene densidad $\frac{1}{2}\phi(x)$ respecto a Lebesgue (donde ϕ es la densidad normal) más masas puntuales de $1/4$ en $x = 0$ y $x = 1$.

7.5 Ejemplos detallados

7.5.1 Distribución discreta: Poisson

Ejemplo 7.15 (Distribución de Poisson)**.** La función de distribución de Poisson con parámetro $\lambda > 0$ es

$$F(x) = e^{-\lambda} \sum_{k=0}^{\lfloor x \rfloor} \frac{\lambda^k}{k!}, \quad x \geq 0,$$

y $F(x) = 0$ para $x < 0$.

La medida asociada μ_F es:

$$\mu_F = \sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!} \delta_k,$$

donde δ_k denota la masa puntual en k.

Verificamos: para cualquier intervalo $(a, b]$,

$$\mu_F((a, b]) = \sum_{k: a < k \leq b} e^{-\lambda} \frac{\lambda^k}{k!} = F(b) - F(a).$$

7.5.2 Distribución absolutamente continua: Normal

Ejemplo 7.16 (Distribución normal)**.** Para la distribución normal estándar,

$$F(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\, dt.$$

La medida asociada es $\mu_F(dx) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\, dx$, absolutamente continua con respecto a Lebesgue.

En este caso, la derivada de Radon-Nikodym es precisamente la densidad:

$$\frac{d\mu_F}{dx}(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

7.5.3 Distribución mixta

Ejemplo 7.17 (Distribución con masa en un punto)**.** Consideremos la función

$$F(x) = \begin{cases} 0 & x < 0, \\ \frac{1}{2} + \frac{x}{2} & 0 \leq x < 1, \\ 1 & x \geq 1. \end{cases}$$

Esta función tiene:

- Un salto en $x = 0$: $\Delta F(0) = F(0) - F(0^-) = 1/2 - 0 = 1/2$.
- Es continua en $x = 1$: $F(1^-) = 1/2 + 1/2 = 1$, $F(1) = 1$.

La medida asociada es:

$$\mu_F = \frac{1}{2}\delta_0 + \frac{1}{2} \cdot \text{Lebesgue en } (0, 1].$$

Verificamos: $\mu_F((-\infty, 0]) = \mu_F(\{0\}) = 1/2 = F(0)$, $\mu_F((0, 0.5]) = 0.25 = F(0.5) - F(0) = (1/2 + 0.5/2) - 1/2 = 0.25$.

7.6 Conexión con variables aleatorias

7.6.1 Variable aleatoria con distribución dada

Definición 7.18 (Variable aleatoria con distribución F)**.** Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Una variable aleatoria $X : \Omega \to \mathbb{R}$ tiene *función de distribución* F si

$$P(X \leq x) = F(x) \quad \text{para todo } x \in \mathbb{R}.$$

Equivalentemente, la medida imagen $P \circ X^{-1}$ (la distribución de X) es precisamente μ_F.

7.6.2 Esperanza como integral de Lebesgue-Stieltjes

Teorema 7.19 (Esperanza como integral de Lebesgue-Stieltjes)**.** *Si X es una variable aleatoria con función de distribución F, entonces para cualquier función medible $g : \mathbb{R} \to \mathbb{R}$ tal que $g(X)$ sea integrable,*

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x)\, \mu_F(dx) = \int_{-\infty}^{\infty} g(x)\, dF(x),$$

donde la última expresión es la notación clásica de integral de Lebesgue-Stieltjes.

Ejemplo 7.20 (Cálculo de momentos)**.** Para la distribución mixta del Ejemplo 5.3, calculemos $\mathbb{E}[X]$:

$$\mathbb{E}[X] = \int_{\mathbb{R}} x\,\mu_F(dx) = \int_{\{0\}} x\,\mu_F(dx) + \int_{(0,1]} x\,\mu_F(dx).$$

La primera integral es $0 \cdot \mu_F(\{0\}) = 0$. La segunda es $\frac{1}{2}\int_0^1 x\,dx = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$. Por lo tanto, $\mathbb{E}[X] = 1/4$.

Directamente usando F:

$$\mathbb{E}[X] = \int_0^\infty (1 - F(x))\,dx - \int_{-\infty}^0 F(x)\,dx = \int_0^1 (1 - (\tfrac{1}{2} + \tfrac{x}{2}))\,dx = \int_0^1 (\tfrac{1}{2} - \tfrac{x}{2})\,dx = \tfrac{1}{4}.$$

7.7 Medidas producto y distribuciones multivariadas

7.7.1 Construcción para $\mathbb{R}^d$

El mismo procedimiento se extiende a $\mathbb{R}^d$ utilizando funciones de distribución multivariadas.

Definición 7.21 (Función de distribución multivariada)**.** Una función $F : \mathbb{R}^d \to [0,1]$ es una *función de distribución conjunta* si:

1. F es creciente en el sentido de que para $a \leq b$ (coordenada a coordenada),

$$\Delta_{(a,b]}F := \sum_{\varepsilon \in \{0,1\}^d} (-1)^{|\varepsilon|} F(a_1 + \varepsilon_1(b_1 - a_1), \ldots, a_d + \varepsilon_d(b_d - a_d)) \geq 0.$$

2. F es continua por la derecha en cada variable.
3. $\lim\limits_{x_1,\ldots,x_d \to -\infty} F(x_1, \ldots, x_d) = 0.$
4. $\lim\limits_{x_1,\ldots,x_d \to \infty} F(x_1, \ldots, x_d) = 1.$

La cantidad $\Delta_{(a,b]}F$ representa la masa $\mu_F((a,b])$ del rectángulo $(a,b] = (a_1,b_1] \times \cdots \times (a_d,b_d]$.

7.7.2 Independencia en términos de la medida

Teorema 7.22 (Independencia y medida producto)**.** *Dos variables aleatorias X e Y con distribuciones μ_X y μ_Y son independientes si y solo si la distribución conjunta $\mu_{(X,Y)}$ es la medida producto $\mu_X \otimes \mu_Y$, es decir,*

$$\mu_{(X,Y)}(A \times B) = \mu_X(A)\mu_Y(B) \quad \textit{para todo } A, B \in \mathcal{B}(\mathbb{R}).$$

En términos de funciones de distribución, esto equivale a $F_{X,Y}(x,y) = F_X(x)F_Y(y)$ para todo x, y.

7.8 Aplicaciones en probabilidad y estadística

7.8.1 Transformación de variables

Teorema 7.23 (Método de la transformación)**.** *Si X tiene distribución μ_F (con función de distribución F) y $g : \mathbb{R} \to \mathbb{R}$ es estrictamente monótona y diferenciable, entonces $Y = g(X)$ tiene función de distribución*

$$F_Y(y) = F(g^{-1}(y)) \quad \textit{si } g \textit{ es creciente},$$

o $F_Y(y) = 1 - F(g^{-1}(y)^-)$ *si* g *es decreciente. La medida asociada es la imagen de* μ_F *bajo* g*.*

Ejemplo 7.24 (Transformación log-normal)**.** Si $X \sim \mathcal{N}(\mu, \sigma^2)$ y $Y = e^X$, entonces Y tiene distribución log-normal. La función de distribución de Y es

$$F_Y(y) = \Phi\left(\frac{\ln y - \mu}{\sigma}\right), \quad y > 0,$$

y la medida asociada tiene densidad $f_Y(y) = \frac{1}{y\sigma\sqrt{2\pi}} e^{-(\ln y - \mu)^2/(2\sigma^2)}$ respecto a Lebesgue en $(0, \infty)$.

7.8.2 Simulación de variables aleatorias

Teorema 7.25 (Método de la transformada inversa)**.** *Si* F *es una función de distribución continua y estrictamente creciente, y* $U \sim$ *Uniforme*$(0, 1)$*, entonces* $X = F^{-1}(U)$ *tiene distribución* F*.*

Demostración. $P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$. □

Cuando F no es estrictamente creciente, se utiliza la inversa generalizada $F^{-1}(u) := \inf\{x : F(x) \geq u\}$.

7.8.3 Convergencia en distribución

Definición 7.26 (Convergencia débil)**.** Una sucesión de medidas de probabilidad $\{\mu_n\}$ converge débilmente a μ (denotado $\mu_n \Rightarrow \mu$) si para toda función continua y acotada f,

$$\int f \, d\mu_n \to \int f \, d\mu.$$

En términos de funciones de distribución, $\mu_n \Rightarrow \mu$ si y solo si $F_n(x) \to F(x)$ en todo punto de continuidad de F.

Ejemplo 7.27 (Teorema Central del Límite)**.** Si $X_1, X_2, \ldots$ son i.i.d. con media μ y varianza $\sigma^2 < \infty$, entonces

$$\mu_n := \text{distribución de } \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \Rightarrow \mathcal{N}(0, 1).$$

En términos de funciones de distribución:

$$F_n(x) \to \Phi(x) \quad \text{para todo } x \in \mathbb{R}.$$

7.9 Resumen y conexiones con el resto del documento

La construcción de la medida generada por una función de distribución es fundamental por varias razones:

1. **Proporciona un puente concreto** entre el análisis (funciones de distribución) y la teoría de la medida (medidas de probabilidad en $\mathbb{R}$).

2. **Permite aplicar los resultados generales** de cambio de medida (Secciones 3-5) a situaciones concretas: dada una variable aleatoria con distribución F, cualquier cambio de medida absolutamente continuo corresponde a multiplicar la densidad de F (si existe) por un factor Z, o más generalmente a modificar F mediante una densidad de Radon-Nikodym.

3. **Conecta con la Sección 6** (algoritmos genéticos): en problemas de estimación por máxima verosimilitud, la verosimilitud es precisamente la densidad de la medida μ_{F_θ} con respecto a una medida de referencia.

4. **Ilustra el teorema de Radon-Nikodym**: cuando F es absolutamente continua, la densidad $f = dF/dx$ (en el sentido de Lebesgue) es la derivada de Radon-Nikodym de μ_F con respecto a la medida de Lebesgue.

Observación 7.28 (Conexión con cambio de medida). Supongamos que tenemos dos funciones de distribución F y G con $G \ll F$ (en el sentido de que G es absolutamente continua con respecto a F). Entonces existe una función $Z \geq 0$ tal que

$$\frac{dG}{dF}(x) = Z(x) \quad \text{y} \quad G(x) = \int_{-\infty}^{x} Z(t)\, dF(t).$$

Esto es precisamente la versión univariada del cambio de medida de la Sección 3, donde P corresponde a μ_F, Q a μ_G, y $Z = dQ/dP$.

8 Esperanza Condicional

8.1 Introducción y motivación

La esperanza condicional es uno de los conceptos más profundos y útiles en teoría de la probabilidad. Generaliza la noción elemental de esperanza condicional dado un evento a la situación donde condicionamos sobre una σ-álgebra, capturando la idea de "mejor predicción" dada la información disponible.

Ejemplo 8.1 (Motivación: predicción)**.** Supongamos que tenemos dos variables aleatorias X e Y y hemos observado $Y = y$. Queremos predecir el valor de X. La mejor predicción en sentido cuadrático medio es la esperanza condicional $\mathbb{E}[X \mid Y = y]$. Esta es una función de y, y por tanto una variable aleatoria cuando consideramos Y aleatoria.

8.2 Definición y existencia

Definición 8.2 (Esperanza condicional)**.** Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad, X una variable aleatoria con $\mathbb{E}[|X|] < \infty$, y $\mathcal{G} \subset \mathcal{F}$ una sub-σ-álgebra. Una *esperanza condicional* de X dado $\mathcal{G}$, denotada $\mathbb{E}[X \mid \mathcal{G}]$, es una variable aleatoria Z tal que:

1. Z es $\mathcal{G}$-medible.
2. Para todo $G \in \mathcal{G}$, $\int_G Z\, dP = \int_G X\, dP$.

Teorema 8.3 (Existencia y unicidad)**.** *Para toda variable aleatoria X con $\mathbb{E}[|X|] < \infty$ y toda sub-σ-álgebra $\mathcal{G} \subset \mathcal{F}$, existe una esperanza condicional $\mathbb{E}[X \mid \mathcal{G}]$, y es única P-c.s.*

Idea de la demostración. La existencia se basa en el teorema de Radon-Nikodym. Definimos una medida con signo ν sobre $(\Omega, \mathcal{G})$ mediante $\nu(G) = \int_G X\, dP$. Esta medida es absolutamente continua con respecto a $P|_{\mathcal{G}}$. Por Radon-Nikodym, existe una densidad $Z = d\nu/dP|_{\mathcal{G}}$ que es $\mathcal{G}$-medible y satisface $\int_G Z\, dP = \nu(G) = \int_G X\, dP$ para todo $G \in \mathcal{G}$. Esta Z es $\mathbb{E}[X \mid \mathcal{G}]$. La unicidad se sigue de que si Z' es otra, entonces $\int_G (Z - Z')\, dP = 0$ para todo G, lo que implica $Z = Z'$ P-c.s. □

Observación 8.4 (Caso particular: condicionamiento por una variable). Si $\mathcal{G} = \sigma(Y)$ es la σ-álgebra generada por una variable aleatoria Y, entonces $\mathbb{E}[X \mid Y] := \mathbb{E}[X \mid \sigma(Y)]$ es una función medible de Y, es decir, existe una función Borel h tal que $\mathbb{E}[X \mid Y] = h(Y)$. Escribimos $\mathbb{E}[X \mid Y = y] = h(y)$.

8.3 Propiedades fundamentales

Teorema 8.5 (Propiedades de la esperanza condicional)**.** *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad, $\mathcal{G} \subset \mathcal{F}$ una sub-σ-álgebra, y X, Y variables aleatorias integrables. Entonces:*

1. ***Linealidad**: $\mathbb{E}[aX + bY \mid \mathcal{G}] = a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}]$ P-c.s. para $a, b \in \mathbb{R}$.*
2. ***Monotonía**: Si $X \leq Y$ P-c.s., entonces $\mathbb{E}[X \mid \mathcal{G}] \leq \mathbb{E}[Y \mid \mathcal{G}]$ P-c.s.*
3. ***Conservación de la esperanza**: $\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]] = \mathbb{E}[X]$.*
4. ***Torre (proyectividad)**: Si $\mathcal{H} \subset \mathcal{G}$ es otra sub-σ-álgebra, entonces*
$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}] \mid \mathcal{H}] = \mathbb{E}[X \mid \mathcal{H}] \quad P\text{-c.s.}$$
5. ***Sacar lo conocido**: Si Y es $\mathcal{G}$-medible y acotada (o XY es integrable), entonces*
$$\mathbb{E}[XY \mid \mathcal{G}] = Y\mathbb{E}[X \mid \mathcal{G}] \quad P\text{-c.s.}$$
6. ***Independencia**: Si X es independiente de $\mathcal{G}$, entonces $\mathbb{E}[X \mid \mathcal{G}] = \mathbb{E}[X]$ P-c.s.*
7. ***Desigualdad de Jensen**: Si $\varphi : \mathbb{R} \to \mathbb{R}$ es convexa y $\varphi(X)$ es integrable, entonces*
$$\varphi(\mathbb{E}[X \mid \mathcal{G}]) \leq \mathbb{E}[\varphi(X) \mid \mathcal{G}] \quad P\text{-c.s.}$$
8. ***Convergencia monótona**: Si $X_n \uparrow X$ y $X_n \geq 0$, entonces $\mathbb{E}[X_n \mid \mathcal{G}] \uparrow \mathbb{E}[X \mid \mathcal{G}]$ P-c.s.*
9. ***Convergencia dominada**: Si $|X_n| \leq Y$ con Y integrable y $X_n \to X$ P-c.s., entonces $\mathbb{E}[X_n \mid \mathcal{G}] \to \mathbb{E}[X \mid \mathcal{G}]$ P-c.s.*

Demostración. Demostramos algunas propiedades clave:

(1) **Linealidad**: Para cualquier $G \in \mathcal{G}$,

$$\int_G (a\mathbb{E}[X \mid \mathcal{G}]+b\mathbb{E}[Y \mid \mathcal{G}])\, dP = a\int_G \mathbb{E}[X \mid \mathcal{G}]\, dP+b\int_G \mathbb{E}[Y \mid \mathcal{G}]\, dP = a\int_G X\, dP+b\int_G Y\, dP = \int_G (aX+bY)\, d$$

Como $a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}]$ es $\mathcal{G}$-medible, es una versión de $\mathbb{E}[aX + bY \mid \mathcal{G}]$.

(4) **Torre**: Sea $Z = \mathbb{E}[X \mid \mathcal{G}]$. Para cualquier $H \in \mathcal{H} \subset \mathcal{G}$,

$$\int_H \mathbb{E}[Z \mid \mathcal{H}]\, dP = \int_H Z\, dP = \int_H X\, dP.$$

Como $\mathbb{E}[Z \mid \mathcal{H}]$ es $\mathcal{H}$-medible, es una versión de $\mathbb{E}[X \mid \mathcal{H}]$.

(5) **Sacar lo conocido**: Primero para $Y = \mathbf{1}_H$ con $H \in \mathcal{G}$:

$$\mathbb{E}[X\mathbf{1}_H \mid \mathcal{G}] = \mathbf{1}_H\mathbb{E}[X \mid \mathcal{G}]$$

porque para cualquier $G \in \mathcal{G}$,

$$\int_G \mathbf{1}_H\mathbb{E}[X \mid \mathcal{G}]\, dP = \int_{G\cap H} \mathbb{E}[X \mid \mathcal{G}]\, dP = \int_{G\cap H} X\, dP = \int_G X\mathbf{1}_H\, dP.$$

Luego se extiende por linealidad y convergencia monótona a funciones simples, y finalmente a Y acotada por aproximación.

(7) **Jensen**: Se sigue de la representación de funciones convexas como supremo de funciones afines. □

Ejemplo 8.6 (Cálculo concreto)**.** Sea $(\Omega, \mathcal{F}, P) = ([0,1], \mathcal{B}([0,1]), \text{Leb})$, $X(\omega) = \omega^2$, y $\mathcal{G}$ generada por la partición $\{[0,1/2], (1/2,1]\}$. Entonces:

$$\mathbb{E}[X \mid \mathcal{G}](\omega) = \begin{cases} \frac{1}{1/2}\int_0^{1/2} t^2 dt = 2 \cdot \frac{1}{24} = \frac{1}{12} & \text{si } \omega \in [0,1/2] \\ \frac{1}{1/2}\int_{1/2}^{1} t^2 dt = 2 \cdot \left(\frac{1}{3} - \frac{1}{24}\right) = 2 \cdot \frac{7}{24} = \frac{7}{12} & \text{si } \omega \in (1/2,1] \end{cases}$$

Verificamos: $\int_{[0,1/2]} X\, dP = \int_0^{1/2} t^2 dt = 1/24$, e $\int_{[0,1/2]} \mathbb{E}[X \mid \mathcal{G}]\, dP = (1/12) \cdot (1/2) = 1/24$.

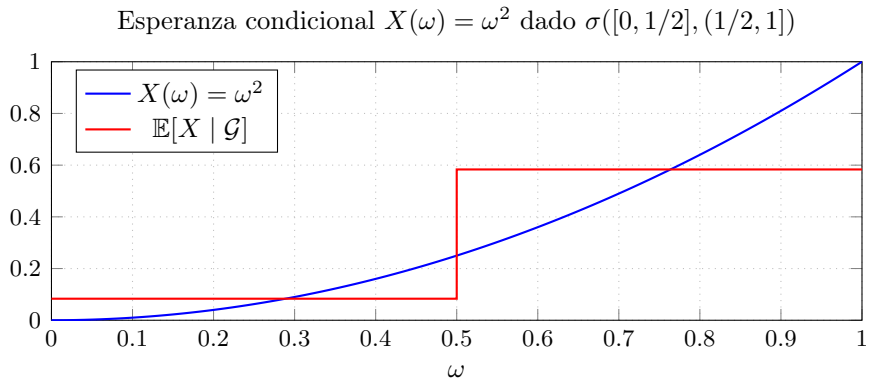

Figura 9: La esperanza condicional promedia X sobre cada átomo de $\mathcal{G}$.

8.4 Esperanza condicional y cambio de medida

Teorema 8.7 (Fórmula de Bayes para esperanzas condicionales)**.** *Sean P y Q medidas equivalentes ($Q \ll P$ y $P \ll Q$) con densidad $Z = dQ/dP$. Entonces para cualquier variable X y sub-σ-álgebra $\mathcal{G}$,*

$$\mathbb{E}_Q[X \mid \mathcal{G}] = \frac{\mathbb{E}_P[XZ \mid \mathcal{G}]}{\mathbb{E}_P[Z \mid \mathcal{G}]} \quad P\text{-c.s.}$$

Demostración. Sea $Y = \mathbb{E}_Q[X \mid \mathcal{G}]$. Por definición, Y es $\mathcal{G}$-medible y para todo $G \in \mathcal{G}$,

$$\int_G Y\, dQ = \int_G X\, dQ.$$

Pero $dQ = Z dP$, por lo que

$$\int_G YZ\, dP = \int_G XZ\, dP.$$

Esto significa que YZ es una versión de $\mathbb{E}_P[XZ \mid \mathcal{G}]$, es decir,

$$YZ = \mathbb{E}_P[XZ \mid \mathcal{G}] \quad P\text{-c.s.}$$

Despejando Y obtenemos la fórmula (notar que $\mathbb{E}_P[Z \mid \mathcal{G}] > 0$ P-c.s. por la equivalencia). □

Ejemplo 8.8 (Aplicación de la fórmula de Bayes)**.** En el contexto del Ejemplo 10.4, con $P = \mathcal{N}(0,1)$, $Q = \mathcal{N}(\mu,1)$, y $Z(x) = e^{\mu x - \mu^2/2}$, calculemos $\mathbb{E}_Q[X \mid X > 0]$. Por la fórmula:

$$\mathbb{E}_Q[X \mid X > 0] = \frac{\mathbb{E}_P[XZ \mid X > 0]}{\mathbb{E}_P[Z \mid X > 0]}.$$

Esto simplifica cálculos que de otra forma requerirían integración directa.

8.5 Ejercicios Resueltos: Cálculo de Esperanzas Condicionales

A continuación se presentan una serie de ejemplos y ejercicios resueltos que ilustran el cálculo de esperanzas condicionales en diversos contextos.

Ejemplo 8.9 (El problema del prisionero)**.** Un prisionero se encuentra atrapado en una celda que contiene 3 puertas. La primera puerta lleva a un túnel que lo regresa a su celda después de dos días de recorrido. La segunda puerta lleva a un túnel que lo regresa a su celda después de dos días de recorrido. La tercera puerta lo conduce a la libertad después de un día de recorrido. Si suponemos que el prisionero siempre seleccionará las puertas 1, 2, y 3 con probabilidades respectivas 0.5, 0.3, y 0.2, ¿cuál es el número esperado de días hasta que el prisionero alcance la libertad?
Solución. Sea Y la variable aleatoria que denota el número de la puerta escogida y X la variable aleatoria que denota el número de días hasta que el prisionero alcance la libertad. Nuestro objetivo es calcular $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X \mid Y]]$. De este modo,

$$\begin{aligned}
\mathbb{E}[X] &= \mathbb{E}[X \mid Y = 1]\mathbb{P}(Y = 1) + \mathbb{E}[X \mid Y = 2]\mathbb{P}(Y = 2) + \mathbb{E}[X \mid Y = 3]\mathbb{P}(Y = 3) \\
&= (2 + \mathbb{E}[X])(0.5) + (2 + \mathbb{E}[X])(0.3) + (1)(0.2) \\
&= 1 + 0.5\mathbb{E}[X] + 0.6 + 0.3\mathbb{E}[X] + 0.2 \\
&= 1.8 + 0.8\mathbb{E}[X]
\end{aligned}$$

Por lo tanto, resolviendo la ecuación, $\mathbb{E}[X] = 9$.

Ejemplo 8.10 (Selección de bolas de una urna)**.** Una urna contiene 30 bolas, de las cuales 10 son rojas y 8 son azules. Se seleccionan 12 bolas de esta urna. Sea X la variable aleatoria que denota el número de bolas rojas seleccionadas, y Y la variable aleatoria que denota el número de bolas azules seleccionadas. Encuentra $\operatorname{cov}(X, Y)$ condicionando para determinar $\mathbb{E}[XY]$.
Solución. X sigue una ley hipergeométrica con parámetros $N = 30$, $K_X = 10$ y $n = 12$. Similarmente, Y sigue una ley hipergeométrica con parámetros $N = 30$, $K_Y = 8$ y $n = 12$. Esto implica que

$$\mathbb{E}[X] = n\frac{K_X}{N} = 4, \qquad \mathbb{E}[Y] = n\frac{K_Y}{N} = \frac{16}{5}.$$

Sabemos que $\mathbb{E}[XY] = \mathbb{E}[\mathbb{E}[XY \mid X]] = \mathbb{E}[X\mathbb{E}[Y \mid X]]$. Dado que se han seleccionado X bolas rojas, quedan 20 bolas que no son rojas (incluyendo las 8 azules) y seleccionamos $12 - X$ de ellas. En este caso, Y sigue una ley hipergeométrica con parámetros $N' = 20$, $K_Y = 8$ y $n' = 12 - X$. Así que

$$\mathbb{E}[Y \mid X] = n'\frac{K_Y}{N'} = \frac{8}{20}(12 - X).$$

Entonces,

$$\mathbb{E}[XY] = \mathbb{E}\left[X \cdot \frac{8}{20}(12 - X)\right] = \frac{2}{5}(12\mathbb{E}[X] - \mathbb{E}[X^2]).$$

Para una hipergeométrica, $\operatorname{Var}(X) = n\frac{K_X}{N}\left(1 - \frac{K_X}{N}\right)\frac{N-n}{N-1} = 12 \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{18}{29} = \frac{144}{87}$. Por lo tanto, $\mathbb{E}[X^2] = \operatorname{Var}(X) + (\mathbb{E}[X])^2 = \frac{144}{87} + 16 = \frac{144+1392}{87} = \frac{1536}{87}$. Sustituyendo, $\mathbb{E}[XY] = \frac{2}{5}\left(12 \cdot 4 - \frac{1536}{87}\right) = \frac{2}{5}\left(48 - \frac{1536}{87}\right) = \frac{2}{5}\left(\frac{4176-1536}{87}\right) = \frac{2}{5} \cdot \frac{2640}{87} = \frac{1056}{87} = \frac{352}{29}$. Finalmente, $\operatorname{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \frac{352}{29} - 4 \cdot \frac{16}{5} = \frac{352}{29} - \frac{64}{5} = \frac{1760-1856}{145} = -\frac{96}{145}$.

Ejemplo 8.11 (Condicionamiento con distribuciones Gamma y Uniforme)**.** Sea (X, Y) un vector aleatorio sobre $\mathbb{R}^2$ tal que:

- X sigue una ley $\Gamma(2,\lambda)$ (de densidad $f_X(x) = \lambda^2 x e^{-\lambda x}\mathbf{1}_{\{x\geq 0\}}$).
- La ley condicional de Y dado X es la ley uniforme sobre el segmento $[0, X]$ (esto es, $f_{Y|X=x}(y) = \frac{1}{x}\mathbf{1}_{\{0<y<x\}}$).

Calcular: a) La densidad conjunta y la ley de Y. b) La densidad condicional de X dado Y. c) $\mathbb{E}[Y|X]$, $\mathbb{E}[X|Y]$, $\mathbb{E}[XY]$ y otras esperanzas.
Solución.

a) La ley conjunta está dada por

$$f_{(X,Y)}(x,y) = f_{Y|X=x}(y) f_X(x) = \lambda^2 e^{-\lambda x}\mathbf{1}_{\{0<y<x\}}.$$

Por lo tanto, Y tiene densidad dada por

$$f_Y(y) = \int_{\mathbb{R}} f_{(X,Y)}(x,y)dx = \lambda^2 \int_y^\infty e^{-\lambda x}dx = \lambda e^{-\lambda y}\mathbf{1}_{\{y>0\}}.$$

Así, $Y \sim \mathrm{Exp}(\lambda)$.

b) Por definición,

$$f_{X|Y=y}(x) = \frac{f_{(X,Y)}(x,y)}{f_Y(y)} = \lambda e^{-\lambda x+\lambda y}\mathbf{1}_{\{0<y<x\}}.$$

c) (i) $\mathbb{E}[Y \mid X] = \int_0^X \frac{y}{X}dy = \frac{X}{2}$. (ii) $\mathbb{E}[X \mid Y] = \int_y^\infty x\lambda e^{-\lambda x+\lambda y}dx$. Haciendo el cambio $u = x - y$, obtenemos

$$\mathbb{E}[X \mid Y] = \left(\frac{1}{\lambda} + Y\right)\mathbf{1}_{\{Y>0\}}.$$

(iii) $\mathbb{E}[XY] = \mathbb{E}[\mathbb{E}[XY|X]] = \mathbb{E}[X\mathbb{E}[Y|X]] = \mathbb{E}[X \cdot \frac{X}{2}] = \frac{\mathbb{E}[X^2]}{2}$. Como $X \sim \Gamma(2,\lambda)$, $\mathbb{E}[X^2] = \frac{6}{\lambda^2}$, por lo que $\mathbb{E}[XY] = \frac{3}{\lambda^2}$. (iv) $\mathbb{E}[X + XY \mid Y] = \mathbb{E}[X \mid Y] + Y\mathbb{E}[X \mid Y] = (Y+1)\left(\frac{1}{\lambda} + Y\right)$. (v) $\mathbb{E}[\mathbb{E}[Y \mid X]] = \mathbb{E}[X/2] = \frac{1}{\lambda}$.

Ejemplo 8.12 (Condicionamiento para la distribución uniforme en $[-1,1]$)**.** Supongamos que X sigue una ley uniforme sobre $[-1,1]$. Para toda $x \in \mathbb{R}$, denotemos $x^+ := \max\{x, 0\}$. Calcular $\mathbb{E}[X \mid X^+]$, $\mathbb{E}[X^2 \mid X^+]$ y $\mathbb{E}[X^n \mid X^+]$ para $n \geq 3$.
Solución. Observamos que $X = X\mathbf{1}_{\{X>0\}} + X\mathbf{1}_{\{X\leq 0\}}$. Por la propiedad de sacar lo conocido y la simetría de la distribución condicionada a los conjuntos donde X^+ es constante,

$$\mathbb{E}[X \mid X^+] = X^+ - \frac{1}{2}\mathbf{1}_{\{X\leq 0\}}.$$

Para el cuadrado, $X^2 = (X^+)^2 + X^2\mathbf{1}_{\{X\leq 0\}}$. Condicionando,

$$\mathbb{E}[X^2 \mid X^+] = (X^+)^2 + \frac{\mathbb{E}[X^2\mathbf{1}_{\{X\leq 0\}}]}{\mathbb{P}(X \leq 0)}\mathbf{1}_{\{X\leq 0\}} = (X^+)^2 + \frac{1}{3}\mathbf{1}_{\{X\leq 0\}}.$$

En general, para $n \geq 3$,

$$\mathbb{E}[X^n \mid X^+] = (X^+)^n - \frac{(-1)^{n+1}}{n+1}\mathbf{1}_{\{X\leq 0\}}.$$

8.6 Esperanza condicional para vectores gaussianos

Un caso particularmente importante y manejable es el de la esperanza condicional en el contexto de vectores gaussianos. La propiedad fundamental es que la esperanza condicional de una componente (o combinación lineal) dadas otras es una función lineal de las condicionantes.

Teorema 8.13 (Esperanza condicional en vectores gaussianos)**.** *Sea (X_1, X_2) un vector gaussiano de media $\mu = (\mu_1, \mu_2)^t$ y de matriz de covarianza*

$$D = \begin{pmatrix} D_{11} & D_{12} \\ D_{12} & D_{22} \end{pmatrix}$$

con $D_{22} > 0$. Entonces, la esperanza condicional de X_1 dado X_2 es

$$\mathbb{E}[X_1 \mid X_2] = \mu_1 + \frac{D_{12}}{D_{22}}(X_2 - \mu_2).$$

Además, la varianza condicional (que no depende del valor de X_2) es $\mathrm{Var}(X_1 \mid X_2) = D_{11} - \frac{D_{12}^2}{D_{22}}$.

Demostración. Sea $\phi(x) = \mu_1 + \frac{D_{12}}{D_{22}}(x - \mu_2)$. Mostremos que para cualquier función h acotada, $\mathbb{E}[(X_1 - \phi(X_2))h(X_2)] = 0$. Notamos que las variables $X_1 - \phi(X_2)$ y $X_2 - \mu_2$ son independientes, pues su covarianza es cero y el vector conjunto es gaussiano. Así,

$$\mathbb{E}[(X_1 - \phi(X_2))h(X_2)] = \mathbb{E}[X_1 - \phi(X_2)]\mathbb{E}[h(X_2)] = 0.$$

Esto demuestra que $\phi(X_2)$ es una versión de la esperanza condicional. El cálculo de la varianza condicional se sigue de la fórmula para la varianza de una gaussiana condicionada. □

Ejemplo 8.14 (Aplicación de la fórmula gaussiana)**.** Sea (X, Y, Z) un vector gaussiano centrado de matriz de covarianza

$$D = \begin{pmatrix} 3 & -2 & 1 \\ -2 & 3 & 1 \\ 1 & 1 & 3 \end{pmatrix}.$$

Determinar varias esperanzas condicionales.
Solución.

- $\mathbb{E}[X \mid Y] = \frac{\mathrm{cov}(X,Y)}{\mathrm{Var}(Y)} Y = \frac{-2}{3} Y$.
- $\mathbb{E}[Y \mid X] = \frac{-2}{3} X$.
- $\mathbb{E}[Z \mid Y] = \frac{1}{3} Y$.
- Para $\mathbb{E}[X \mid Y, Z]$, utilizamos la fórmula matricial. La matriz de covarianza de (Y, Z) es $D_{(Y,Z)} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$. Entonces,

$$\mathbb{E}[X \mid Y, Z] = D_{X,(Y,Z)} D_{(Y,Z)}^{-1} \begin{pmatrix} Y \\ Z \end{pmatrix} = \frac{1}{8}(-2, 1) \begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix} \begin{pmatrix} Y \\ Z \end{pmatrix} = \frac{-7Y + 5Z}{8}.$$

- $\mathbb{E}[Y \mid X, Z] = \frac{-7X+5Z}{8}$.

- Para $\mathbb{E}[X \mid 4Y + 5Z]$, calculamos la covarianza: $\operatorname{cov}(X, 4Y + 5Z) = 4\operatorname{cov}(X, Y) + 5\operatorname{cov}(X, Z) = 4(-2) + 5(1) = -8 + 5 = -3$. La varianza es $\operatorname{Var}(4Y + 5Z) = 16 \cdot 3 + 25 \cdot 3 + 2 \cdot 4 \cdot 5 \cdot 1 = 48 + 75 + 40 = 163$. Por lo tanto, $\mathbb{E}[X \mid 4Y + 5Z] = \frac{-3}{163}(4Y + 5Z)$.

Ejemplo 8.15 (Independencia y condicionamiento con gaussianas)**.** Sean X_1, X_2, X_3 tres variables gaussianas estándar independientes. Sea $U = 2X_1 - X_2 - X_3$, $V = X_1 + X_2 + X_3$, $W = 3X_1 + X_2 - 4X_3$. Demuestra que existe $a \in \mathbb{R}$ tal que $W = aU + Z$ con U y Z independientes. Calcula $\mathbb{E}[W \mid U]$, $\mathbb{E}[W^2 \mid U]$ y $\mathbb{E}[W^3 \mid U]$.
Solución. Calculamos las varianzas y covarianzas: $\operatorname{Var}(U) = 6$, $\operatorname{Var}(W) = 26$, $\operatorname{cov}(U, W) = 9$. El vector $(W - aU, U)$ es gaussiano. Sus coordenadas son independientes si y sólo si $\operatorname{cov}(W - aU, U) = \operatorname{cov}(W, U) - a\operatorname{Var}(U) = 9 - 6a = 0$, es decir $a = \frac{3}{2}$. Entonces, $Z = W - \frac{3}{2}U$ es independiente de U, con $\mathbb{E}[Z] = 0$ y $\operatorname{Var}(Z) = \operatorname{Var}(W) + \frac{9}{4}\operatorname{Var}(U) - 2 \cdot \frac{3}{2}\operatorname{cov}(W, U) = 26 + \frac{9}{4} \cdot 6 - 3 \cdot 9 = 26 + 13.5 - 27 = 12.5 = \frac{25}{2}$. Por lo tanto,

- $\mathbb{E}[W \mid U] = \frac{3}{2}U$.
- $\mathbb{E}[W^2 \mid U] = \mathbb{E}\left[\left(\frac{3}{2}U + Z\right)^2 \mid U\right] = \frac{9}{4}U^2 + \mathbb{E}[Z^2] = \frac{9}{4}U^2 + \frac{25}{2}$.
- $\mathbb{E}[W^3 \mid U] = \mathbb{E}\left[\left(\frac{3}{2}U + Z\right)^3 \mid U\right] = \frac{27}{8}U^3 + 3 \cdot \frac{3}{2}U\mathbb{E}[Z^2] = \frac{27}{8}U^3 + \frac{9}{2}U \cdot \frac{25}{2} = \frac{27}{8}U^3 + \frac{225}{4}U$.

8.7 Esperanza condicional y martingalas

Definición 8.16 (Martingala discreta)**.** Una sucesión $\{X_n\}_{n \geq 0}$ de variables aleatorias integrables adaptada a una filtración $\{\mathcal{F}_n\}_{n \geq 0}$ es una *martingala* si para todo $n \geq 0$,

$$\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = X_n \quad P\text{-c.s.}$$

Si la igualdad se reemplaza por $\leq$ (resp. $\geq$), se llama *supermartingala* (resp. *submartingala*).

Ejemplo 8.17 (Ejemplos clásicos de martingalas)**.** 1. **Caminata aleatoria simétrica**: Sea $\{\xi_n\}$ i.i.d. con $\mathbb{E}[\xi_n] = 0$ y $S_n = \sum_{k=1}^n \xi_k$ con $S_0 = 0$. Entonces $\{S_n\}$ es martingala respecto a $\mathcal{F}_n = \sigma(\xi_1, \ldots, \xi_n)$.

2. **Producto de variables independientes**: Sea $\{Y_n\}$ i.i.d. con $\mathbb{E}[Y_n] = 1$ y $M_n = \prod_{k=1}^n Y_k$ con $M_0 = 1$. Entonces $\{M_n\}$ es martingala.

3. **Proceso de Galton-Watson**: Sea $\{Z_n\}$ un proceso de ramificación con media μ. Entonces $\{Z_n/\mu^n\}$ es martingala.

4. **Derivada de Radon-Nikodym**: Sea $Q \ll P$ con densidad $Z = dQ/dP$. Definimos $Z_n = \mathbb{E}_P[Z \mid \mathcal{F}_n]$. Entonces $\{Z_n\}$ es una martingala (llamada martingala de Radon-Nikodym).

Ejemplo 8.18 (Martingala de razón de verosimilitud)**.** En el contexto del Ejemplo 10.4, sea $P = \mathcal{N}(0, 1)$, $Q = \mathcal{N}(\mu, 1)$, y $X_1, X_2, \ldots$ i.i.d. bajo P. Definimos

$$L_n = \prod_{i=1}^n \frac{dQ}{dP}(X_i) = \exp\left(\mu \sum_{i=1}^n X_i - \frac{n\mu^2}{2}\right).$$

Entonces $\{L_n\}$ es una martingala bajo P respecto a $\mathcal{F}_n = \sigma(X_1, \ldots, X_n)$. Esto se verifica:

$$\mathbb{E}_P[L_{n+1} \mid \mathcal{F}_n] = L_n \mathbb{E}_P\left[\frac{dQ}{dP}(X_{n+1})\right] = L_n \cdot 1 = L_n.$$

Esta martingala es fundamental en el test de hipótesis secuencial y en la teoría de cambio de medida.

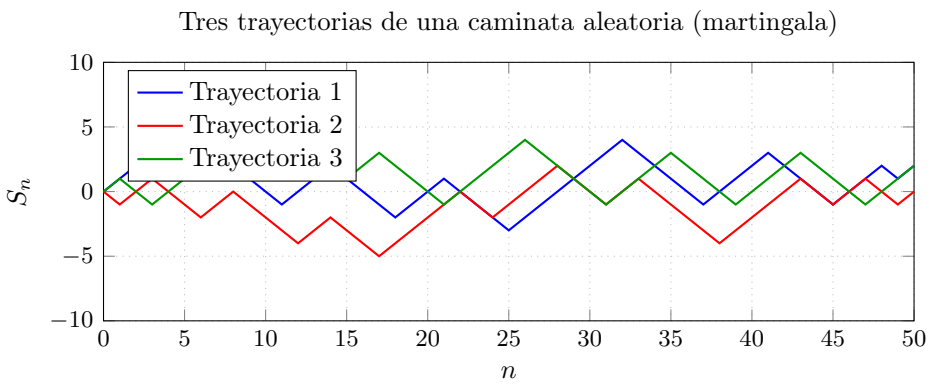

Figura 10: Tres trayectorias de una caminata aleatoria simétrica. La propiedad de martingala implica que el valor esperado futuro dado el pasado es el valor actual.

8.8 Tiempos de paro y teorema de paro opcional

Definición 8.19 (Tiempo de paro)**.** Una variable aleatoria $\tau : \Omega \to \{0, 1, 2, \ldots\} \cup \{\infty\}$ es un *tiempo de paro* respecto a una filtración $\{\mathcal{F}_n\}$ si $\{\tau \leq n\} \in \mathcal{F}_n$ para todo n.

Teorema 8.20 (Teorema de paro opcional de Doob)**.** *Sea $\{X_n\}$ una martingala y τ un tiempo de paro. Entonces, bajo cualquiera de las siguientes condiciones:*

1. *τ es acotado (existe N tal que $\tau \leq N$ P-c.s.).*
2. *$\{X_n\}$ es uniformemente integrable y $\tau < \infty$ P-c.s.*
3. *$\mathbb{E}[\tau] < \infty$ y $|X_{n+1} - X_n| \leq C$ para todo n,*

se tiene $\mathbb{E}[X_\tau] = \mathbb{E}[X_0]$. Más generalmente, $\mathbb{E}[X_\tau \mid \mathcal{F}_\sigma] = X_\sigma$ para tiempos de paro $\sigma \leq \tau$ bajo condiciones adecuadas.

Ejemplo 8.21 (Aplicación: problema del sobre)**.** Un jugador lanza una moneda repetidamente. Antes de cada lanzamiento, puede apostar cualquier cantidad no negativa que no exceda su fortuna actual. Si sale cara, recupera el doble de lo apostado; si sale cruz, pierde la apuesta. ¿Existe una estrategia que garantice una ganancia esperada positiva? La teoría de martingalas muestra que no: la fortuna del jugador es una martingala bajo cualquier estrategia predecible, y bajo tiempos de paro acotados, la esperanza permanece constante.

8.9 Descomposición de Doob

Teorema 8.22 (Descomposición de Doob)**.** *Toda submartingala $\{X_n\}$ puede descomponerse de manera única como*

$$X_n = M_n + A_n,$$

donde $\{M_n\}$ es una martingala y $\{A_n\}$ es un proceso predecible creciente con $A_0 = 0$.

Idea. Definimos $A_0 = 0$ y recursivamente:

$$A_{n+1} - A_n = \mathbb{E}[X_{n+1} - X_n \mid \mathcal{F}_n] \geq 0,$$

y $M_n = X_n - A_n$. Se verifica que M_n es martingala. □

Esta descomposición es fundamental en el cálculo estocástico discreto y conduce a la noción de variación cuadrática.

9 Integral Estocástica Discreta

9.1 Introducción

La integral estocástica en tiempo discreto es una herramienta fundamental para modelar sistemas donde la incertidumbre se resuelve paso a paso. Surge naturalmente en finanzas (estrategias de trading), control estocástico y filtrado.

Definición 9.1 (Proceso predecible)**.** Un proceso $\{H_n\}_{n\geq 1}$ es *predecible* (o previsible) respecto a una filtración $\{\mathcal{F}_n\}$ si H_n es $\mathcal{F}_{n-1}$-medible para todo $n \geq 1$. Interpretamos H_n como la cantidad apostada/invertida en el periodo n, basada en la información hasta $n-1$.

9.2 Definición de la integral estocástica discreta

Definición 9.2 (Transformada de martingala)**.** Sea $\{M_n\}$ una martingala (o más generalmente un proceso adaptado) y $\{H_n\}$ un proceso predecible. Definimos la *transformada de martingala* (o integral estocástica discreta) $(H \cdot M)_n$ mediante:

$$(H \cdot M)_0 = 0, \quad (H \cdot M)_n = \sum_{k=1}^{n} H_k(M_k - M_{k-1}), \quad n \geq 1.$$

Observación 9.3 (Interpretación financiera)*.* En un modelo de mercado, M_n representa el precio de un activo riesgoso y H_k el número de acciones mantenidas en el periodo k. Entonces $(H \cdot M)_n$ es la ganancia o pérdida acumulada hasta n de la estrategia de trading $\{H_k\}$.

9.3 Propiedades fundamentales

Teorema 9.4 (Propiedades de la transformada de martingala)**.** *1.* ***Linealidad****: $(H+K)\cdot M = H \cdot M + K \cdot M$ y $(cH) \cdot M = c(H \cdot M)$.*

2. ***Adaptación****: $(H \cdot M)_n$ es $\mathcal{F}_n$-medible.*

3. ***Propiedad de martingala****: Si $\{M_n\}$ es una martingala y $\{H_n\}$ es predecible y acotado (o más generalmente $\mathbb{E}[|H_k(M_k - M_{k-1})|] < \infty$), entonces $\{(H \cdot M)_n\}$ es una martingala.*

4. ***Varianza****: Si $\{M_n\}$ es una martingala de cuadrado integrable, entonces*

$$\mathbb{E}[(H \cdot M)_n^2] = \mathbb{E}\left[\sum_{k=1}^{n} H_k^2 (M_k - M_{k-1})^2\right].$$

5. ***Isometría****: Bajo condiciones de cuadrado integrable, se cumple la isometría:*

$$\mathbb{E}[(H \cdot M)_n^2] = \mathbb{E}\left[\sum_{k=1}^{n} H_k^2 \Delta\langle M\rangle_k\right],$$

donde $\langle M\rangle_k$ es la variación cuadrática de M.

Demostración. (1) y (2) son inmediatas de la definición.

(3) Para ver que es martingala, calculamos:

$$\begin{aligned}
\mathbb{E}[(H \cdot M)_{n+1} \mid \mathcal{F}_n] &= \mathbb{E}[(H \cdot M)_n + H_{n+1}(M_{n+1} - M_n) \mid \mathcal{F}_n] \\
&= (H \cdot M)_n + H_{n+1}\mathbb{E}[M_{n+1} - M_n \mid \mathcal{F}_n] \\
&= (H \cdot M)_n + H_{n+1} \cdot 0 = (H \cdot M)_n,
\end{aligned}$$

donde usamos que H_{n+1} es $\mathcal{F}_n$-medible.

(4) Se sigue de que los incrementos de martingala son no correlacionados:

$$\mathbb{E}[(H \cdot M)_n^2] = \sum_{k=1}^{n} \mathbb{E}[H_k^2 (M_k - M_{k-1})^2] + 2 \sum_{i<j} \mathbb{E}[H_i H_j (M_i - M_{i-1})(M_j - M_{j-1})].$$

Para $i < j$, el término cruzado es $\mathbb{E}[H_i H_j (M_i - M_{i-1}) \mathbb{E}[M_j - M_{j-1} \mid \mathcal{F}_{j-1}]] = 0$. □

Ejemplo 9.5 (Caminata aleatoria e integral)**.** Sea $\{\xi_n\}$ i.i.d. con $\mathbb{E}[\xi_n] = 0$, $\mathrm{Var}(\xi_n) = 1$, y $M_n = \sum_{k=1}^{n} \xi_k$ (martingala). Sea $H_n = M_{n-1}$ (estrategia "comprar cuando el precio es alto"). Entonces

$$(H \cdot M)_n = \sum_{k=1}^{n} M_{k-1} \xi_k.$$

Esta es una martingala (si $\mathbb{E}[M_{k-1}^2] < \infty$). Su varianza es

$$\mathbb{E}[(H \cdot M)_n^2] = \sum_{k=1}^{n} \mathbb{E}[M_{k-1}^2] = \sum_{k=1}^{n} (k-1) = \frac{n(n-1)}{2}.$$

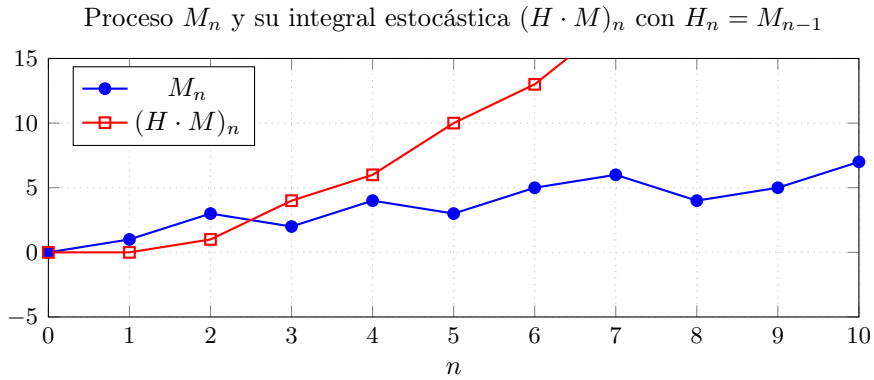

Figura 11: La integral estocástica acumula los productos $H_k(M_k - M_{k-1})$. Nótese que $(H \cdot M)_n$ es mucho más variable que M_n.

9.4 Integral estocástica y cambio de medida

Teorema 9.6 (Transformación de Girsanov en tiempo discreto)**.** *Sean P y Q medidas equivalentes con densidad $Z_n = \mathbb{E}_P[Z \mid \mathcal{F}_n]$ donde $Z = dQ/dP$. Entonces $\{Z_n\}$ es una martingala positiva bajo P. Si definimos*

$$M_n^Q = M_n - \sum_{k=1}^{n} \frac{1}{Z_{k-1}} \mathbb{E}_P[(M_k - M_{k-1}) Z_k \mid \mathcal{F}_{k-1}],$$

entonces $\{M_n^Q\}$ es una martingala bajo Q. Equivalentemente, el cambio de medida añade un "drift" que se expresa como una integral estocástica.

Ejemplo 9.7 (Cambio de medida para caminata aleatoria)**.** Sea $\{\xi_n\}$ i.i.d. $\mathcal{N}(0,1)$ bajo P, y $M_n = \sum_{k=1}^{n} \xi_k$. Bajo Q con densidad $Z = \exp(\mu M_n - n\mu^2/2)$, tenemos que $\xi_n^Q = \xi_n - \mu$ son i.i.d. $\mathcal{N}(0,1)$ bajo Q. Entonces

$$M_n = \underbrace{(M_n - n\mu)}_{\text{martingala bajo } Q} + n\mu.$$

El término $n\mu$ puede escribirse como $\sum_{k=1}^{n} \mu\, dk$, que en tiempo continuo sería una integral de Lebesgue, pero en discreto es simplemente una suma determinista.

9.5 Aplicación: Representación de martingalas

Teorema 9.8 (Representación de martingalas en tiempo discreto)**.** *Sea $\{\xi_n\}$ una sucesión de variables aleatorias independientes con $\mathbb{E}[\xi_n] = 0$ y $\mathrm{Var}(\xi_n) = 1$, y sea $\mathcal{F}_n = \sigma(\xi_1, \ldots, \xi_n)$. Entonces toda martingala $\{M_n\}$ de cuadrado integrable puede representarse como*

$$M_n = M_0 + \sum_{k=1}^{n} H_k \xi_k,$$

donde $\{H_k\}$ es un proceso predecible. Explícitamente,

$$H_k = \mathbb{E}[M_k \xi_k \mid \mathcal{F}_{k-1}] = \mathbb{E}[(M_k - M_{k-1})\xi_k \mid \mathcal{F}_{k-1}].$$

Demostración. Definimos H_k como arriba. Verificamos que $M_n - M_0 - \sum_{k=1}^{n} H_k \xi_k$ es una martingala ortogonal a ξ, y por tanto constante. □

Esta representación es el análogo discreto del teorema de representación de martingalas para el movimiento browniano, fundamental en finanzas matemáticas para la cobertura de opciones.

Ejemplo 9.9 (Representación de una martingala)**.** Con ξ_n i.i.d. con distribución simétrica, sea $M_n = S_n^2 - n$ donde $S_n = \sum_{k=1}^{n} \xi_k$. Entonces M_n es martingala y:

$$M_n = \sum_{k=1}^{n} (S_{k-1}^2 - (k-1) + 2S_{k-1}\xi_k + \xi_k^2 - 1) - (S_n^2 - n) \text{ (cálculo directo).}$$

La representación da $H_k = 2S_{k-1}$, es decir,

$$M_n = \sum_{k=1}^{n} 2S_{k-1}\xi_k.$$

10 Identidad del cambio de medida: $\mathbb{E}_Q[X] = \mathbb{E}_P[XZ]$

Ahora asumimos que $(\Omega, \mathcal{F}, P)$ es un espacio de probabilidad, $Z \geq 0$ con $\mathbb{E}_P[Z] = 1$, y definimos $Q(A) = \int_A Z(\omega)\, P(d\omega)$ como en §3–§4. Entonces $Z = \frac{dQ}{dP}$.

Teorema 10.1 (Identidad fundamental)**.** *Sea X una variable aleatoria no negativa medible. Entonces*

$$\mathbb{E}_Q[X] = \int_\Omega X(\omega)\, Q(d\omega) = \int_\Omega X(\omega) Z(\omega)\, P(d\omega) = \mathbb{E}_P[XZ].$$

Si $X \in L^1(Q)$ (equivalentemente $\int |X|\,(\omega) Z(\omega)\, P(d\omega) < \infty$), entonces lo mismo se cumple para X con signo:

$$\mathbb{E}_Q[X] = \mathbb{E}_P[XZ].$$

Demostración. **Paso 1: $X = \mathbf{1}_A$.** Si $X = \mathbf{1}_A$, entonces

$$\mathbb{E}_Q[\mathbf{1}_A] = Q(A) = \int_A Z(\omega)\, P(d\omega) = \int_\Omega \mathbf{1}_A(\omega) Z(\omega)\, P(d\omega) = \mathbb{E}_P[\mathbf{1}_A Z].$$

Paso 2: X simple no negativa. Sea $X = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$ con $a_i \geq 0$ y A_i disjuntos. Por el Paso 1 y la linealidad (suma finita),

$$\mathbb{E}_Q[X] = \sum_{i=1}^n a_i Q(A_i) = \sum_{i=1}^n a_i \int_{A_i} Z(\omega)\, P(d\omega) = \int_\Omega \Big(\sum_{i=1}^n a_i \mathbf{1}_{A_i}(\omega) \Big) Z(\omega)\, P(d\omega) = \mathbb{E}_P[XZ].$$

Paso 3: $X \geq 0$ general. Elegimos X_n simples con $X_n \uparrow X$ puntualmente (Lema en §2.2). Entonces $X_n Z \uparrow XZ$ ya que $Z \geq 0$. Aplicamos Convergencia Monótona dos veces:

$$\mathbb{E}_Q[X] = \lim_{n\to\infty} \mathbb{E}_Q[X_n] = \lim_{n\to\infty} \mathbb{E}_P[X_n Z] = \mathbb{E}_P[XZ],$$

donde la igualdad del medio usa el Paso 2.

Paso 4: X con signo integrable. Escribimos $X = X^+ - X^-$. Si $X \in L^1(Q)$ entonces $\mathbb{E}_Q[X^+] < \infty$ y $\mathbb{E}_Q[X^-] < \infty$. Por el Paso 3,

$$\mathbb{E}_Q[X^+] = \mathbb{E}_P[X^+ Z], \qquad \mathbb{E}_Q[X^-] = \mathbb{E}_P[X^- Z].$$

Restamos para obtener $\mathbb{E}_Q[X] = \mathbb{E}_P[XZ]$, sin ambigüedad $\infty - \infty$. □

Ejemplo 10.2 (Cambio de medida para momentos)**.** Con P uniforme en $[0,1]$, $P(dx) = dx$, $Z(x) = 2x$, $Q(dx) = 2x\, dx$. Calculemos $\mathbb{E}_Q[X]$ para $X(x) = x^2$:

$$\mathbb{E}_Q[X] = \mathbb{E}_P[XZ] = \int_0^1 x^2 \cdot 2x\, dx = 2\int_0^1 x^3\, dx = 2 \cdot \frac{1}{4} = \frac{1}{2}.$$

Verificación directa: $\mathbb{E}_Q[X] = \int_0^1 x^2 \cdot 2x\, dx = 1/2$ (coincide).

Ejemplo 10.3 (Esperanza condicional y cambio de medida)**.** En el mismo contexto, calculemos $\mathbb{E}_Q[X]$ para $X(x) = \mathbf{1}_{[0,0.5]}$:

$$\mathbb{E}_Q[X] = \mathbb{E}_P[XZ] = \int_0^{0.5} 2x\, dx = [x^2]_0^{0.5} = 0.25.$$

Directamente: $Q([0, 0.5]) = 0.5^2 = 0.25$.

Ejemplo 10.4 (Cambio de medida entre normales)**.** Sean $P = \mathcal{N}(0,1)$ y $Q = \mathcal{N}(\mu, 1)$ medidas en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. La derivada de Radon–Nikodym es

$$\frac{dQ}{dP}(x) = \frac{e^{-(x-\mu)^2/2}}{e^{-x^2/2}} = e^{\mu x - \mu^2/2}.$$

Por la identidad de cambio de medida, para cualquier $g \in L^1(Q)$:

$$\mathbb{E}_Q[g(X)] = \mathbb{E}_P\Big[g(X)\, e^{\mu X - \mu^2/2} \Big].$$

Por ejemplo, con $\mu = 1$ y $g(x) = x^2$:

$$\mathbb{E}_Q[X^2] = \mathbb{E}_P[X^2 e^{X - 1/2}].$$

Directamente: $\mathbb{E}_Q[X^2] = \mathrm{Var}_Q(X) + (\mathbb{E}_Q X)^2 = 1 + \mu^2 = 2$. El cambio de medida da el mismo resultado.

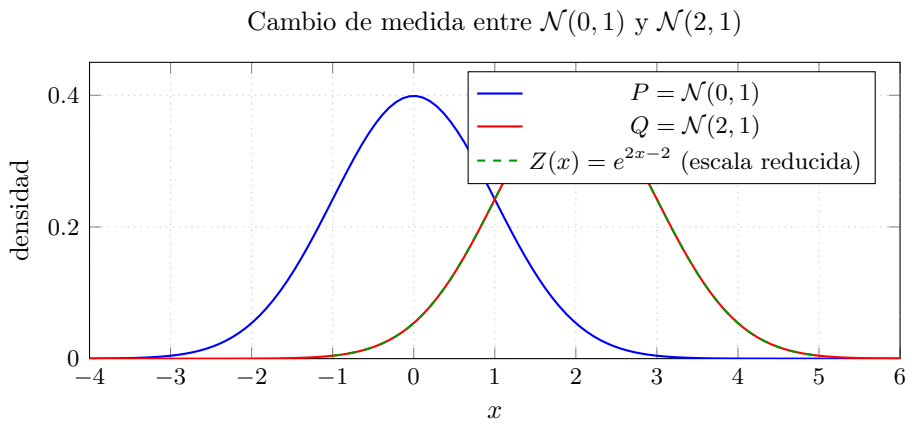

Figura 12: Al desplazar la media en $\mu = 2$, el cociente $dQ/dP = e^{2x-2}$ penaliza las colas izquierdas y amplifica las colas derechas.

Corolario 10.5 (Forma de Bayes / cociente de verosimilitudes)**.** *Si* $Z = \frac{dQ}{dP}$, *entonces también* $\frac{dP}{dQ} = \frac{1}{Z}$ *sobre* $\{Z > 0\}$, *y para* $X \in L^1(P)$,

$$\mathbb{E}_P[X] = \mathbb{E}_Q\Big[X\,\frac{dP}{dQ}\Big] = \mathbb{E}_Q\Big[\frac{X}{Z}\,\mathbf{1}_{\{Z>0\}}\Big],$$

siempre que el lado derecho esté bien definido.

Ejemplo 10.6 (Uso de la forma de Bayes)**.** Con los mismos P, Q, calculemos $\mathbb{E}_P[X]$ para $X(x) = x$ usando Q:

$$\mathbb{E}_P[X] = \mathbb{E}_Q\left[\frac{X}{Z}\right] = \int_0^1 \frac{x}{2x} \cdot 2x\,dx \text{ (¿cuidado?)}$$

Mejor: $\frac{dP}{dQ}(x) = \frac{1}{Z(x)} = \frac{1}{2x}$ para $x > 0$. Entonces:

$$\mathbb{E}_P[X] = \mathbb{E}_Q\left[X \cdot \frac{dP}{dQ}\right] = \int_0^1 x \cdot \frac{1}{2x} \cdot 2x\,dx = \int_0^1 x\,dx = \frac{1}{2}.$$

Notar que Z aparece dos veces: una en $Q(dx) = Z(x)P(dx)$ y otra en la fórmula.

11 Aplicación: Algoritmos Genéticos y Cambio de Medida

En esta sección exploramos una aplicación concreta de la teoría de cambio de medida en el contexto de los algoritmos genéticos. Específicamente, mostramos cómo la estimación por máxima verosimilitud (MLE) puede formularse como un problema de cambio de medida, y cómo los algoritmos genéticos proporcionan un método eficaz para resolverlo cuando la función de verosimilitud es compleja o multimodal.

11.1 Estimación por Máxima Verosimilitud como Cambio de Medida

Definición 11.1 (Modelo estadístico paramétrico)**.** Un *modelo estadístico paramétrico* es una familia de medidas de probabilidad $\{P_\theta : \theta \in \Theta\}$ sobre $(\Omega, \mathcal{F})$, donde $\Theta \subseteq \mathbb{R}^d$ es el espacio de parámetros. Suponemos que cada P_θ es absolutamente continua con respecto a una medida σ-finita μ (típicamente la medida de Lebesgue o de conteo), con densidad $f_\theta = dP_\theta/d\mu$.

Observación 11.2 (Verosimilitud como derivada de Radon-Nikodym). Para una observación $x \in \Omega$, la *verosimilitud* $L(\theta|x) = f_\theta(x)$ es precisamente la derivada de Radon-Nikodym de P_θ con respecto a μ evaluada en x. Dadas observaciones independientes $x_1, \ldots, x_n$, la verosimilitud conjunta es

$$L(\theta|x_1, \ldots, x_n) = \prod_{i=1}^{n} f_\theta(x_i) = \frac{dP_\theta^{\otimes n}}{d\mu^{\otimes n}}(x_1, \ldots, x_n),$$

donde $P_\theta^{\otimes n}$ es la medida producto en Ω^n.

Teorema 11.3 (Identidad de cambio de medida para verosimilitud)**.** *Sean P_{θ_0} y P_{θ_1} dos medidas en el modelo. Entonces para cualquier variable aleatoria X medible,*

$$\mathbb{E}_{\theta_1}[X] = \mathbb{E}_{\theta_0}\left[X \frac{dP_{\theta_1}}{dP_{\theta_0}}\right] = \mathbb{E}_{\theta_0}\left[X \frac{f_{\theta_1}}{f_{\theta_0}}\right],$$

donde el cociente $f_{\theta_1}/f_{\theta_0}$ es el cociente de verosimilitudes *(likelihood ratio).*

Demostración. Es una aplicación directa del Teorema 10.1 con $Z = dP_{\theta_1}/dP_{\theta_0} = f_{\theta_1}/f_{\theta_0}$. □

Corolario 11.4 (Verosimilitud como peso de importancia)**.** *Para estimar esperanzas bajo P_{θ_1} utilizando muestras de P_{θ_0}, podemos reweightear las observaciones con el cociente de verosimilitudes. Esta es la base del* muestreo por importancia *(importance sampling) y tiene aplicaciones directas en algoritmos genéticos cuando la población evoluciona mediante pesos de verosimilitud.*

11.2 El Problema de Máxima Verosimilitud

Dadas observaciones $\mathbf{x} = (x_1, \ldots, x_n)$, el estimador de máxima verosimilitud es

$$\hat{\theta}_{\text{MLE}} = \arg\max_{\theta \in \Theta} L(\theta|\mathbf{x}) = \arg\max_{\theta \in \Theta} \sum_{i=1}^{n} \log f_\theta(x_i).$$

Este problema de optimización puede ser:

- **Analíticamente resoluble**: cuando la log-verosimilitud es diferenciable y las ecuaciones de score tienen solución cerrada (ej: familia exponencial).
- **Numerablemente resoluble**: cuando existen algoritmos iterativos como Newton-Raphson o EM.
- **Intratable analíticamente**: cuando la función es multimodal, no diferenciable, o el espacio de parámetros es complejo.

En el último caso, los algoritmos genéticos ofrecen una alternativa robusta.

11.3 Algoritmos Genéticos para Máxima Verosimilitud

Definición 11.5 (Codificación)**.** Cada individuo en la población del algoritmo genético representa un vector de parámetros $\theta \in \Theta$. Por ejemplo, para una distribución normal $N(\mu, \sigma^2)$, cada individuo es (μ, σ).

Definición 11.6 (Función de aptitud)**.** La *fitness* de un individuo θ se define como su log-verosimilitud (o una transformación monótona de ella):

$$\text{fitness}(\theta) = \ell(\theta|\mathbf{x}) = \sum_{i=1}^{n} \log f_\theta(x_i).$$

Para problemas de minimización, puede utilizarse $-\ell(\theta)$ o $1/(1+\ell(\theta))$ si $\ell(\theta)$ puede ser negativo.

Observación 11.7 (Interpretación probabilística)*.* La función de fitness puede interpretarse como el logaritmo de la densidad conjunta de los datos bajo el modelo P_θ. Maximizar la fitness equivale a encontrar la medida P_θ que hace más probables las observaciones, es decir, la que tiene mayor verosimilitud.

11.4 Operadores Genéticos en el Espacio de Parámetros

- **Selección**: Los individuos con mayor fitness (mayor verosimilitud) tienen mayor probabilidad de ser seleccionados para reproducción. Esto corresponde a un *reweighting* de la población hacia regiones de alta verosimilitud, análogo al muestreo por importancia.
- **Cruce (crossover)**: Dados dos padres $\theta^{(1)}$ y $\theta^{(2)}$, el cruce genera hijos combinando sus componentes. Por ejemplo, cruce uniforme: cada componente del hijo se toma aleatoriamente de uno de los padres. Esto explora combinaciones lineales de parámetros prometedores.
- **Mutación**: Se añade una perturbación aleatoria a los parámetros:

  $$\theta' = \theta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2_{\text{mut}}) \text{ o } \varepsilon \sim \text{Uniforme}(-\delta, \delta).$$

  La mutación permite explorar regiones no representadas en la población inicial y evita la convergencia prematura a óptimos locales.

Ejemplo 11.8 (Distribución Gumbel para valores extremos)**.** La distribución Gumbel (valor extremo tipo I) tiene densidad

$$f(x|\mu,\beta) = \frac{1}{\beta} e^{-(z+e^{-z})}, \quad z = \frac{x-\mu}{\beta},\ \beta > 0.$$

Su log-verosimilitud para una muestra $\{x_i\}$ es

$$\ell(\mu,\beta) = -n\log\beta - \sum_{i=1}^{n}\left(\frac{x_i-\mu}{\beta} + e^{-\frac{x_i-\mu}{\beta}}\right).$$

Esta función es multimodal y no tiene solución analítica cerrada. Los algoritmos genéticos han demostrado ser efectivos para encontrar el MLE en este contexto [6].

11.5 Convergencia y Conexión con Cambio de Medida

Teorema 11.9 (Convergencia del AG hacia el MLE)**.** *Bajo condiciones de regularidad (compacidad de Θ, continuidad de la verosimilitud, y operadores genéticos que garantizan exploración ergódica), la población del algoritmo genético converge en distribución hacia una medida concentrada en los puntos de máxima verosimilitud.*

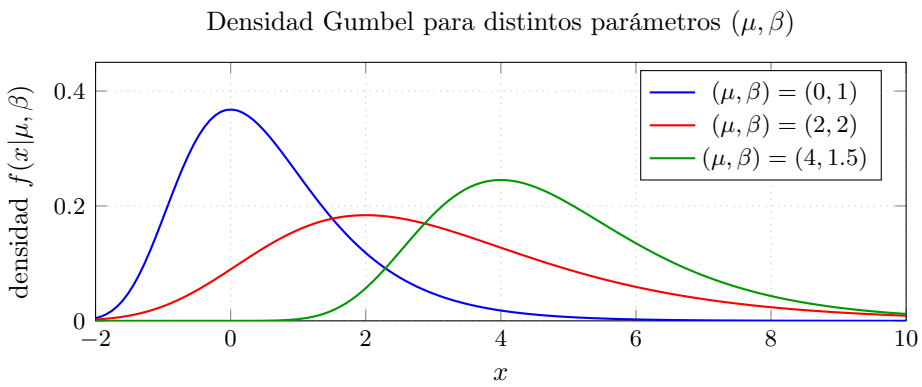

Figura 13: La distribución Gumbel presenta asimetría positiva (cola derecha larga). La variación de μ desplaza la moda y β controla la dispersión.

Idea. La selección proporcional al fitness realiza un *reweighting* de la población: después de selección, la distribución empírica de los individuos es

$$Q_N(\theta) = \frac{\sum_{i=1}^{N} \delta_{\theta_i}(\theta) e^{\ell(\theta_i)}}{\sum_{j=1}^{N} e^{\ell(\theta_j)}}.$$

Esto es análogo a un cambio de medida de la distribución uniforme (o inicial) hacia una medida con densidad proporcional a $e^{\ell(\theta)}$. Bajo condiciones de ergodicidad, esta medida se concentra asintóticamente en los maximizadores de $\ell(\theta)$ [7]. □

Observación 11.10 (Conexión con muestreo por importancia). La expresión anterior es precisamente un estimador de muestreo por importancia (importance sampling) donde la distribución objetivo tiene densidad $\pi(\theta) \propto e^{\ell(\theta)}$, que es la distribución posterior en un contexto bayesiano con prior uniforme. El algoritmo genético puede verse como un método secuencial de muestreo por importancia con rejuvenecimiento de la población mediante cruce y mutación.

11.6 Ejemplo Computacional

Ejemplo 11.11 (Estimación MLE para la distribución Gumbel)**.** Retomamos el Ejemplo 11.8. Supongamos que generamos $n = 100$ observaciones de una Gumbel con $\mu = 10$, $\beta = 2$. Implementamos un algoritmo genético con:

- Población: $N = 50$ individuos (μ, β).
- Rango de búsqueda: $\mu \in [5, 15]$, $\beta \in [0.5, 5]$.
- Fitness: $\ell(\mu, \beta)$ (log-verosimilitud).
- Selección: torneo de tamaño 3.
- Cruce: uniforme con probabilidad 0.8.
- Mutación: gaussiana con $\sigma_{\text{mut}} = 0.1$ en cada coordenada.
- Reemplazo: generacional con elitismo (se conserva el mejor).

Tras 100 generaciones, el AG converge a valores cercanos a los verdaderos. Este enfoque supera a los métodos basados en gradiente cuando la función es multimodal o cuando el punto de partida está lejos del óptimo [6].

11.7 Ejemplo adicional: Muestreo por Importancia

Ejemplo 11.12 (Estimación de una probabilidad de cola via muestreo por importancia)**.** Queremos estimar $p = P(X > 3)$ donde $X \sim \mathcal{N}(0,1)$. El valor exacto es $p \approx 0.00135$.

El estimador de Monte Carlo con P es ineficiente porque raramente cae en la cola. Usamos en cambio $Q = \mathcal{N}(3,1)$ como distribución propuesta. Por el Teorema 10.1 con $g(x) = \mathbf{1}_{\{x>3\}}$:

$$p = \mathbb{E}_P[\mathbf{1}_{\{X>3\}}] = \mathbb{E}_Q\left[\mathbf{1}_{\{X>3\}} \cdot \frac{dP}{dQ}(X)\right], \qquad \frac{dP}{dQ}(x) = e^{-3x+9/2}.$$

Bajo Q, la región $\{x > 3\}$ es mucho más frecuente, reduciendo la varianza del estimador por un factor de ≈ 400.

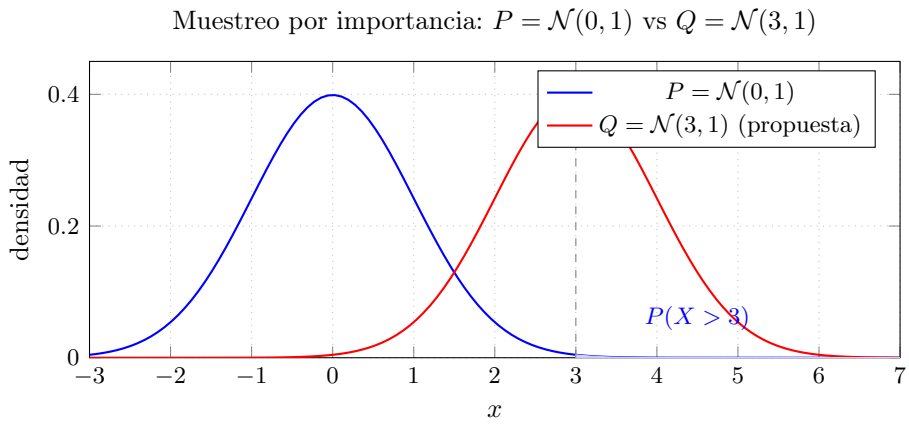

Figura 14: Bajo P, la región $\{x > 3\}$ (sombreada) tiene probabilidad ≈ 0.00135, muy difícil de estimar por Monte Carlo directo. Al proponer Q centrada en 3, la región se vuelve mucho más frecuente.

12 Referencias

Referencias

[1] G. Folland, *Real Analysis: Modern Techniques and Their Applications*, 2ª ed., Wiley (1999).

[2] V. I. Bogachev, *Measure Theory*, Vol. I, Springer (2007).

[3] O. Kallenberg, *Foundations of Modern Probability*, 2ª ed., Springer (2002).

[4] R. Durrett, *Probability: Theory and Examples*, 5ª ed., Cambridge (2019).

[5] D. Williams, *Probability with Martingales*, Cambridge (1991).

[6] Fuentes-Moriles, R., Castañón-Puga, M., Castro, J.R., Rodríguez-Díaz, A. (2015). Maximización de la función de Verosimilitud de Distribuciones de Probabilidad usando Algoritmos Genéticos. *Revista de Matemática: Teoría y Aplicaciones*, 22(2), 351-364.

[7] Celeux, G., Diday, E., Govaert, G., Lechevallier, Y., Ralambondrainy, H. (1985). *Analyse des données: Algorithmes d'échange et de recuit simulé.* INRIA.

[8] Bäck, T. (1996). *Evolutionary Algorithms in Theory and Practice.* Oxford University Press.

[9] Serafini, P. (1994). Simulated annealing versus genetic algorithms: a mathematical comparison. *Proceedings of the IFIP TC7/WG7.2 Working Conference.*

[10] Ash, R. B. (1972). *Real Analysis and Probability.* Academic Press.

[11] Chung, K. L. (2001). *A Course in Probability Theory*, 3ª ed. Academic Press.

[12] Shiryaev, A. N. (1996). *Probability*, 2ª ed. Springer.

[13] Revuz, D., Yor, M. (1999). *Continuous Martingales and Brownian Motion*, 3ª ed. Springer.

[14] Karatzas, I., Shreve, S. E. (1991). *Brownian Motion and Stochastic Calculus*, 2ª ed. Springer.

[15] Protter, P. E. (2005). *Stochastic Integration and Differential Equations*, 2ª ed. Springer.

[16] Øksendal, B. (2003). *Stochastic Differential Equations*, 6ª ed. Springer.

[17] Billingsley, P. (1995). *Probability and Measure*, 3ª ed. Wiley.

[18] Doob, J. L. (1990). *Stochastic Processes.* Wiley.

[19] Meyer, P. A. (1966). *Probability and Potentials.* Blaisdell.