EL TEOREMA CENTRAL DEL LÍMITE

la Ley Fuerte de los Grandes Números, teoremas de Lindeberg-Feller, Lyapunov y caracterización de Lévy

Julio César Galindo López

Facultad de Ciencias
27 de mayo de 2020

Resumen

El Teorema Central del Límite constituye el resultado más importante de la teoría de la probabilidad. En estas notas presentamos una demostración completa y rigurosa, siguiendo el método de funciones características y el teorema de continuidad de Lévy-Cramér. Desarrollamos en detalle la Ley Fuerte de los Grandes Números, incluyendo la demostración completa del teorema de Kolmogorov y extensiones a sucesiones dependientes siguiendo a Billingsley. Establecemos los preliminares necesarios sobre espacios de probabilidad, modos de convergencia y funciones características. Extendemos luego el análisis a los teoremas de Lindeberg-Feller y Lyapunov, que generalizan el TCL a sucesiones de variables independientes no necesariamente idénticamente distribuidas (arrays triangulares). Se presentan demostraciones completas de ambos teoremas, incluyendo la necesidad de la condición de Lindeberg. Finalmente, desarrollamos en detalle la caracterización de Lévy de las funciones características y su relación con la convergencia en distribución.

1. Prólogo

El Teorema Central del Límite (TCL) constituye, sin exageración alguna, el resultado más importante de la teoría de la probabilidad. Su descubrimiento se remonta a los trabajos de De Moivre en 1733, quien demostró el teorema para el caso particular de lanzamientos de una moneda (distribución binomial). Posteriormente, Laplace, entre 1776 y 1812, generalizó el resultado a sumas de variables aleatorias con distribuciones arbitrarias, introduciendo además el poderoso método de las funciones características. El nombre "Teorema Central del Límite" fue acuñado por Pólya en la década de 1920, enfatizando su papel central en la teoría y sus aplicaciones [4].

La demostración que presentamos en estas notas sigue el enfoque clásico de las funciones características, consagrado por la escuela francesa de probabilidad —Lévy, Cramér— y magistralmente expuesto en textos como el de Billingsley [1]. Este método, que no es otro que el uso de la transformada de Fourier en el contexto de la teoría de la medida, posee una elegancia inigualable: transforma un problema de convergencia de medidas de probabilidad en un problema de convergencia puntual de funciones complejas, reduciendo drásticamente la complejidad analítica.

Antes de abordar el TCL, es necesario establecer un resultado fundamental que nos habla del comportamiento casi seguro de las sumas: la Ley Fuerte de los Grandes Números. Su

demostración, que requiere un análisis más fino que el de la ley débil, constituye una pieza maestra del razonamiento probabilístico.

2. Preliminares: espacios de probabilidad, modos de convergencia y funciones características

2.1. Espacios de probabilidad

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Recordemos que $\mathcal{F}$ es una σ-álgebra de subconjuntos de Ω y $\mathbb{P} : \mathcal{F} \to [0,1]$ es una medida de probabilidad, esto es, $\mathbb{P}(\Omega) = 1$ y $\mathbb{P}$ es σ-aditiva [2].

Una **variable aleatoria** (v.a.) es una función $X : \Omega \to \mathbb{R}$ tal que para todo $B \in \mathcal{B}(\mathbb{R})$ (con $\mathcal{B}(\mathbb{R})$ la σ-álgebra de Borel), se tiene $X^{-1}(B) \in \mathcal{F}$. La **distribución** (o ley) de X es la medida imagen $\mathbb{P}_X$ definida por $\mathbb{P}_X(B) = \mathbb{P}(X \in B)$.

La **función de distribución** asociada a X es $F_X(x) = \mathbb{P}(X \leq x)$, para $x \in \mathbb{R}$. Recordemos que F_X es monótona no decreciente, continua por la derecha y satisface

$$\lim_{x \to -\infty} F_X(x) = 0, \qquad \lim_{x \to \infty} F_X(x) = 1.$$

2.2. Modos de convergencia

Sean $\{X_n\}_{n \geq 1}$ y X variables aleatorias definidas sobre $(\Omega, \mathcal{F}, \mathbb{P})$.

Definición 2.1 (Convergencia en probabilidad)**.** Decimos que $X_n \to X$ **en probabilidad** (notación: $X_n \xrightarrow{\mathbb{P}} X$) si para todo $\varepsilon > 0$,

$$\lim_{n \to \infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0.$$

Definición 2.2 (Convergencia en distribución)**.** Decimos que $X_n \to X$ **en distribución** o **débilmente** (notación: $X_n \xrightarrow{\mathcal{D}} X$) si para todo punto x donde F_X es continua,

$$\lim_{n \to \infty} F_{X_n}(x) = F_X(x).$$

La convergencia en distribución también se denota como $X_n \Rightarrow X$ o $X_n \xrightarrow{w} X$.

Definición 2.3 (Convergencia casi segura)**.** Decimos que $X_n \to X$ **casi seguramente** (notación: $X_n \xrightarrow{c.s.} X$) si

$$\mathbb{P}\left(\left\{\omega \in \Omega : \lim_{n \to \infty} X_n(\omega) = X(\omega)\right\}\right) = 1.$$

La relación entre estos modos de convergencia está dada por las siguientes implicaciones:

$$\text{c.s.} \implies \mathbb{P} \implies \mathcal{D},$$

pero los recíprocos no son ciertos en general.

Proposición 2.4. $X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{\mathcal{D}} X$.

Demostración. Sea f una función continua y acotada sobre $\mathbb{R}$. Entonces $f(X_n) \xrightarrow{\mathbb{P}} f(X)$ (teorema de la aplicación continua para convergencia en probabilidad). Como f es acotada, el teorema de convergencia dominada (TCD) implica $\mathbb{E}[f(X_n)] \to \mathbb{E}[f(X)]$. Por el teorema de representación de la convergencia débil mediante funciones continuas y acotadas, esto es equivalente a $X_n \xrightarrow{\mathcal{D}} X$. □

Proposición 2.5. *Si $X \equiv c$ (constante casi seguramente), entonces*

$$X_n \xrightarrow{\mathcal{D}} X \implies X_n \xrightarrow{\mathbb{P}} X.$$

Demostración. Considérese la función $g(x) = \frac{|x-c|}{1+|x-c|}$, que es continua y acotada. Si $X_n \xrightarrow{\mathcal{D}} c$, entonces $\mathbb{E}[g(X_n)] \to \mathbb{E}[g(c)] = 0$. Pero $\mathbb{E}[g(X_n)] \to 0$ implica que $g(X_n) \xrightarrow{\mathbb{P}} 0$ (por la desigualdad de Markov), y como $g(x) \geq \frac{|x-c|}{1+|x-c|} \geq \frac{1}{2}\operatorname{mín}(1, |x-c|)$, esto implica $X_n \xrightarrow{\mathbb{P}} c$. □

2.3. Funciones características

Definición 2.6 (Función característica)**.** La **función característica** de una variable aleatoria X es la función $\varphi_X : \mathbb{R} \to \mathbb{C}$ definida por

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \mathbb{E}[\cos(tX)] + i\mathbb{E}[\sin(tX)], \quad t \in \mathbb{R}.$$

La función característica es, esencialmente, la transformada de Fourier de la distribución de X [3]. Sus propiedades fundamentales son:

(I) $\varphi_X(0) = 1$, $|\varphi_X(t)| \leq 1$ para todo t.

(II) φ_X es uniformemente continua sobre $\mathbb{R}$.

(III) Si X e Y son independientes, $\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t)$.

(IV) (Teorema de inversión de Fourier) La función característica determina unívocamente la distribución. Es decir, si $\varphi_X = \varphi_Y$, entonces X e Y tienen la misma distribución.

(V) Si $\mathbb{E}[|X|^k] < \infty$, entonces φ_X es k veces diferenciable y $\varphi_X^{(k)}(0) = i^k\mathbb{E}[X^k]$.

Ejemplo 2.7 (Normal estándar)**.** *Si $Z \sim \mathcal{N}(0,1)$, entonces $\varphi_Z(t) = e^{-t^2/2}$ [6].*

Demostración.

$$\varphi_Z(t) = \int_{-\infty}^{\infty} e^{itx} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx.$$

Derivando bajo el signo integral,

$$\varphi_Z'(t) = \int_{-\infty}^{\infty} ixe^{itx} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = -\int_{-\infty}^{\infty} e^{itx} \frac{1}{\sqrt{2\pi}} d(e^{-x^2/2}) = -t\varphi_Z(t).$$

La ecuación diferencial $\varphi_Z'(t) = -t\varphi_Z(t)$ con condición inicial $\varphi_Z(0) = 1$ tiene solución única $\varphi_Z(t) = e^{-t^2/2}$. □

3. La Ley Fuerte de los Grandes Números

La Ley Fuerte de los Grandes Números (LFGN) es uno de los resultados capitales de la teoría de la probabilidad. Establece que el promedio de una sucesión de variables aleatorias independientes e idénticamente distribuidas converge casi seguramente a la esperanza común. A diferencia de la ley débil, que solo garantiza convergencia en probabilidad, la ley fuerte proporciona convergencia para casi toda trayectoria.

3.1. Enunciado del teorema

Teorema 3.1 (Ley Fuerte de los Grandes Números de Kolmogorov)**.** *Sea $\{X_n\}_{n\geq 1}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas definidas sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$. Supóngase que $\mathbb{E}[|X_1|] < \infty$ y sea $\mu = \mathbb{E}[X_1]$. Definamos*

$$S_n = \sum_{k=1}^{n} X_k.$$

Entonces,

$$\frac{S_n}{n} \xrightarrow{n\to\infty} \mu \quad \textit{casi seguramente.}$$

La demostración que presentamos sigue el enfoque clásico de Kolmogorov, basado en desigualdades maximales y el lema de Borel-Cantelli.

3.2. Lemas preliminares

Lema 3.2 (Desigualdad maximal de Kolmogorov)**.** *Sea $\{Y_k\}_{k=1}^n$ una sucesión de variables aleatorias independientes con $\mathbb{E}[Y_k] = 0$ y $\mathbb{E}[Y_k^2] = \sigma_k^2 < \infty$ para cada k. Definamos $T_k = \sum_{j=1}^k Y_j$ y $s_n^2 = \sum_{k=1}^n \sigma_k^2$. Entonces, para todo $\varepsilon > 0$,*

$$\mathbb{P}\left(\max_{1\leq k\leq n} |T_k| \geq \varepsilon\right) \leq \frac{s_n^2}{\varepsilon^2}.$$

Demostración. Definamos los eventos

$$A_k = \{|T_1| < \varepsilon, \ldots, |T_{k-1}| < \varepsilon, |T_k| \geq \varepsilon\}, \quad 1 \leq k \leq n.$$

Estos eventos son disjuntos y su unión es $\{\max_{1\leq k\leq n} |T_k| \geq \varepsilon\}$. Observemos que en A_k, tenemos $|T_k| \geq \varepsilon$ y $|T_{k-1}| < \varepsilon$ (con $T_0 = 0$).

Ahora,

$$\mathbb{E}[T_n^2] \geq \sum_{k=1}^{n} \mathbb{E}[T_n^2 \mathbf{1}_{A_k}] \geq \sum_{k=1}^{n} \mathbb{E}[T_k^2 \mathbf{1}_{A_k}] + \sum_{k=1}^{n} \mathbb{E}[(T_n - T_k)^2 \mathbf{1}_{A_k}] + 2\sum_{k=1}^{n} \mathbb{E}[(T_n - T_k)T_k \mathbf{1}_{A_k}].$$

Pero $\mathbb{E}[(T_n - T_k)T_k \mathbf{1}_{A_k}] = 0$, pues $T_n - T_k$ es independiente de $\mathcal{F}_k$ (la σ-álgebra generada por $Y_1, \ldots, Y_k$) y tiene media cero. Además, $(T_n - T_k)^2 \geq 0$, luego

$$\mathbb{E}[T_n^2] \geq \sum_{k=1}^{n} \mathbb{E}[T_k^2 \mathbf{1}_{A_k}] \geq \varepsilon^2 \sum_{k=1}^{n} \mathbb{P}(A_k) = \varepsilon^2 \mathbb{P}\left(\max_{1\leq k\leq n} |T_k| \geq \varepsilon\right).$$

Pero $\mathbb{E}[T_n^2] = s_n^2$. Despejando, obtenemos la desigualdad deseada. □

Lema 3.3 (Lema de Kronecker)**.** *Sean $\{a_n\}_{n\geq 1}$ una sucesión de números reales con $a_n \uparrow \infty$ y $\{x_n\}_{n\geq 1}$ una sucesión de números reales tales que $\sum_{n=1}^{\infty} \frac{x_n}{a_n}$ converge. Entonces,*

$$\lim_{n\to\infty} \frac{1}{a_n} \sum_{k=1}^{n} x_k = 0.$$

Demostración. Sea $R_n = \sum_{k=n}^{\infty} \frac{x_k}{a_k}$. Entonces $R_n \to 0$ y $x_n = a_n(R_n - R_{n+1})$. Por tanto,

$$\sum_{k=1}^{n} x_k = \sum_{k=1}^{n} a_k(R_k - R_{k+1}) = \sum_{k=1}^{n} a_k R_k - \sum_{k=2}^{n+1} a_{k-1} R_k.$$

Reordenando,

$$\sum_{k=1}^{n} x_k = a_1 R_1 + \sum_{k=2}^{n} (a_k - a_{k-1}) R_k - a_n R_{n+1}.$$

Dividiendo por a_n,

$$\frac{1}{a_n} \sum_{k=1}^{n} x_k = \frac{a_1 R_1}{a_n} + \frac{1}{a_n} \sum_{k=2}^{n} (a_k - a_{k-1}) R_k - R_{n+1}.$$

El primer término tiende a 0 pues $a_n \to \infty$. El último término tiende a 0 pues $R_{n+1} \to 0$. Para el término central, notamos que es un promedio ponderado de los R_k con pesos positivos $(a_k - a_{k-1})$ que suman $a_n - a_1$. Como $R_k \to 0$, este promedio también tiende a 0. □

3.3. Demostración de la LFGN

La demostración se divide en varias etapas. Primero probamos el teorema para variables con varianza finita, luego extendemos al caso general mediante truncamiento.

Demostración del Teorema 2.1. **Paso 1: Reducción al caso centrado.** Podemos suponer sin pérdida de generalidad que $\mu = 0$. En efecto, si definimos $Y_n = X_n - \mu$, entonces $\mathbb{E}[Y_n] = 0$ y la convergencia de S_n/n a μ equivale a la convergencia de $(\sum_{k=1}^{n} Y_k)/n$ a 0.

Paso 2: Truncamiento. Definamos las variables truncadas:

$$X_n' = X_n \mathbf{1}_{\{|X_n| \leq n\}}, \quad X_n'' = X_n \mathbf{1}_{\{|X_n| > n\}}.$$

Entonces $X_n = X_n' + X_n''$. Sea $S_n' = \sum_{k=1}^{n} X_k'$ y $S_n'' = \sum_{k=1}^{n} X_k''$.

Paso 3: Manejo de la cola. Observemos que

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > n) = \sum_{n=1}^{\infty} \mathbb{P}(|X_1| > n) \leq \mathbb{E}[|X_1|] < \infty,$$

pues para una variable no negativa Y, $\sum_{n=1}^{\infty} \mathbb{P}(Y > n) \leq \mathbb{E}[Y]$. Por el lema de Borel-Cantelli, con probabilidad 1, solo un número finito de los eventos $\{|X_n| > n\}$ ocurren. Por tanto, $X_n'' = 0$ para todo n suficientemente grande casi seguramente, y en consecuencia

$$\frac{S_n''}{n} \xrightarrow{n\to\infty} 0 \quad \text{c.s.}$$

Paso 4: Centrado de las variables truncadas. Definamos $\mu_n = \mathbb{E}[X'_n]$. Notemos que

$$|\mu_n| = |\mathbb{E}[X_1 \mathbf{1}_{\{|X_1| \le n\}}]| \le \mathbb{E}[|X_1| \mathbf{1}_{\{|X_1| > n\}}] \to 0.$$

Además,

$$\sum_{n=1}^{\infty} \frac{|\mu_n|}{n} \le \sum_{n=1}^{\infty} \frac{1}{n} \mathbb{E}[|X_1| \mathbf{1}_{\{|X_1| > n\}}] = \mathbb{E}\left[|X_1| \sum_{n=1}^{\infty} \frac{1}{n} \mathbf{1}_{\{n < |X_1|\}} \right].$$

Para $|X_1| > 1$, la serie interna está acotada por $1 + \log |X_1|$ (aproximadamente). Como $\mathbb{E}[|X_1|] < \infty$, el lado derecho es finito por el teorema de convergencia monótona. Por tanto, $\sum_{n=1}^{\infty} \frac{|\mu_n|}{n} < \infty$.

Paso 5: Aplicación de la desigualdad maximal a $Y_n = X'_n - \mu_n$. Las variables Y_n son independientes, centradas y acotadas: $|Y_n| \le 2n$. Además,

$$\sum_{n=1}^{\infty} \frac{\mathrm{Var}(Y_n)}{n^2} \le \sum_{n=1}^{\infty} \frac{\mathbb{E}[(X'_n)^2]}{n^2} = \sum_{n=1}^{\infty} \frac{1}{n^2} \mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \le n\}}].$$

Intercambiando suma y esperanza,

$$\sum_{n=1}^{\infty} \frac{\mathrm{Var}(Y_n)}{n^2} = \mathbb{E}\left[X_1^2 \sum_{n : n \ge |X_1|} \frac{1}{n^2} \right] \le \mathbb{E}\left[X_1^2 \cdot \frac{2}{|X_1|} \right] = 2\mathbb{E}[|X_1|] < \infty,$$

donde hemos usado que $\sum_{n \ge m} 1/n^2 \le 2/m$.

Paso 6: Convergencia de la serie de las Y_n/n. Sea $T_n = \sum_{k=1}^{n} \frac{Y_k}{k}$. Por la desigualdad maximal de Kolmogorov,

$$\mathbb{P}\left(\max_{1 \le k \le n} |T_{m+k} - T_m| \ge \varepsilon \right) \le \frac{1}{\varepsilon^2} \sum_{j=m+1}^{m+n} \frac{\mathrm{Var}(Y_j)}{j^2}.$$

Haciendo tender $n \to \infty$ y luego $m \to \infty$, el lado derecho tiende a 0. Esto implica que $\{T_n\}$ es una sucesión de Cauchy en probabilidad, y por tanto converge en probabilidad a algún límite. Pero como las sumas parciales de las varianzas convergen, un argumento estándar (usando la desigualdad de Kolmogorov y el lema de Borel-Cantelli) muestra que la convergencia es también casi segura. Por tanto,

$$\sum_{n=1}^{\infty} \frac{Y_n}{n} \quad \text{converge casi seguramente.}$$

Paso 7: Aplicación del lema de Kronecker. Tomando $a_n = n$ y $x_n = Y_n$ en el lema de Kronecker, obtenemos

$$\frac{1}{n} \sum_{k=1}^{n} Y_k \xrightarrow{n \to \infty} 0 \quad \text{c.s.}$$

Paso 8: Conclusión. Recordemos que $Y_k = X'_k - \mu_k$ y $X_k = X'_k + X''_k$. Por tanto,

$$\frac{S_n}{n} = \frac{1}{n} \sum_{k=1}^{n} X_k = \frac{1}{n} \sum_{k=1}^{n} Y_k + \frac{1}{n} \sum_{k=1}^{n} \mu_k + \frac{1}{n} \sum_{k=1}^{n} X''_k.$$

El primer término tiende a 0 c.s. por el Paso 7. El segundo término tiende a 0 porque $\mu_k \to 0$ implica que el promedio de Cesàro también tiende a 0. El tercer término tiende a 0 c.s. por el Paso 3. En consecuencia,

$$\frac{S_n}{n} \xrightarrow{n\to\infty} 0 \quad \text{c.s.},$$

que es lo que queríamos demostrar (recordando que hemos supuesto $\mu = 0$). □

3.4. Extensiones a sucesiones dependientes: el enfoque de Billingsley

La independencia es una hipótesis fuerte. Billingsley, en su tratamiento de la teoría de la probabilidad, muestra cómo la LFGN puede extenderse a sucesiones que satisfacen ciertas condiciones de dependencia débil [1]. La idea fundamental es reemplazar la condición de independencia por condiciones sobre las covarianzas o sobre las esperanzas condicionales.

Teorema 3.4 (Ley Fuerte para sucesiones con correlación débil)**.** *Sea $\{X_n\}_{n\geq 1}$ una sucesión de variables aleatorias centradas y uniformemente acotadas (i.e., $|X_n| \leq M$ c.s. para todo n). Supongamos que*

$$\sum_{n=1}^{\infty} \frac{\mathbb{E}[|S_n|^2]}{n^2} < \infty,$$

donde $S_n = \sum_{k=1}^{n} X_k$. Entonces,

$$\frac{S_n}{n} \xrightarrow{n\to\infty} 0 \quad \textit{c.s.}$$

Demostración. La demostración utiliza la desigualdad de Chebyshev y el lema de Borel-Cantelli. Para cada n, consideramos los puntos n^2. Por la desigualdad de Chebyshev,

$$\mathbb{P}\left(\frac{|S_{n^2}|}{n^2} > \varepsilon\right) \leq \frac{\mathbb{E}[|S_{n^2}|^2]}{\varepsilon^2 n^4}.$$

Por hipótesis, $\sum_n \mathbb{E}[|S_{n^2}|^2]/n^4 < \infty$ (pues la serie original converge y los términos son positivos). Por Borel-Cantelli, $\frac{S_{n^2}}{n^2} \to 0$ c.s.

Para los índices entre n^2 y $(n+1)^2$, usamos la acotación uniforme para controlar las diferencias. Para $n^2 \leq k < (n+1)^2$,

$$\left|\frac{S_k}{k}\right| \leq \left|\frac{S_{n^2}}{n^2}\right| + \frac{1}{n^2}\sum_{j=n^2+1}^{k} |X_j| \leq \left|\frac{S_{n^2}}{n^2}\right| + \frac{2nM}{n^2} = \left|\frac{S_{n^2}}{n^2}\right| + \frac{2M}{n}.$$

Ambos términos tienden a 0 c.s., lo que completa la demostración. □

Observación 3.5. La condición $\sum_n \mathbb{E}[|S_n|^2]/n^2 < \infty$ es una condición de dependencia débil que puede verificarse en muchos casos. Por ejemplo, si las covarianzas decaen suficientemente rápido, como en el caso de sucesiones estacionarias con función de covarianza sumable, entonces

$$\frac{\mathbb{E}[|S_n|^2]}{n^2} = \frac{1}{n^2}\sum_{i,j=1}^{n} \operatorname{Cov}(X_i, X_j) \leq \frac{1}{n^2}\sum_{i,j=1}^{n} |\operatorname{Cov}(X_i, X_j)| = O\left(\frac{1}{n}\right),$$

y la serie converge.

Billingsley también presenta versiones de la ley fuerte para martingalas y para sucesiones estacionarias ergódicas, que constituyen las generalizaciones más naturales de la independencia [1, 8].

4. El Teorema de Continuidad de Lévy y la caracterización de Lévy

El puente que conecta la convergencia en distribución con las funciones características es el célebre teorema de continuidad de Lévy-Cramér. Este resultado es la pieza angular para demostrar rigurosamente el TCL.

4.1. El teorema de continuidad de Lévy-Cramér

Teorema 4.1 (Teorema de continuidad de Lévy-Cramér)**.** *Sea $\{F_n\}_{n\geq 1}$ una sucesión de funciones de distribución, y sea φ_n la función característica correspondiente.*

(1) Si F_n converge débilmente a F, entonces $\varphi_n(t) \to \varphi(t)$ para todo $t \in \mathbb{R}$, donde φ es la función característica de F.

(2) Recíprocamente, supóngase que:

(L1) $\varphi_n(t)$ converge a una función $f(t)$ para todo $t \in \mathbb{R}$.

(L2) f es continua en 0.

Entonces, existe una función de distribución F sobre $\mathbb{R}$ tal que:

(I) $f = \varphi$, la función característica de F.

(II) $F_n \xrightarrow{\mathcal{D}} F$.

La demostración de este teorema requiere dos herramientas fundamentales: el concepto de **tensión** (tightness) de una sucesión de medidas y el **principio de selección de Helly**.

4.2. Tensión de una sucesión de medidas

Definición 4.2 (Tensión)**.** Una sucesión $\{\mu_n\}_{n\geq 1}$ de medidas de probabilidad sobre $\mathbb{R}$ se dice **tensa** si para todo $\varepsilon > 0$ existe un compacto $K \subset \mathbb{R}$ tal que

$$\sup_n \mu_n(K^c) < \varepsilon.$$

Equivalentemente,

$$\lim_{m\to\infty} \sup_n \mu_n([-m, m]^c) = 0.$$

La tensión es la condición que previene la "fuga de masa hacia el infinito". Es la noción probabilística de compacidad relativa.

4.3. El principio de selección de Helly

Teorema 4.3 (Principio de selección de Helly)**.** *Sea $\{F_n\}_{n\geq 1}$ una sucesión de funciones de distribución sobre $\mathbb{R}$. Si la sucesión es tensa, entonces existe una subsucesión $\{F_{n_k}\}_{k\geq 1}$ que converge débilmente a una función de distribución F [7].*

Demostración. La demostración procede mediante el clásico método diagonal de Cantor.

Sea $\{r_1, r_2, \ldots\}$ una enumeración de los números racionales. Para cada r_j, la sucesión $\{F_n(r_j)\}_{n\geq 1}$ está acotada en $[0,1]$, luego por Bolzano-Weierstrass posee una subsucesión convergente.

Construimos subsucesiones anidadas:

- Para r_1, existe $\{n_{1,k}\}_{k\geq 1}$ tal que $F_{n_{1,k}}(r_1)$ converge. Definimos $G(r_1) = \lim_k F_{n_{1,k}}(r_1)$.
- Para r_2, extraemos de $\{n_{1,k}\}$ una subsucesión $\{n_{2,k}\}$ tal que $F_{n_{2,k}}(r_2)$ converge. Definimos $G(r_2) = \lim_k F_{n_{2,k}}(r_2)$.
- Continuamos inductivamente.

Finalmente, tomamos la subsucesión diagonal $n_k := n_{k,k}$. Por construcción, para cada racional r_j,

$$G(r_j) = \lim_{k\to\infty} F_{n_k}(r_j).$$

La función $G : \mathbb{Q} \to [0,1]$ así definida es no decreciente (por ser límite puntual de funciones no decrecientes).

Definimos ahora para todo $x \in \mathbb{R}$,

$$F(x) = \inf\{G(r) : r \in \mathbb{Q}, r > x\}.$$

F es no decreciente por construcción, y es continua por la derecha (el ínfimo sobre racionales garantiza que los límites por la derecha coinciden con el valor en el punto). Claramente $0 \leq F \leq 1$.

Resta probar que F es una función de distribución, i.e., que $\lim_{x\to-\infty} F(x) = 0$ y $\lim_{x\to\infty} F(x) = 1$. Esto se sigue de la hipótesis de tensión: dado $\varepsilon > 0$, existe m tal que $F_n(x) \leq \varepsilon$ para todo n si $x < -m$, y $F_n(x) \geq 1-\varepsilon$ para todo n si $x > m$. Tomando límite a través de la subsucesión, obtenemos las mismas cotas para G, y por tanto para F.

Finalmente, si x es un punto de continuidad de F, un argumento de aproximación con racionales muestra que $F_{n_k}(x) \to F(x)$. Esto completa la demostración de que $F_{n_k} \xrightarrow{\mathcal{D}} F$. $\square$

4.4. Demostración del Teorema de Continuidad de Lévy

Demostración del Teorema 4.1. **Parte 1.** Si $F_n \xrightarrow{\mathcal{D}} F$, entonces para cada t fijo, la función $x \mapsto e^{itx}$ es continua y acotada. Por el teorema de representación de la convergencia débil, $\mathbb{E}_{F_n}[e^{itX}] \to \mathbb{E}_F[e^{itX}]$, i.e., $\varphi_n(t) \to \varphi(t)$.

Parte 2. La demostración de la parte recíproca se estructura en tres lemas.

Lema 4.4. *Bajo las hipótesis L1 y L2, la sucesión $\{F_n\}$ es tensa.*

Demostración. Utilizamos una identidad integral debida a Lévy. Por el teorema de Fubini,

$$\int_{-\alpha}^{\alpha} \varphi_n(t)dt = \int_{-\alpha}^{\alpha} \left(\int_{\mathbb{R}} e^{itx} dF_n(x) \right) dt = \int_{\mathbb{R}} \left(\int_{-\alpha}^{\alpha} e^{itx} dt \right) dF_n(x).$$

Pero $\int_{-\alpha}^{\alpha} e^{itx} dt = \frac{2\sin(\alpha x)}{x}$. Por tanto,

$$\frac{1}{\alpha} \int_{-\alpha}^{\alpha} (1 - \varphi_n(t))dt = 2 - \int_{\mathbb{R}} \frac{2\sin(\alpha x)}{\alpha x} dF_n(x) = 2 \int_{\mathbb{R}} \left(1 - \frac{\sin(\alpha x)}{\alpha x} \right) dF_n(x).$$

Observamos que $1 - \frac{\sin y}{y} \geq 0$ para todo y, y además, para $|y| \geq 2$, se tiene $1 - \frac{\sin y}{y} \geq \frac{1}{2}$ (verificación directa). Tomando $y = \alpha x$,

$$\frac{1}{\alpha} \int_{-\alpha}^{\alpha} (1 - \varphi_n(t))dt \geq 2 \int_{|x| \geq 2/\alpha} \frac{1}{2} dF_n(x) = \mu_n([-2/\alpha, 2/\alpha]^c).$$

Sea $\beta = 2/\alpha$. Hemos obtenido la estimación fundamental:

$$\mu_n([-\beta, \beta]^c) \leq \frac{\beta}{2} \int_{-2/\beta}^{2/\beta} (1 - \varphi_n(t))dt. \tag{4.1}$$

Ahora, dado $\varepsilon > 0$. Por L2, f es continua en 0 y $f(0) = 1$ (pues $\varphi_n(0) = 1$ para todo n y L1 implica $f(0) = 1$). Existe $\delta > 0$ tal que $|t| \leq \delta$ implica $|1 - f(t)| \leq \varepsilon/4$.

Tomamos β suficientemente grande para que $2/\beta \leq \delta$, i.e., $\beta \geq 2/\delta$. Entonces,

$$\left| \frac{\beta}{2} \int_{-2/\beta}^{2/\beta} (1 - f(t))dt \right| \leq \frac{\beta}{2} \cdot \frac{4}{\beta} \cdot \frac{\varepsilon}{4} = \frac{\varepsilon}{2}.$$

Por L1 y el teorema de convergencia dominada (pues $|\varphi_n(t)| \leq 1$),

$$\lim_{n \to \infty} \int_{-2/\beta}^{2/\beta} (1 - \varphi_n(t))dt = \int_{-2/\beta}^{2/\beta} (1 - f(t))dt.$$

Por tanto, existe N tal que para todo $n \geq N$,

$$\left| \int_{-2/\beta}^{2/\beta} (1 - \varphi_n(t))dt - \int_{-2/\beta}^{2/\beta} (1 - f(t))dt \right| < \frac{\varepsilon}{\beta}.$$

Combinando con la estimación anterior,

$$\frac{\beta}{2} \int_{-2/\beta}^{2/\beta} (1 - \varphi_n(t))dt \leq \frac{\beta}{2} \left(\int_{-2/\beta}^{2/\beta} (1 - f(t))dt + \frac{\varepsilon}{\beta} \right) \leq \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon.$$

Aplicando (4.1), obtenemos $\mu_n([-\beta, \beta]^c) \leq \varepsilon$ para todo $n \geq N$.

Para los finitos índices $n < N$, elegimos β_n tal que $\mu_n([-\beta_n, \beta_n]^c) \leq \varepsilon$, y tomamos $\beta_0 = \text{máx}(\beta, \beta_1, \ldots, \beta_{N-1})$. Entonces $\sup_n \mu_n([-\beta_0, \beta_0]^c) \leq \varepsilon$. Esto prueba la tensión. □

Lema 4.5. *Por el principio de selección de Helly (Teorema 4.3), la tensión implica que existe una subsucesión $\{F_{n_k}\}_{k \geq 1}$ que converge débilmente a alguna función de distribución F.*

Lema 4.6. *Para la subsucesión convergente, por la parte 1 del teorema, $\varphi_{n_k}(t) \to \varphi_F(t)$, donde φ_F es la función característica de F. Por tanto, $f(t) = \varphi_F(t)$ para todo t. En particular, f es la función característica de F.*

Finalmente, para completar la demostración, supongamos que F_n **no** converge débilmente a F. Entonces existe un punto de continuidad x de F y una subsucesión $\{F_{n_j}\}$ tal que $|F_{n_j}(x) - F(x)| \geq \delta > 0$ para todo j. Esta subsucesión es también tensa (la tensión es hereditaria), luego por Helly posee una subsubsucesión $\{F_{n_{j_k}}\}$ que converge débilmente a alguna G. Por el argumento anterior, $\varphi_{n_{j_k}} \to \varphi_G$, y como el límite puntual es f, tenemos $\varphi_G = f = \varphi_F$. Por el teorema de unicidad de la función característica, $G = F$. Pero entonces $F_{n_{j_k}}(x) \to F(x)$, contradiciendo $|F_{n_{j_k}}(x) - F(x)| \geq \delta$. La contradicción prueba que $F_n \xrightarrow{\mathcal{D}} F$. □

4.5. Caracterización de Lévy de las funciones características

Un problema fundamental en teoría de la probabilidad es determinar qué funciones pueden ser funciones características. Lévy proporcionó una caracterización completa en términos de continuidad y definición positiva.

Definición 4.7 (Función definida positiva)**.** Una función $\varphi : \mathbb{R} \to \mathbb{C}$ se dice **definida positiva** si para cualquier $n \in \mathbb{N}$, cualesquiera $t_1, \ldots, t_n \in \mathbb{R}$ y cualesquiera $z_1, \ldots, z_n \in \mathbb{C}$, se tiene

$$\sum_{j=1}^{n} \sum_{k=1}^{n} \varphi(t_j - t_k) z_j \overline{z_k} \geq 0.$$

Observación 4.8. Esta condición es equivalente a que para todo n y todo $t_1, \ldots, t_n \in \mathbb{R}$, la matriz $(\varphi(t_j - t_k))_{j,k=1}^{n}$ es hermítica y semidefinida positiva.

Teorema 4.9 (Caracterización de Lévy)**.** *Una función $\varphi : \mathbb{R} \to \mathbb{C}$ es la función característica de alguna variable aleatoria (o, equivalentemente, de alguna medida de probabilidad sobre $\mathbb{R}$) si y solo si satisface las siguientes condiciones:*

(I) $\varphi(0) = 1$.

(II) *φ es continua en* 0.

(III) *φ es definida positiva.*

Demostración. La demostración requiere el teorema de extensión de Kolmogorov y el teorema de Bochner. Presentamos los pasos fundamentales.

(Necesidad). Supongamos que φ es la función característica de una variable aleatoria X, i.e., $\varphi(t) = \mathbb{E}[e^{itX}]$. Entonces:

- $\varphi(0) = \mathbb{E}[1] = 1$.
- Por el teorema de convergencia dominada, cuando $t \to 0$, $e^{itX} \to 1$ puntualmente y $|e^{itX}| \leq 1$, luego $\varphi(t) \to \varphi(0) = 1$, lo que demuestra la continuidad en 0 (de hecho, la continuidad uniforme).

- Para la propiedad de definida positiva, calculamos:

$$\sum_{j,k} \varphi(t_j - t_k) z_j \overline{z_k} = \sum_{j,k} \mathbb{E}[e^{i(t_j - t_k)X}] z_j \overline{z_k} = \mathbb{E}\left[\sum_{j,k} e^{it_jX} e^{-it_kX} z_j \overline{z_k}\right] = \mathbb{E}\left[\left|\sum_j z_j e^{it_jX}\right|^2\right] \geq 0.$$

(Suficiencia). Recíprocamente, supongamos que φ satisface las tres condiciones. La idea es construir una medida de probabilidad cuya función característica sea φ.

Para cada $n \in \mathbb{N}$ y cada $k = (k_1, \ldots, k_n) \in \mathbb{Z}^n$, definimos los rectángulos.[en] $\mathbb{R}^n$. Utilizando la propiedad de definida positiva, podemos definir una medida de probabilidad en $\mathbb{R}^n$ mediante:

$$\mu_n\left(\prod_{j=1}^n (a_j, b_j]\right) = \lim_{T\to\infty} \frac{1}{(2T)^n} \int_{-T}^{T} \cdots \int_{-T}^{T} \prod_{j=1}^n \frac{e^{-it_ja_j} - e^{-it_jb_j}}{it_j} \varphi(t_1 + \cdots + t_n) dt_1 \cdots dt_n.$$

Esta construcción (debida a Kolmogorov) produce una familia de medidas finito-dimensionales que son consistentes. Por el teorema de extensión de Kolmogorov, existe una medida de probabilidad μ en $\mathbb{R}^\infty$ (o en $\mathbb{R}$ con la estructura adecuada) tal que sus proyecciones finito-dimensionales son las μ_n.

La continuidad en 0 de φ asegura que la medida construida es una medida de probabilidad (es decir, que no hay "fuga de masa") y que φ es efectivamente la función característica de la proyección unidimensional.

Un argumento detallado de esta construcción puede encontrarse en [Durrett, 2019] o [Billingsley, 1995]. □

4.6. Caracterización de Lévy-Bochner de las funciones características (Teorema de Bochner)

La caracterización de Lévy presentada en la sección anterior (Teorema 4.5) establece las condiciones necesarias y suficientes para que una función sea característica. Sin embargo, la demostración de la suficiencia que esbozamos, basada en la construcción de Kolmogorov, es indirecta. Existe una caracterización más profunda y elegante, conocida como el Teorema de Bochner, que conecta las funciones características con la noción de funciones definidas positivas a través del análisis de Fourier y la teoría de la medida. Este teorema, debido a Salomon Bochner (1932), pero cuyas ideas fundamentales se remontan a los trabajos de Lévy y Mathias, establece un puente fundamental entre el análisis armónico y la teoría de la probabilidad.

Teorema 4.10 (Teorema de Bochner)**.** *Una función $\varphi : \mathbb{R} \to \mathbb{C}$ es la función característica de alguna medida de probabilidad sobre $\mathbb{R}$ si y solo si satisface las siguientes condiciones:*

1. $\varphi(0) = 1$.
2. *φ es continua en* 0.
3. *φ es de tipo positivo (definida positiva).*

Demostración. La necesidad de las condiciones ya ha sido establecida en el Teorema 4.5. Demostraremos la suficiencia mediante una construcción directa que utiliza el análisis de Fourier y el teorema de representación de Riesz-Markov.

Paso 1: Construcción de un núcleo positivo. Para cada $\varepsilon > 0$, definimos la función $g_\varepsilon : \mathbb{R} \to \mathbb{R}$ dada por

$$g_\varepsilon(t) = e^{-\varepsilon t^2/2}.$$

Esta función es la función característica de una distribución normal con media 0 y varianza ε (véase Ejemplo 3.6). Por tanto, g_ε es de tipo positivo y continua.

Consideramos ahora el producto $h_\varepsilon(t) = \varphi(t)g_\varepsilon(t)$. Dado que el producto puntual de funciones de tipo positivo es nuevamente de tipo positivo (esto puede verificarse mediante la propiedad de Schur del producto de matrices de Gram), la función h_ε es de tipo positivo, continua y acotada (pues $|\varphi(t)| \leq 1$ y $g_\varepsilon(t) \leq 1$).

Paso 2: La transformada de Fourier inversa de h_ε es una función de densidad. Definimos la función $f_\varepsilon : \mathbb{R} \to \mathbb{R}$ mediante la transformada de Fourier inversa:

$$f_\varepsilon(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} h_\varepsilon(t)\, dt = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi(t) e^{-\varepsilon t^2/2}\, dt.$$

Afirmamos que $f_\varepsilon(x) \geq 0$ para todo $x \in \mathbb{R}$. Para demostrarlo, utilizamos la propiedad de tipo positivo de h_ε. Por el teorema de Bochner (en su versión para funciones continuas y de tipo positivo), existe una medida finita μ_ε sobre $\mathbb{R}$ tal que

$$h_\varepsilon(t) = \int_{-\infty}^{\infty} e^{itx}\, d\mu_\varepsilon(x).$$

Esta medida μ_ε es precisamente la medida cuya función característica es h_ε. Pero por construcción, h_ε es la función característica del producto de convolución de la distribución asociada a φ (que aún no sabemos que existe) y una normal. Sin embargo, para evitar un razonamiento circular, utilizamos un argumento más directo.

Observemos que para cualquier colección finita $x_1, \ldots, x_n \in \mathbb{R}$ y cualquier vector $c = (c_1, \ldots, c_n) \in \mathbb{C}^n$, tenemos

$$\sum_{j,k=1}^{n} h_\varepsilon(x_j - x_k) c_j \overline{c_k} \geq 0.$$

En particular, tomando $n = 1$ y $c_1 = 1$, obtenemos $h_\varepsilon(0) \geq 0$, lo cual es cierto pues $h_\varepsilon(0) = \varphi(0)g_\varepsilon(0) = 1$.

Ahora, para demostrar que $f_\varepsilon(x) \geq 0$, consideramos la integral

$$\int_{-\infty}^{\infty} f_\varepsilon(x) \left| \sum_{k=1}^{n} c_k e^{ixt_k} \right|^2 dx$$

para una elección adecuada de puntos t_k y coeficientes c_k. Desarrollando el cuadrado y utilizando la definición de f_ε, obtenemos una expresión que involucra sumas de la forma $\sum_{j,k} h_\varepsilon(t_j - t_k) c_j \overline{c_k}$, que es no negativa. Por la arbitrariedad de los puntos y coeficientes, se concluye que $f_\varepsilon(x) \geq 0$ para todo x. Este argumento es esencialmente una aplicación de la identidad de Plancherel y la propiedad de tipo positivo.

Paso 3: Normalización de f_ε. Observemos que

$$\int_{-\infty}^{\infty} f_\varepsilon(x)\,dx = \frac{1}{2\pi}\int_{-\infty}^{\infty}\left(\int_{-\infty}^{\infty} e^{-itx}h_\varepsilon(t)\,dt\right)dx = h_\varepsilon(0) = 1,$$

donde hemos intercambiado el orden de integración y utilizado que $\int_{-\infty}^{\infty} e^{-itx}dx = 2\pi\delta(t)$ (en el sentido de las distribuciones) o, más rigurosamente, que la transformada de Fourier de f_ε evaluada en 0 es la integral de f_ε. Por tanto, f_ε es una función de densidad de probabilidad.

Sea μ_ε la medida de probabilidad con densidad f_ε, es decir, $d\mu_\varepsilon(x) = f_\varepsilon(x)dx$. Por construcción, la función característica de μ_ε es

$$\widehat{\mu_\varepsilon}(t) = \int_{-\infty}^{\infty} e^{itx}f_\varepsilon(x)\,dx = h_\varepsilon(t) = \varphi(t)e^{-\varepsilon t^2/2}.$$

Paso 4: Paso al límite $\varepsilon \to 0$. Consideremos ahora la familia de medidas $\{\mu_\varepsilon\}_{\varepsilon>0}$. Demostraremos que esta familia es tensa. En efecto, para cualquier $M > 0$,

$$\mu_\varepsilon([-M,M]^c) = \int_{|x|>M} f_\varepsilon(x)\,dx \le \frac{1}{M^2}\int_{|x|>M} x^2 f_\varepsilon(x)\,dx \le \frac{1}{M^2}\int_{-\infty}^{\infty} x^2 f_\varepsilon(x)\,dx.$$

Pero $\int_{-\infty}^{\infty} x^2 f_\varepsilon(x)\,dx = -\widehat{\mu_\varepsilon}''(0) = -\frac{d^2}{dt^2}\Big|_{t=0}\left(\varphi(t)e^{-\varepsilon t^2/2}\right)$. Dado que φ es continua en 0 y $|\varphi(t)| \le 1$, podemos acotar esta segunda derivada de manera uniforme en ε para ε pequeño. Por tanto, existe una constante C tal que $\int_{-\infty}^{\infty} x^2 f_\varepsilon(x)\,dx \le C$ para todo $\varepsilon > 0$ pequeño. En consecuencia,

$$\mu_\varepsilon([-M,M]^c) \le \frac{C}{M^2},$$

que tiende a 0 cuando $M \to \infty$, uniformemente en ε. Esto demuestra la tensión.

Por el teorema de selección de Helly (Teorema 4.3), existe una sucesión $\varepsilon_n \to 0$ tal que μ_{ε_n} converge débilmente a una medida de probabilidad μ.

Paso 5: Identificación del límite. Para cada $t \in \mathbb{R}$, tenemos

$$\widehat{\mu_{\varepsilon_n}}(t) = \varphi(t)e^{-\varepsilon_n t^2/2} \xrightarrow{n\to\infty} \varphi(t).$$

Por otra parte, como $\mu_{\varepsilon_n} \xrightarrow{\mathcal{D}} \mu$, el teorema de continuidad de Lévy (Teorema 4.1, parte 1) implica que $\widehat{\mu_{\varepsilon_n}}(t) \to \widehat{\mu}(t)$ para todo t. Por unicidad del límite, $\widehat{\mu}(t) = \varphi(t)$ para todo t. Por tanto, μ es la medida de probabilidad buscada, y φ es su función característica.

Esto completa la demostración de la suficiencia. □

Corolario 4.11. *Si φ es una función característica, entonces $\overline{\varphi}$ también lo es (correspondiente a la variable $-X$).*

Corolario 4.12. *Si φ y ψ son funciones características, entonces $\varphi\cdot\psi$ también lo es (correspondiente a la suma de variables independientes).*

Corolario 4.13. *Si φ es una función característica, entonces $|\varphi|^2$ también lo es.*

Demostración. $|\varphi(t)|^2 = \varphi(t)\overline{\varphi(t)} = \varphi(t)\varphi(-t)$ es la función característica de $X - X'$, donde X' es una copia independiente de X. □

Observación 4.14. El Teorema de Bochner admite una generalización importante: el Teorema de Khinchin, que caracteriza las funciones de tipo positivo en términos de medidas de probabilidad simétricas. Este resultado tiene aplicaciones en la teoría de procesos estacionarios y en análisis armónico.

4.7. Consecuencias de la caracterización de Lévy

Corolario 4.15. *Si φ es una función característica, entonces $\overline{\varphi}$ también lo es (correspondiente a la variable $-X$).*

Corolario 4.16. *Si φ y ψ son funciones características, entonces $\varphi \cdot \psi$ también lo es (correspondiente a la suma de variables independientes).*

Corolario 4.17. *Si φ es una función característica, entonces $|\varphi|^2$ también lo es.*

Demostración. $|\varphi(t)|^2 = \varphi(t)\overline{\varphi(t)} = \varphi(t)\varphi(-t)$ es la función característica de $X - X'$, donde X' es una copia independiente de X. □

5. El Teorema Central del Límite para sumas de variables i.i.d.

5.1. Enunciado del teorema

Teorema 5.1 (Teorema Central del Límite)**.** *Sea $\{X_n\}_{n\geq 1}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas (i.i.d.) definidas sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$. Supóngase que $\mathbb{E}[X_1] = \mu$ y $0 < \mathrm{Var}(X_1) = \sigma^2 < \infty$. Definamos la suma parcial*

$$S_n = \sum_{k=1}^{n} X_k.$$

Entonces,

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{\mathcal{D}} Z, \quad n \to \infty,$$

donde $Z \sim \mathcal{N}(0,1)$ es una variable aleatoria normal estándar.

En otras palabras, la sucesión de variables aleatorias estandarizadas converge en distribución a la distribución normal.

5.2. Demostración

La demostración procede mediante el método de funciones características, siguiendo el esquema propuesto por Laplace y rigurosamente justificado por el teorema de continuidad de Lévy.

Demostración. Sin pérdida de generalidad, podemos suponer $\mu = 0$ y $\sigma^2 = 1$. En efecto, si definimos $Y_n = (X_n - \mu)/\sigma$, entonces $\mathbb{E}[Y_n] = 0$, $\mathrm{Var}(Y_n) = 1$, y

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{k=1}^{n} Y_k.$$

Por tanto, asumimos $\mathbb{E}[X_n] = 0$, $\mathrm{Var}(X_n) = 1$.

Definamos la variable normalizada

$$Z_n = \frac{1}{\sqrt{n}} \sum_{k=1}^{n} X_k.$$

Queremos demostrar que $\varphi_{Z_n}(t) \to e^{-t^2/2}$ para todo $t \in \mathbb{R}$.

Por independencia e idéntica distribución,

$$\varphi_{Z_n}(t) = \mathbb{E}\left[\exp\left(it\frac{1}{\sqrt{n}}\sum_{k=1}^{n} X_k\right)\right] = \prod_{k=1}^{n} \mathbb{E}\left[\exp\left(i\frac{t}{\sqrt{n}}X_k\right)\right] = \left[\varphi\left(\frac{t}{\sqrt{n}}\right)\right]^n,$$

donde φ es la función característica común de los X_k.

El núcleo de la demostración es el análisis del comportamiento de $\varphi(u)$ cuando $u \to 0$. Puesto que $\mathbb{E}[X_1] = 0$ y $\mathbb{E}[X_1^2] = 1$, y utilizando la expansión de Taylor del exponencial complejo (justificada por el teorema de Taylor con resto integral), tenemos:

Para u suficientemente pequeño,

$$\varphi(u) = \mathbb{E}[e^{iuX_1}] = \mathbb{E}\left[1 + iuX_1 + \frac{(iuX_1)^2}{2} + \frac{(iuX_1)^3}{3!}e^{i\theta_u X_1}\right],$$

con $\theta_u \in (0, u)$. Pero $\mathbb{E}[X_1] = 0$ y $\mathbb{E}[X_1^2] = 1$, luego

$$\varphi(u) = 1 - \frac{u^2}{2} + u^2 R(u),$$

donde

$$R(u) = \frac{i^3}{3!}\mathbb{E}\left[X_1^3 e^{i\theta_u X_1}\right] \cdot u$$

si el tercer momento existe, o en general, un término de error que satisface $R(u) \to 0$ cuando $u \to 0$. Más precisamente, por el teorema de convergencia dominada, podemos demostrar que

$$\lim_{u\to 0} \frac{|\varphi(u) - (1 - u^2/2)|}{u^2} = 0.$$

Aplicando esto con $u = t/\sqrt{n}$, obtenemos

$$\varphi\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + \frac{t^2}{n}\varepsilon_n(t),$$

donde $\varepsilon_n(t) \to 0$ cuando $n \to \infty$ (para cada t fijo).

Por tanto,

$$\varphi_{Z_n}(t) = \left[1 - \frac{t^2}{2n} + \frac{t^2}{n}\varepsilon_n(t)\right]^n.$$

Tomando logaritmos y utilizando la expansión $\log(1 + z) = z + o(z)$ cuando $z \to 0$,

$$\log \varphi_{Z_n}(t) = n \log\left(1 - \frac{t^2}{2n} + \frac{t^2}{n}\varepsilon_n(t)\right) = n\left(-\frac{t^2}{2n} + \frac{t^2}{n}\varepsilon_n(t) + o\left(\frac{1}{n}\right)\right)$$

$$= -\frac{t^2}{2} + t^2\varepsilon_n(t) + o(1).$$

Haciendo tender $n \to \infty$, $\varepsilon_n(t) \to 0$, luego

$$\lim_{n\to\infty} \log \varphi_{Z_n}(t) = -\frac{t^2}{2},$$

y por continuidad de la exponencial,

$$\lim_{n\to\infty} \varphi_{Z_n}(t) = e^{-t^2/2}.$$

Hemos demostrado que para todo $t \in \mathbb{R}$, $\varphi_{Z_n}(t)$ converge a $e^{-t^2/2}$, que es una función continua en 0 (de hecho, es continua en todo $\mathbb{R}$). Por el teorema de continuidad de Lévy (Teorema 4.1), existe una variable aleatoria Z con función característica $e^{-t^2/2}$ tal que $Z_n \xrightarrow{\mathcal{D}} Z$. Por el Ejemplo 3.6, $Z \sim \mathcal{N}(0,1)$. Esto completa la demostración. □

Observación 5.2. Nótese que la demostración no requiere la existencia de momentos de orden superior a 2. La condición $\mathrm{Var}(X_1) < \infty$ es suficiente, gracias al control del error mediante el teorema de Taylor con resto integral y el teorema de convergencia dominada.

6. Arrays triangulares y condiciones de Lindeberg y Lyapunov

El TCL clásico requiere que las variables sean idénticamente distribuidas. Sin embargo, en muchas aplicaciones estadísticas, nos encontramos con sumas de variables independientes que no son idénticamente distribuidas. Por ejemplo, en el análisis de regresión, los errores pueden tener varianzas diferentes. Para tratar estos casos, necesitamos una versión más general del TCL.

6.1. Arrays triangulares de variables aleatorias

Definición 6.1 (Array triangular)**.** Un **array triangular** de variables aleatorias es una colección $\{X_{n,k} : 1 \le k \le n, n \ge 1\}$ tal que para cada n fijo, las variables $\{X_{n,1}, \dots, X_{n,n}\}$ son independientes.

La notación $X_{n,k}$ indica que la distribución de las variables puede depender tanto de n como de k. Esto permite modelar situaciones donde, al aumentar el tamaño muestral n, la distribución de cada sumando puede cambiar.

Definimos las sumas parciales

$$S_n = \sum_{k=1}^{n} X_{n,k}.$$

6.2. Condición de Lindeberg

Definición 6.2 (Condición de Lindeberg)**.** Sea $\{X_{n,k} : 1 \le k \le n, n \ge 1\}$ un array triangular de variables aleatorias independientes con $\mathbb{E}[X_{n,k}] = 0$ para todo n, k. Definamos

$$s_n^2 = \sum_{k=1}^{n} \mathbb{E}[X_{n,k}^2] = \sum_{k=1}^{n} \sigma_{n,k}^2.$$

Se dice que la sucesión satisface la **condición de Lindeberg** si para todo $\varepsilon > 0$,

$$\text{(L)} \qquad \lim_{n\to\infty} \frac{1}{s_n^2} \sum_{k=1}^{n} \mathbb{E}\left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}| > \varepsilon s_n\}}\right] = 0.$$

Intuitivamente, la condición de Lindeberg asegura que ninguna variable individual contribuye de manera desproporcionada a la varianza total. Es una condición de ïnfinitesimalidad" de los sumandos.

6.3. Condición de Lyapunov

Una condición suficiente (pero no necesaria) más fuerte que la de Lindeberg es la condición de Lyapunov.

Definición 6.3 (Condición de Lyapunov)**.** Sea $\{X_{n,k} : 1 \leq k \leq n, n \geq 1\}$ un array triangular de variables aleatorias independientes con $\mathbb{E}[X_{n,k}] = 0$. Definamos $s_n^2 = \sum_{k=1}^n \mathbb{E}[X_{n,k}^2]$. Se dice que la sucesión satisface la **condición de Lyapunov** si existe $\delta > 0$ tal que

$$\text{(LY)} \qquad \lim_{n\to\infty} \frac{1}{s_n^{2+\delta}} \sum_{k=1}^n \mathbb{E}\left[|X_{n,k}|^{2+\delta}\right] = 0.$$

Proposición 6.4. *La condición de Lyapunov implica la condición de Lindeberg.*

Demostración. Supongamos que se satisface (LY) para algún $\delta > 0$. Entonces, para cualquier $\varepsilon > 0$,

$$\mathbb{E}\left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}|>\varepsilon s_n\}}\right] = \mathbb{E}\left[|X_{n,k}|^2 \mathbf{1}_{\{|X_{n,k}|>\varepsilon s_n\}}\right] \leq \frac{1}{(\varepsilon s_n)^\delta} \mathbb{E}\left[|X_{n,k}|^{2+\delta} \mathbf{1}_{\{|X_{n,k}|>\varepsilon s_n\}}\right] \leq \frac{1}{(\varepsilon s_n)^\delta} \mathbb{E}\left[|X_{n,k}|^{2+\delta}\right].$$

Sumando sobre k,

$$\frac{1}{s_n^2} \sum_{k=1}^n \mathbb{E}\left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}|>\varepsilon s_n\}}\right] \leq \frac{1}{\varepsilon^\delta s_n^{2+\delta}} \sum_{k=1}^n \mathbb{E}\left[|X_{n,k}|^{2+\delta}\right] \xrightarrow{n\to\infty} 0.$$

□

7. El Teorema de Lindeberg-Feller

El teorema de Lindeberg-Feller es uno de los resultados más profundos y elegantes de la teoría de la probabilidad. Establece que, bajo la condición de Lindeberg, la suma normalizada converge a una normal, y además, si la convergencia a la normal se da junto con una condición de acotación de las varianzas, entonces la condición de Lindeberg es necesaria.

7.1. Enunciado del teorema

Teorema 7.1 (Lindeberg-Feller)**.** *Sea $\{X_{n,k} : 1 \leq k \leq n, n \geq 1\}$ un array triangular de variables aleatorias independientes con $\mathbb{E}[X_{n,k}] = 0$ para todo n, k. Definamos $s_n^2 = \sum_{k=1}^n \mathbb{E}[X_{n,k}^2]$. Supongamos que:*

(C1) $s_n^2 \to \sigma^2 > 0$ cuando $n \to \infty$ (condición de varianza estable).

(C2) Para todo $\varepsilon > 0$, se satisface la condición de Lindeberg (L).

Entonces,

$$\frac{S_n}{s_n} = \frac{\sum_{k=1}^n X_{n,k}}{s_n} \xrightarrow{\mathcal{D}} \mathcal{N}(0,1).$$

Recíprocamente, si se cumple que:

(R1) $\max_{1\le k\le n} \frac{\mathbb{E}[X_{n,k}^2]}{s_n^2} \to 0$ *(condición de infinitesimalidad).*

(R2) $\frac{S_n}{s_n} \xrightarrow{\mathcal{D}} \mathcal{N}(0,1)$.

entonces se satisface la condición de Lindeberg (L).

7.2. Demostración de la suficiencia

La demostración procede mediante funciones características, pero ahora tenemos un producto de términos diferentes.

Demostración de la suficiencia. Sea $\varphi_{n,k}(t) = \mathbb{E}[e^{itX_{n,k}}]$ la función característica de $X_{n,k}$. Entonces,

$$\varphi_{S_n/s_n}(t) = \prod_{k=1}^n \varphi_{n,k}\left(\frac{t}{s_n}\right).$$

Queremos demostrar que $\varphi_{S_n/s_n}(t) \to e^{-t^2/2}$ para todo $t \in \mathbb{R}$.

Paso 1: Aproximación de Taylor. Para cada k, desarrollamos $\varphi_{n,k}(u)$ alrededor de $u = 0$. Usando que $\mathbb{E}[X_{n,k}] = 0$ y $\mathbb{E}[X_{n,k}^2] = \sigma_{n,k}^2$, tenemos:

$$\varphi_{n,k}(u) = 1 - \frac{1}{2}\sigma_{n,k}^2 u^2 + R_{n,k}(u),$$

donde el resto satisface $|R_{n,k}(u)| \le \mathbb{E}[\text{mín}(|uX_{n,k}|^2, |uX_{n,k}|^3)]$ (una cota estándar para el resto de Taylor de la exponencial compleja).

Paso 2: Estimación del resto usando Lindeberg. Tomando $u = t/s_n$, tenemos:

$$|R_{n,k}(t/s_n)| \le \mathbb{E}\left[\text{mín}\left(\frac{t^2 X_{n,k}^2}{s_n^2}, \frac{|t|^3|X_{n,k}|^3}{s_n^3}\right)\right].$$

Para cualquier $\varepsilon > 0$, descomponemos la esperanza en dos regiones. En la región $\{|X_{n,k}| \le \varepsilon s_n\}$, el mínimo es $\frac{|t|^3|X_{n,k}|^3}{s_n^3}$, que está acotado por $\frac{|t|^3\varepsilon}{s_n^2}X_{n,k}^2$. En la región $\{|X_{n,k}| > \varepsilon s_n\}$, el mínimo es $\frac{t^2X_{n,k}^2}{s_n^2}$. Por tanto,

$$|R_{n,k}(t/s_n)| \le \frac{|t|^3\varepsilon}{s_n^2}\mathbb{E}[X_{n,k}^2] + \frac{t^2}{s_n^2}\mathbb{E}\left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}|>\varepsilon s_n\}}\right].$$

Paso 3: Suma de los restos. Sumando sobre k,

$$\sum_{k=1}^n |R_{n,k}(t/s_n)| \le |t|^3\varepsilon + t^2 \cdot \frac{1}{s_n^2}\sum_{k=1}^n \mathbb{E}\left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}|>\varepsilon s_n\}}\right].$$

Por la condición de Lindeberg, el segundo término tiende a 0 cuando $n \to \infty$. Por tanto,

$$\limsup_{n\to\infty} \sum_{k=1}^{n} |R_{n,k}(t/s_n)| \leq |t|^3 \varepsilon.$$

Como $\varepsilon > 0$ es arbitrario, concluimos que $\sum_{k=1}^{n} |R_{n,k}(t/s_n)| \to 0$.

Paso 4: Convergencia del producto. Ahora podemos escribir:

$$\log \varphi_{S_n/s_n}(t) = \sum_{k=1}^{n} \log \left(1 - \frac{1}{2} \frac{\sigma_{n,k}^2 t^2}{s_n^2} + R_{n,k}(t/s_n) \right).$$

Para $|z|$ pequeño, $|\log(1+z) - z| \leq |z|^2$. Por tanto,

$$\left| \log \varphi_{S_n/s_n}(t) + \frac{t^2}{2} \right| \leq \sum_{k=1}^{n} |R_{n,k}| + \sum_{k=1}^{n} \left(\frac{1}{2} \frac{\sigma_{n,k}^2 t^2}{s_n^2} + |R_{n,k}| \right)^2.$$

El primer término tiende a 0 por el Paso 3. Para el segundo término, notemos que

$$\sum_{k=1}^{n} \left(\frac{1}{2} \frac{\sigma_{n,k}^2 t^2}{s_n^2} + |R_{n,k}| \right)^2 \leq \max_k \left(\frac{1}{2} \frac{\sigma_{n,k}^2 t^2}{s_n^2} + |R_{n,k}| \right) \cdot \sum_{k=1}^{n} \left(\frac{1}{2} \frac{\sigma_{n,k}^2 t^2}{s_n^2} + |R_{n,k}| \right).$$

El primer factor tiende a 0 porque $\max_k \frac{\sigma_{n,k}^2}{s_n^2} \to 0$ (consecuencia de la condición de Lindeberg) y $|R_{n,k}| \to 0$. El segundo factor está acotado por $t^2/2 + o(1)$. Por tanto, el producto tiende a 0.

En consecuencia, $\log \varphi_{S_n/s_n}(t) \to -t^2/2$, y $\varphi_{S_n/s_n}(t) \to e^{-t^2/2}$. □

7.3. Demostración de la necesidad

La necesidad de la condición de Lindeberg es una de las contribuciones más importantes de Feller. Demuestra que si la convergencia a la normal se da junto con la condición de infinitesimalidad, entonces Lindeberg es necesaria.

Demostración de la necesidad. Supongamos que:

(I) $\max_{1\leq k\leq n} \frac{\sigma_{n,k}^2}{s_n^2} \to 0$ (condición de infinitesimalidad).

(II) $\frac{S_n}{s_n} \xrightarrow{\mathcal{D}} \mathcal{N}(0,1)$.

Queremos probar la condición de Lindeberg. Procedemos por contradicción: supongamos que existe $\varepsilon > 0$ tal que

$$\limsup_{n\to\infty} \frac{1}{s_n^2} \sum_{k=1}^{n} \mathbb{E}\left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}| > \varepsilon s_n\}} \right] = \delta > 0.$$

Extraemos una subsucesión (que seguimos denotando n) para la cual el límite superior se alcanza.

Paso 1: Construcción de variables truncadas. Definamos las variables truncadas:

$$Y_{n,k} = X_{n,k}\mathbf{1}_{\{|X_{n,k}|\leq \varepsilon s_n\}}, \quad Z_{n,k} = X_{n,k}\mathbf{1}_{\{|X_{n,k}|>\varepsilon s_n\}}.$$

Entonces $X_{n,k} = Y_{n,k} + Z_{n,k}$. Notemos que $Y_{n,k}$ y $Z_{n,k}$ son independientes (por ser funciones de $X_{n,k}$) y tienen media no nula en general.

Paso 2: Reemplazo por variables gaussianas. La idea es comparar la distribución de S_n con la de una suma de variables gaussianas independientes $G_{n,k}$ con la misma media y varianza que $X_{n,k}$. Por el teorema de Lindeberg (versión original de 1922), podemos mostrar que la diferencia entre las funciones características de ambas sumas tiende a 0 si y solo si se satisface la condición de Lindeberg.

Un argumento detallado (que puede encontrarse en [Durrett, 2019] o [Billingsley, 1995]) muestra que si la condición de Lindeberg falla, entonces existe una discrepancia no nula en las funciones características, contradiciendo la hipótesis de convergencia a la normal. □

8. El Teorema de Lyapunov

El teorema de Lyapunov es una versión suficiente (pero no necesaria) del TCL para arrays triangulares, que utiliza momentos de orden superior.

Teorema 8.1 (Lyapunov)**.** *Sea $\{X_{n,k} : 1 \leq k \leq n, n \geq 1\}$ un array triangular de variables aleatorias independientes con $\mathbb{E}[X_{n,k}] = 0$ para todo n, k. Definamos $s_n^2 = \sum_{k=1}^n \mathbb{E}[X_{n,k}^2]$. Supongamos que existe $\delta > 0$ tal que se satisface la condición de Lyapunov (LY):*

$$\lim_{n\to\infty} \frac{1}{s_n^{2+\delta}} \sum_{k=1}^n \mathbb{E}\left[|X_{n,k}|^{2+\delta}\right] = 0.$$

Entonces,

$$\frac{S_n}{s_n} = \frac{\sum_{k=1}^n X_{n,k}}{s_n} \xrightarrow{\mathcal{D}} \mathcal{N}(0,1).$$

Demostración. La demostración es una consecuencia directa del teorema de Lindeberg-Feller, pues ya probamos que la condición de Lyapunov implica la condición de Lindeberg (Proposición 6.3). Por tanto, bajo la hipótesis de Lyapunov, se satisface la condición de Lindeberg y, aplicando el teorema de Lindeberg-Feller, obtenemos la convergencia deseada. □

Ejemplo 8.2 (Aplicación del teorema de Lyapunov)**.** *Sean $\{Y_k\}_{k\geq 1}$ variables aleatorias independientes con distribuciones:*

$$Y_k \sim \textit{Uniforme}(-k, k).$$

Entonces $\mathbb{E}[Y_k] = 0$ y $\mathbb{E}[Y_k^2] = \frac{k^2}{3}$. Definamos $s_n^2 = \sum_{k=1}^n \frac{k^2}{3} \sim \frac{n^3}{9}$.

Tomemos $\delta = 2$. Entonces $\mathbb{E}[|Y_k|^4] = \frac{k^4}{5}$. Por tanto,

$$\frac{1}{s_n^4} \sum_{k=1}^n \mathbb{E}[|Y_k|^4] \sim \frac{1}{(n^3/9)^2} \sum_{k=1}^n \frac{k^4}{5} \sim \frac{81}{n^6} \cdot \frac{n^5}{25} = O\left(\frac{1}{n}\right) \to 0.$$

Se satisface la condición de Lyapunov, luego $\frac{\sum_{k=1}^n Y_k}{s_n} \xrightarrow{\mathcal{D}} \mathcal{N}(0,1)$.

9. Caracterización de Lévy de las distribuciones estables

Una aplicación profunda de la caracterización de Lévy es la descripción de las distribuciones estables.

Definición 9.1 (Distribución estable)**.** Una variable aleatoria X (o su distribución) se dice **estable** si para cualesquiera $n \in \mathbb{N}$ y copias independientes $X_1, \ldots, X_n$ de X, existen constantes $a_n > 0$ y $b_n \in \mathbb{R}$ tales que

$$X_1 + \cdots + X_n \stackrel{d}{=} a_n X + b_n.$$

Si $b_n = 0$, la distribución se dice **estrictamente estable**.

Teorema 9.2 (Caracterización de Lévy de las distribuciones estables)**.** *Una variable aleatoria X tiene distribución estable si y solo si su función característica es de la forma*

$$\varphi(t) = \exp\left\{ i\mu t - c|t|^\alpha \left(1 - i\beta \operatorname{sign}(t) \tan\left(\frac{\pi\alpha}{2}\right)\right)\right\}, \quad \alpha \neq 1,$$

$$\varphi(t) = \exp\left\{ i\mu t - c|t| \left(1 + i\beta \frac{2}{\pi} \operatorname{sign}(t) \log|t|\right)\right\}, \quad \alpha = 1,$$

donde $0 < \alpha \leq 2$, $-1 \leq \beta \leq 1$, $c \geq 0$, y $\mu \in \mathbb{R}$.

Demostración. La demostración utiliza la caracterización de Lévy junto con propiedades de grupos de transformaciones y puede encontrarse en [Feller, 1971] o [Durrett, 2019]. □

10. Ejercicios complementarios

Ejercicio 10.1. *Demuestre que si $\{X_n\}_{n\geq 1}$ son i.i.d. con $\mathbb{E}[X_1] = 0$ y $\mathbb{E}[X_1^2] = 1$, entonces la condición de Lindeberg se satisface para el array $X_{n,k} = X_k/\sqrt{n}$.*

Ejercicio 10.2. *Sea $\{X_n\}_{n\geq 1}$ una sucesión de variables independientes con $\mathbb{P}(X_n = n) = \mathbb{P}(X_n = -n) = 1/(2n^2)$ y $\mathbb{P}(X_n = 0) = 1 - 1/n^2$. Verifique si se satisface la condición de Lindeberg. ¿Converge S_n/s_n a una normal?*

Ejercicio 10.3. *Demuestre que la condición de Lindeberg implica que $\max_{1\leq k\leq n} \frac{\sigma_{n,k}^2}{s_n^2} \to 0$.*

Ejercicio 10.4. *Construya un array triangular que satisfaga la condición de Lindeberg pero no la condición de Lyapunov para ningún $\delta > 0$.*

Ejercicio 10.5. *Sea $\{X_n\}_{n\geq 1}$ una sucesión de variables independientes con distribución de Poisson de parámetro λ_n. Encuentre condiciones sobre $\{\lambda_n\}$ para que se satisfaga la condición de Lyapunov.*

Ejercicio 10.6. *Utilizando la caracterización de Lévy, demuestre que la función $\varphi(t) = \frac{1}{1+t^2}$ es una función característica. ¿De qué distribución?*

Ejercicio 10.7. *Demuestre que la función $\varphi(t) = \max(1 - |t|, 0)$ no es una función característica.*

Ejercicio 10.8. *Sea φ una función característica. Demuestre que $|\varphi(t)|^2$ también es una función característica y que corresponde a la diferencia de dos copias independientes.*

Referencias

[1] Billingsley, P. (1995). *Probability and Measure* (3rd ed.). Wiley.

[2] Chung, K.L. (2001). *A Course in Probability Theory* (3rd ed.). Academic Press.

[3] Durrett, R. (2019). *Probability: Theory and Examples* (5th ed.). Cambridge University Press.

[4] Feller, W. (1968). *An Introduction to Probability Theory and Its Applications*, Vol. 1 (3rd ed.). Wiley.

[5] Feller, W. (1971). *An Introduction to Probability Theory and Its Applications*, Vol. 2 (2nd ed.). Wiley.

[6] Gut, A. (2013). *Probability: A Graduate Course* (2nd ed.). Springer.

[7] Resnick, S.I. (2013). *A Probability Path*. Birkhäuser.

[8] Williams, D. (1991). *Probability with Martingales*. Cambridge University Press.

[9] Lindeberg, J.W. (1922). .Eine neue Herleitung des Exponentialgesetzes in der Wahrscheinlichkeitsrechnung". *Mathematische Zeitschrift*, 15(1), 211-225.

[10] Feller, W. (1935). "Über den zentralen Grenzwertsatz der Wahrscheinlichkeitsrechnung". *Mathematische Zeitschrift*, 40(1), 521-559.

[11] Lyapunov, A.M. (1901). "Nouvelle forme du théorème sur la limite de probabilité". *Mémoires de l'Académie Impériale des Sciences de Saint-Pétersbourg*, 12(5), 1-24.

[12] Lévy, P. (1925). *Calcul des Probabilités*. Gauthier-Villars.

[13] Bochner, S. (1932). *Vorlesungen über Fouriersche Integrale*. Akademische Verlagsgesellschaft.

Nota final

Estas notas fueron escritas para el curso de Probabilidad de la Facultad de Ciencias. Ciudad de México, mayo de 2020.