Cadenas de Markov en Tiempo Continuo

César Galindo

Contenido

Propiedades de la Exponencial

Cadenas en Tiempo Continuo
- Interpretación con tiempos de espera

Galería de Imágenes

Tiempos medios de paso

Procesos de Nacimiento y Muerte
- Ejemplos
- Clasificación

Procesos de Nacimiento Puro

Aplicaciones en Inteligencia Artificial

Ecuaciones Forward y Backward

Relojes exponenciales independientes

Definición

Sean $T_1, \ldots, T_n$ variables aleatorias independientes con distribución exponencial de parámetros $b_1, \ldots, b_n$ respectivamente. Definimos

$$T = \text{mín}\{T_1, \ldots, T_n\}.$$

Interpretamos T_i como el momento en que suena el reloj i.

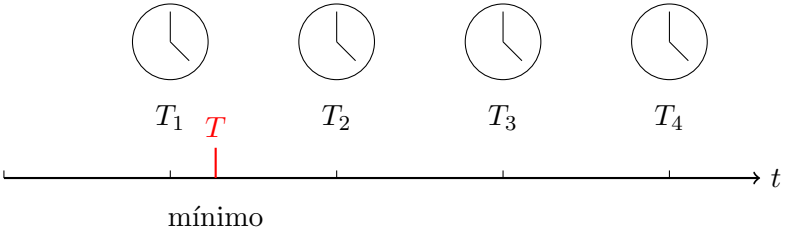

El mínimo de exponenciales es exponencial

Teorema

La variable aleatoria $T = \min\{T_1, \ldots, T_n\}$ *tiene distribución exponencial con parámetro* $b_1 + \cdots + b_n$.

Demostración.

Calculamos la función de supervivencia:

$$\mathbb{P}\{T \geq t\} = \mathbb{P}\{T_1 \geq t, \ldots, T_n \geq t\}.$$

Por independencia:

$$\mathbb{P}\{T \geq t\} = \prod_{i=1}^{n} \mathbb{P}\{T_i \geq t\} = \prod_{i=1}^{n} e^{-b_i t} = e^{-(b_1 + \cdots + b_n)t}.$$

$\square$

Probabilidad de que un reloj sea el primero

Teorema

La probabilidad de que el reloj i sea el primero en sonar es

$$\mathbb{P}\{T_i = T\} = \frac{b_i}{b_1 + \cdots + b_n}.$$

Idea: se integra sobre el instante en que suena el reloj i y se exige que todos los demás sigan activos hasta ese tiempo.

Probabilidad de que un reloj sea el primero (demostración)

Demostración.

Condicionamos en el valor de T_i:

$$\begin{aligned}
\mathbb{P}\{T_i = T\} &= \int_0^\infty \mathbb{P}\{T_j > t \ \forall j \neq i\}\, b_i e^{-b_i t}\, dt \\
&= \int_0^\infty e^{-(b_1+\cdots+b_{i-1}+b_{i+1}+\cdots+b_n)t} b_i e^{-b_i t}\, dt \\
&= b_i \int_0^\infty e^{-(b_1+\cdots+b_n)t}\, dt \\
&= \frac{b_i}{\sum_j b_j}.
\end{aligned}$$

$\square$

Definición de CTMC

Definición

Sea S un espacio de estados finito. Un proceso $\{X_t\}_{t\geq 0}$ con valores en S es una **cadena de Markov en tiempo continuo** si satisface:

- **Propiedad de Markov:** $\mathbb{P}\{X_t = y \mid X_r, 0 \leq r \leq s\} = \mathbb{P}\{X_t = y \mid X_s\}$.
- **Homogeneidad temporal:** $\mathbb{P}\{X_t = y \mid X_s = x\} = \mathbb{P}\{X_{t-s} = y \mid X_0 = x\}$.

Tasas de transición

Definición

Para cada $x \neq y$, asignamos una **tasa de transición** $\alpha(x, y) \geq 0$. La **tasa total de salida** de x es

$$\alpha(x) = \sum_{y \neq x} \alpha(x, y).$$

Interpretación

En un intervalo muy pequeño, $\alpha(x, y)$ mide la rapidez con la que el proceso abandona x y salta hacia y.

Probabilidades infinitesimales

Comportamiento en intervalos pequeños

$$\mathbb{P}\{X_{t+\Delta t} = x \mid X_t = x\} = 1 - \alpha(x)\Delta t + o(\Delta t),$$
$$\mathbb{P}\{X_{t+\Delta t} = y \mid X_t = x\} = \alpha(x, y)\Delta t + o(\Delta t), \quad y \neq x.$$

Probabilidades infinitesimales: esquema

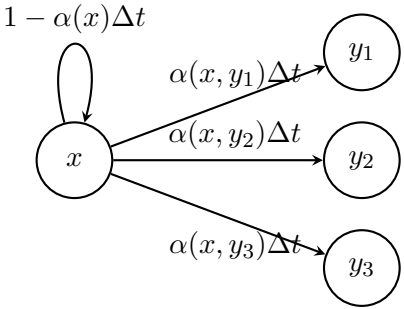

Generador infinitesimal

Definición

La **matriz generadora infinitesimal $\mathbf{A}$** tiene entradas:

$$\mathbf{A}(x,y) = \begin{cases} \alpha(x,y) & \text{si } x \neq y, \\ -\alpha(x) & \text{si } x = y. \end{cases}$$

Observación

Las filas de $\mathbf{A}$ suman cero y las entradas fuera de la diagonal son no negativas.

Forma de la matriz generadora

$$\begin{bmatrix} -\alpha(1) & \alpha(1,2) & \cdots & \alpha(1,n) \\ \alpha(2,1) & -\alpha(2) & \cdots & \alpha(2,n) \\ \vdots & \vdots & \ddots & \vdots \\ \alpha(n,1) & \alpha(n,2) & \cdots & -\alpha(n) \end{bmatrix}$$

$$\sum_{y} \mathbf{A}(x,y) = -\alpha(x) + \sum_{y \neq x} \alpha(x,y) = 0.$$

Ecuaciones diferenciales

Proposición

Las probabilidades $p_x(t) = \mathbb{P}\{X_t = x\}$ *satisfacen*

$$p_x'(t) = -\alpha(x)p_x(t) + \sum_{y \neq x} \alpha(y,x)p_y(t).$$

flujo que entra − flujo que sale

Ecuaciones diferenciales: demostración I

Demostración.

Condicionando en el estado en el instante t:

$$\begin{aligned} p_x(t+\Delta t) &= \sum_y \mathbb{P}\{X_t = y\}\mathbb{P}\{X_{t+\Delta t} = x \mid X_t = y\} \\ &= p_x(t)\mathbb{P}\{X_{t+\Delta t} = x \mid X_t = x\} + \sum_{y \neq x} p_y(t)\mathbb{P}\{X_{t+\Delta t} = x \mid X_t = y\}. \end{aligned}$$

Usando las probabilidades infinitesimales:

$$p_x(t+\Delta t) = p_x(t)(1-\alpha(x)\Delta t) + \sum_{y \neq x} p_y(t)\alpha(y,x)\Delta t + o(\Delta t).$$

$\square$

Ecuaciones diferenciales: demostración II

Continuación.

Restamos $p_x(t)$ a ambos lados y dividimos entre Δt:

$$\frac{p_x(t+\Delta t) - p_x(t)}{\Delta t} = -\alpha(x)p_x(t) + \sum_{y \neq x} \alpha(y,x)p_y(t) + o(1).$$

Al tomar el límite cuando $\Delta t \to 0$ obtenemos

$$p_x'(t) = -\alpha(x)p_x(t) + \sum_{y \neq x} \alpha(y,x)p_y(t).$$

$\square$

Forma matricial

Proposición

Sea $\mathbf{p}(t)$ *el vector fila de probabilidades. Entonces*

$$\mathbf{p}'(t) = \mathbf{p}(t)\mathbf{A}.$$

Definición

La matriz de transición $\mathbf{P}_t$ tiene entradas

$$p_t(x, y) = \mathbb{P}\{X_t = y \mid X_0 = x\}.$$

Por tanto,

$$\frac{d}{dt}\mathbf{P}_t = \mathbf{P}_t\mathbf{A}, \qquad \mathbf{P}_0 = \mathbf{I}.$$

Solución matricial

Proposición

La solución del sistema es

$$\mathbf{p}(t) = \mathbf{p}(0)e^{t\mathbf{A}}.$$

En particular,

$$\mathbf{P}_t = e^{t\mathbf{A}} = \sum_{n=0}^{\infty} \frac{(t\mathbf{A})^n}{n!}.$$

$$\boxed{\mathbf{P}_t = e^{t\mathbf{A}}}$$

$$\xrightarrow[\text{evolución temporal}]{}$$

Ejemplo: cadena de dos estados

Ejemplo

Estados $\{0, 1\}$, tasas $\alpha(0, 1) = 1$, $\alpha(1, 0) = 2$.

$$\mathbf{A} = \begin{pmatrix} -1 & 1 \\ 2 & -2 \end{pmatrix}.$$

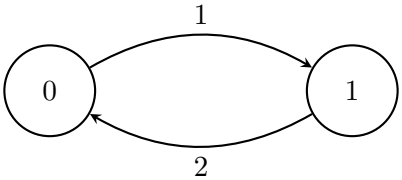

Ejemplo: cadena de dos estados (solución)

Eigenvalores: $\lambda_1 = 0$, $\lambda_2 = -3$.

$$\mathbf{P}_t = \begin{pmatrix} \frac{2}{3} + \frac{1}{3}e^{-3t} & \frac{1}{3} - \frac{1}{3}e^{-3t} \\ \frac{2}{3} - \frac{2}{3}e^{-3t} & \frac{1}{3} + \frac{2}{3}e^{-3t} \end{pmatrix}.$$

Ejemplo: cadena de cuatro estados

Ejemplo

Estados $\{0, 1, 2, 3\}$, generador:

$$\mathbf{A} = \begin{pmatrix} -3 & 1 & 1 & 1 \\ 2 & -4 & 1 & 1 \\ 2 & 1 & -4 & 1 \\ 1 & 1 & 1 & -3 \end{pmatrix}.$$

Ejemplo: cadena de cuatro estados (grafo)

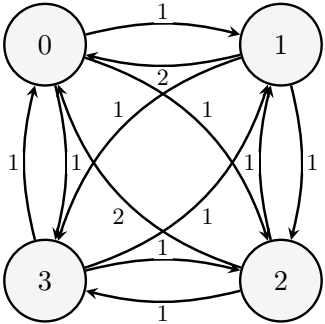

Grafo simétrico con etiquetas separadas para evitar cruces y encimamientos.

Distribución estacionaria

Teorema

Para una cadena irreducible en espacio finito, existe una única distribución π tal que $\pi\mathbf{A} = 0$ y

$$\lim_{t\to\infty} \mathbf{P}_t = \mathbf{1}\pi.$$

Para el ejemplo de 4 estados: $\pi = (7/20, 1/5, 1/5, 1/4)$.

Tiempo hasta el primer salto

Teorema

Sea $X_0 = x$ *y* $T = \inf\{t : X_t \neq x\}$. *Entonces* T *tiene distribución exponencial con parámetro* $\alpha(x)$.

Demostración.

Propiedad de pérdida de memoria y $\mathbb{P}\{T \leq \Delta t\} = \alpha(x)\Delta t + o(\Delta t)$. $\square$

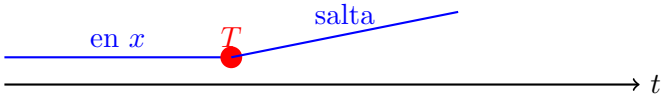

$$T \sim \mathrm{Exp}(\alpha(x))$$

Probabilidad del destino del salto

Teorema

Condicionado a T, la probabilidad de saltar a $y \neq x$ es

$$\mathbb{P}\{X_T = y\} = \frac{\alpha(x,y)}{\alpha(x)}.$$

Probabilidad del destino del salto: demostración

Demostración.

Para $y \neq x$, comparamos la probabilidad de que el primer salto ocurra en $[t, t+\Delta t]$ y termine en y con la probabilidad total de saltar en ese intervalo:

$$\mathbb{P}\{X_T = y \mid T \in [t, t+\Delta t]\} = \frac{e^{-\alpha(x)t}\alpha(x,y)\Delta t}{e^{-\alpha(x)t}\alpha(x)\Delta t} + o(1).$$

Cancelando el factor común $e^{-\alpha(x)t}\Delta t$ y dejando $\Delta t \to 0$, obtenemos

$$\mathbb{P}\{X_T = y\} = \frac{\alpha(x,y)}{\alpha(x)}.$$

$\square$

Probabilidad del destino del salto: esquema

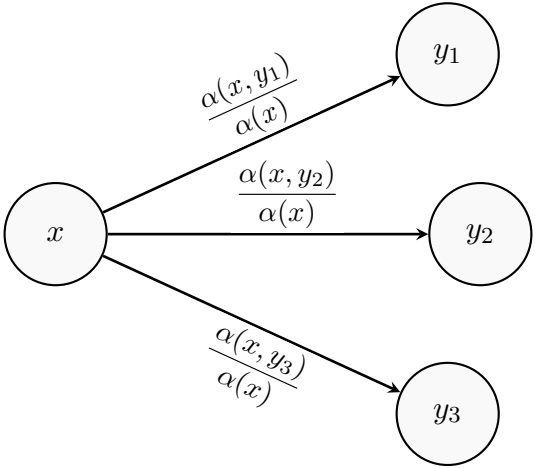

Interpretación de los relojes

Observación (Relojes independientes)

En cada estado $y \neq x$ colocamos un reloj independiente que suena con tiempo exponencial de tasa $\alpha(x, y)$. La cadena permanece en x hasta que suena el primer reloj y entonces salta al estado correspondiente.

Idea central

El *mínimo* de esos relojes determina el tiempo de espera en x, y el reloj ganador determina el siguiente estado.

Relojes independientes: representación gráfica

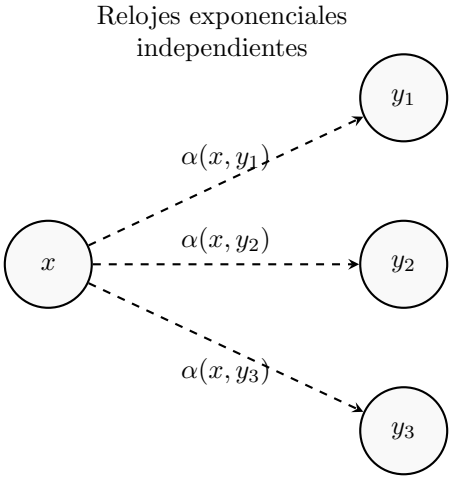

Visualización: convergencia estacionaria

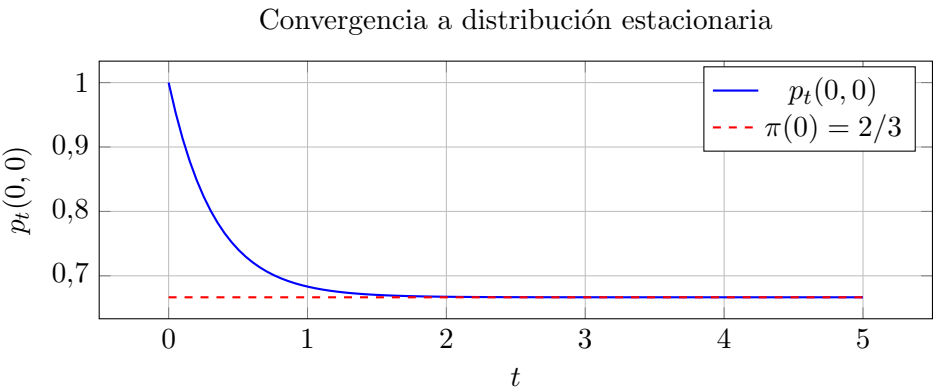

Visualización: crecimiento del proceso de Yule

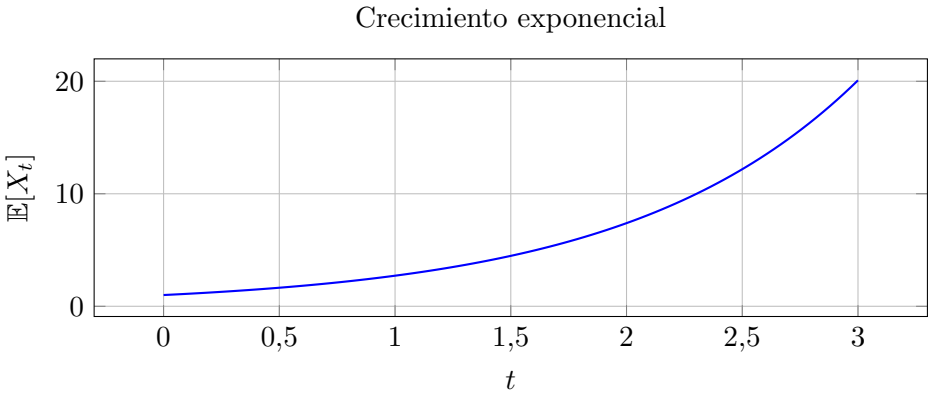

Visualización: distribución estacionaria M/M/∞

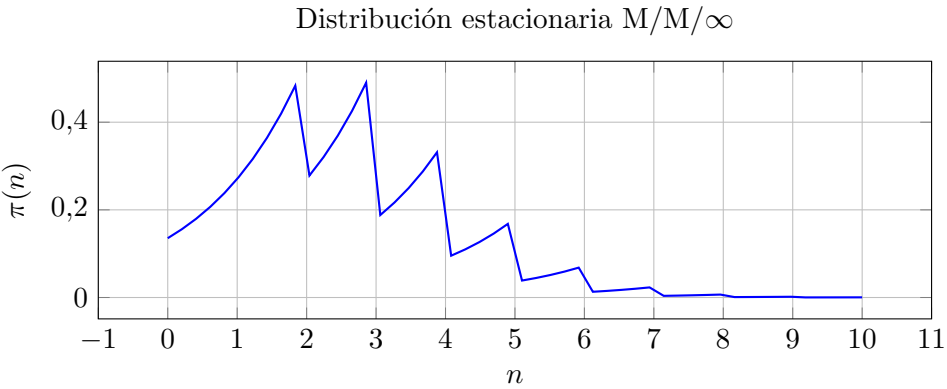

Visualización: probabilidades del proceso de Yule

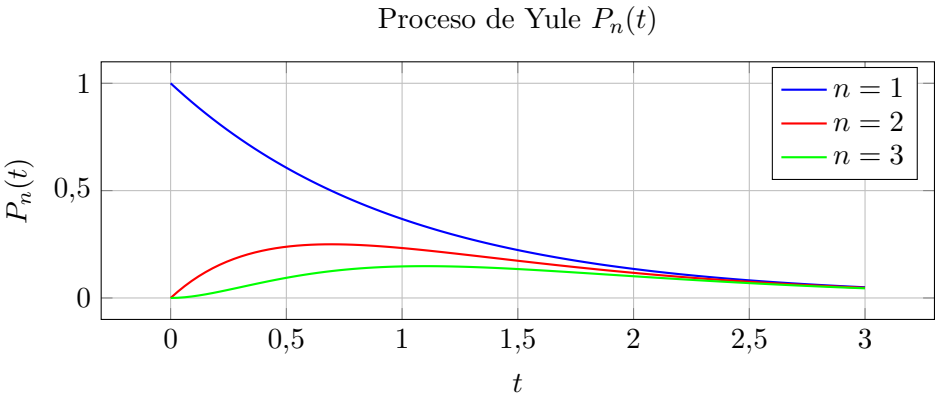

Estructuras de cadenas de Markov I

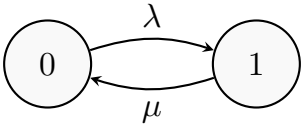

Cadena de 2 estados

Estructuras de cadenas de Markov I: cadena de 4 estados

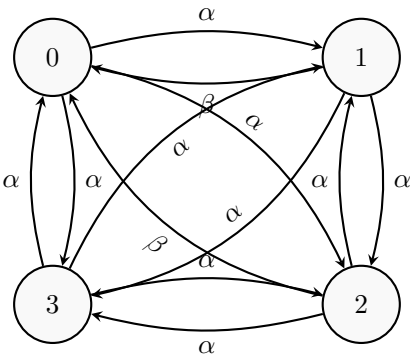

Cadena de 4 estados con mayor separación entre nodos y etiquetas.

Estructuras de cadenas de Markov II

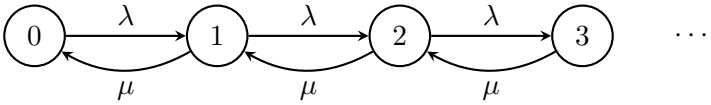

Proceso de nacimiento–muerte

Explosión en tiempo finito: esquema

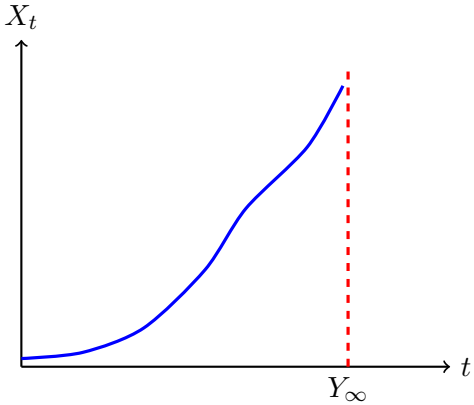

El proceso acumula infinitos saltos antes de un tiempo aleatorio finito.

Estructuras de cadenas de Markov III

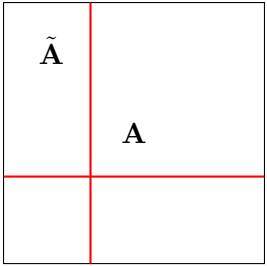

Matriz reducida para tiempos medios de paso

Definición

Definición

Sea z un estado fijo. Definimos el **tiempo medio de paso** a z comenzando en x como

$$b(x) = \mathbb{E}(Y \mid X_0 = x), \quad \text{donde } Y = \inf\{t : X_t = z\}.$$

Claramente $b(z) = 0$.

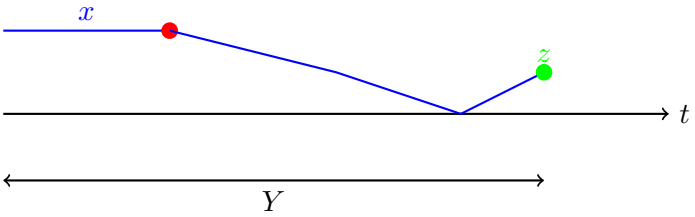

Ecuación para los tiempos medios de paso

Teorema

Para $x \neq z$, la función $b(x)$ satisface

$$\alpha(x)b(x) = 1 + \sum_{y \neq x,z} \alpha(x,y)b(y).$$

Demostración.

Condicionando en el primer salto:

$$b(x) = \mathbb{E}(T) + \sum_{y} \mathbb{P}\{X_T = y\}b(y) = \frac{1}{\alpha(x)} + \sum_{y \neq x} \frac{\alpha(x,y)}{\alpha(x)} b(y).$$

Usando $b(z) = 0$ y multiplicando por $\alpha(x)$ obtenemos la ecuación. $\square$

Forma matricial

Corolario

Sea $\tilde{\mathbf{A}}$ *la matriz obtenida de* $\mathbf{A}$ *eliminando la fila y columna correspondientes al estado* z*. Sea* $\bar{b}$ *el vector de tiempos medios para* $x \neq z$*. Entonces*

$$\tilde{\mathbf{A}}\,\bar{b} = -\bar{1}.$$

En consecuencia,

$$\bar{b} = [-\tilde{\mathbf{A}}]^{-1}\bar{1}.$$

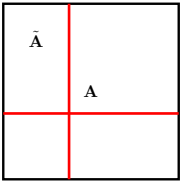

Ejemplo numérico

Para la cadena de 4 estados con $z = 3$:

$$\tilde{\mathbf{A}} = \begin{pmatrix} -3 & 1 & 1 \\ 2 & -4 & 1 \\ 2 & 1 & -4 \end{pmatrix}.$$

Resolvemos $-\tilde{\mathbf{A}}\bar{b} = \bar{1}$:

$$\begin{cases} 3b_0 - b_1 - b_2 = 1 \\ -2b_0 + 4b_1 - b_2 = 1 \\ -2b_0 - b_1 + 4b_2 = 1 \end{cases}$$

Solución: $b_0 = b_1 = b_2 = 1$.

El tiempo esperado del estado 0 al estado 3 es 1.

Definición

Definición

Un **proceso de nacimiento y muerte** es una cadena de Markov en tiempo continuo con espacio de estados $\{0, 1, 2, \ldots\}$ donde los únicos cambios posibles son:

- $n \to n+1$ (nacimiento) con tasa $\lambda_n \geq 0$
- $n \to n-1$ (muerte) con tasa $\mu_n \geq 0$, $\mu_0 = 0$

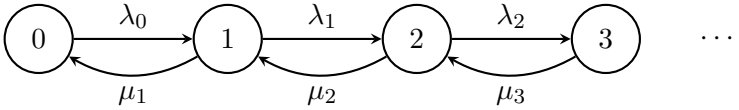

Probabilidades infinitesimales

$$
\begin{aligned}
\mathbb{P}\{X_{t+\Delta t} = n \mid X_t = n\} &= 1 - (\lambda_n + \mu_n)\Delta t + o(\Delta t), \\
\mathbb{P}\{X_{t+\Delta t} = n+1 \mid X_t = n\} &= \lambda_n \Delta t + o(\Delta t), \\
\mathbb{P}\{X_{t+\Delta t} = n-1 \mid X_t = n\} &= \mu_n \Delta t + o(\Delta t).
\end{aligned}
$$

Probabilidades infinitesimales: esquema del salto

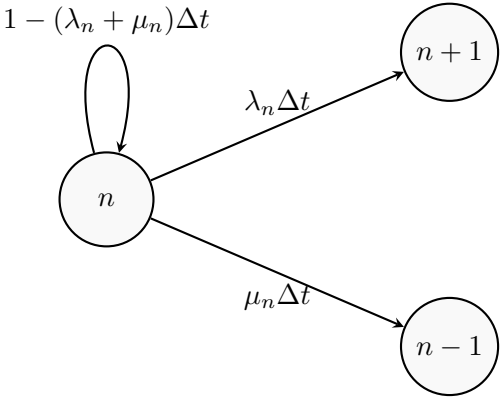

Ecuaciones diferenciales

Proposición

Las probabilidades $P_n(t) = \mathbb{P}\{X_t = n\}$ *satisfacen:*

$$P_n'(t) = \mu_{n+1}P_{n+1}(t) + \lambda_{n-1}P_{n-1}(t) - (\mu_n + \lambda_n)P_n(t).$$

con $\lambda_{-1} = 0$, $\mu_0 = 0$.

$$\begin{tikzcd}
\mu_{n+1}P_{n+1} \arrow[dr, "\text{flujo}"] & \\
\lambda_{n-1}P_{n-1} \arrow[dr, "\text{flujo}"] & P_n' \\
-(\mu_n + \lambda_n)P_n &
\end{tikzcd}$$

Ejemplo 1: Proceso de Poisson

Ejemplo

$\lambda_n = \lambda$, $\mu_n = 0$ para todo n.

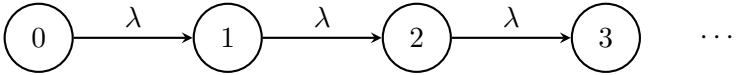

Ecuaciones: $P_n'(t) = \lambda P_{n-1}(t) - \lambda P_n(t)$.
Solución: $P_n(t) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}$.

Ejemplo 2: Cola M/M/1

Ejemplo

Un servidor, llegadas Poisson con tasa λ, servicios exponenciales con tasa μ.

$$\lambda_n = \lambda, \quad \mu_n = \mu \ (n \geq 1), \ \mu_0 = 0.$$

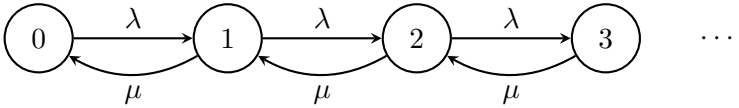

Ejemplo 3: Cola M/M/k

Ejemplo

k servidores, cada uno sirve a tasa μ.

$$\lambda_n = \lambda, \quad \mu_n = \text{mín}(n, k)\mu.$$

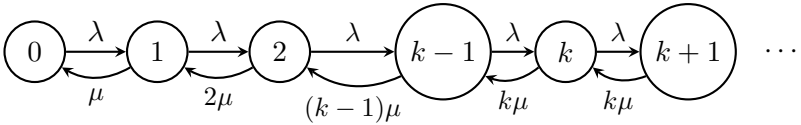

Ejemplo 4: Cola M/M/∞

Ejemplo

Infinitos servidores: cada persona en cola es servida inmediatamente.

$$\lambda_n = \lambda, \quad \mu_n = n\mu.$$

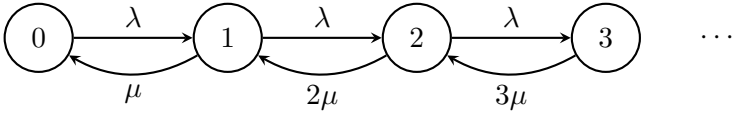

Ejemplo 5: Modelo de población

Ejemplo

Cada individuo produce descendencia a tasa λ y muere a tasa μ, independientemente.

$$\lambda_n = n\lambda, \quad \mu_n = n\mu.$$

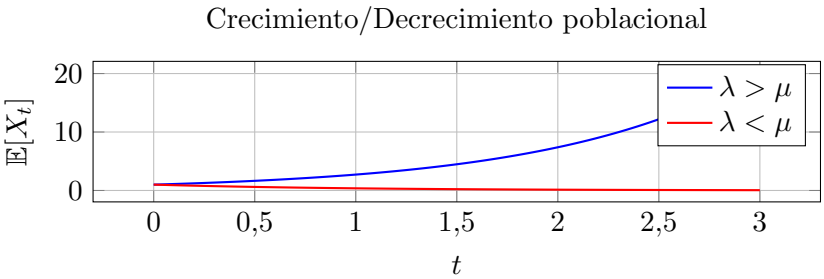

Ejemplo 6: Crecimiento rápido

Ejemplo

$\lambda_n = n^2\lambda$, $\mu_n = 0$.

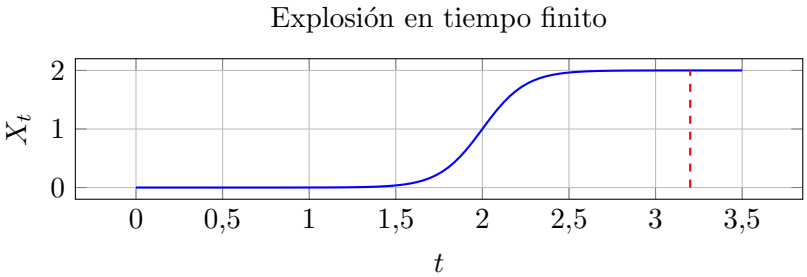

$$Y_\infty = \sum_{i=1}^{\infty} \frac{1}{i^2\lambda} = \frac{\pi^2}{6\lambda} < \infty$$

Criterio de transiencia

Teorema

Un proceso de nacimiento y muerte irreducible es ***transitorio*** *si y solo si*

$$\sum_{n=1}^{\infty} \frac{\mu_1 \mu_2 \cdots \mu_n}{\lambda_1 \lambda_2 \cdots \lambda_n} < \infty.$$

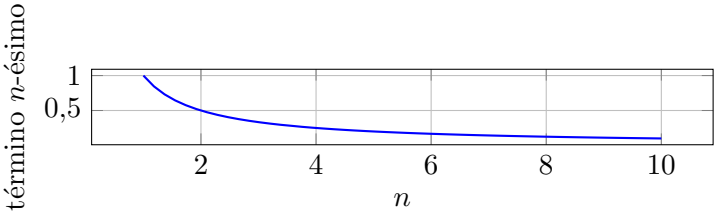

Convergencia $\Rightarrow$ transiencia

Criterio de recurrencia positiva

Teorema

Un proceso de nacimiento y muerte irreducible es ***positivamente recurrente*** *si y solo si*

$$\sum_{n=0}^{\infty} \frac{\lambda_0 \lambda_1 \cdots \lambda_{n-1}}{\mu_1 \mu_2 \cdots \mu_n} < \infty.$$

En tal caso, la distribución estacionaria es

$$\pi(n) = \frac{\lambda_0 \lambda_1 \cdots \lambda_{n-1}}{\mu_1 \mu_2 \cdots \mu_n} \cdot \frac{1}{C},$$

donde C es la suma de la serie.

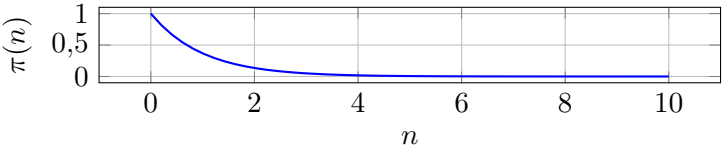

Clasificación de colas M/M

Modelo	Transitoria	Positivamente recurrente	Distribución $\pi(n)$
M/M/1	$\mu < \lambda$	$\lambda < \mu$	$(1-\rho)\rho^n$, $\rho = \lambda/\mu$
M/M/k	$k\mu < \lambda$	$\lambda < k\mu$	fórmula complicada
M/M/∞	nunca	siempre	$e^{-\lambda/\mu}\frac{(\lambda/\mu)^n}{n!}$

Para M/M/1: $\mathbb{E}[X] = \dfrac{\lambda}{\mu - \lambda}$.

Para M/M/∞: $\mathbb{E}[X] = \frac{\lambda}{\mu}$.

Proceso de Yule

Definición

Proceso de Yule: $\lambda_n = n\lambda$, $\mu_n = 0$, $X_0 = 1$.

Teorema

Las probabilidades son

$$P_n(t) = e^{-\lambda t}(1 - e^{-\lambda t})^{n-1}, \quad n \geq 1.$$

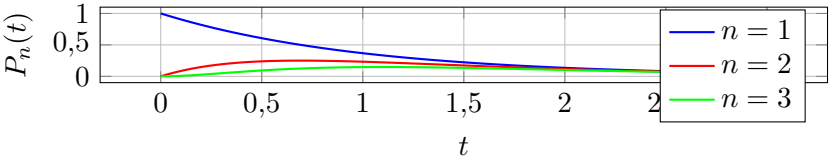

Propiedades del proceso de Yule

Proposición

Para el proceso de Yule:

- *Esperanza:* $\mathbb{E}[X_t] = e^{\lambda t}$
- *Tiempo hasta n individuos:* $\mathbb{E}[Y_n] = \sum_{i=1}^{n-1} \frac{1}{i\lambda} \sim \frac{\ln n}{\lambda}$

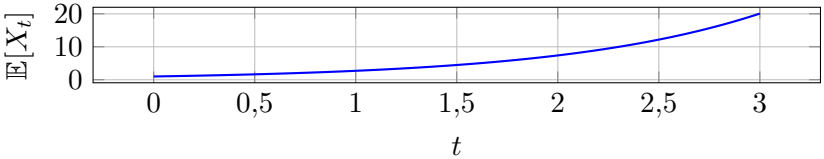

Explosión en tiempo finito

Ejemplo (Crecimiento rápido)

$\lambda_n = n^2\lambda$, $\mu_n = 0$, $X_0 = 1$.

El tiempo para alcanzar n es $Y_n = \sum_{i=1}^{n-1} T_i$ con $T_i \sim \mathrm{Exp}(i^2\lambda)$. Entonces

$$\mathbb{E}[Y_\infty] = \sum_{i=1}^{\infty} \frac{1}{i^2\lambda} = \frac{\pi^2}{6\lambda} < \infty.$$

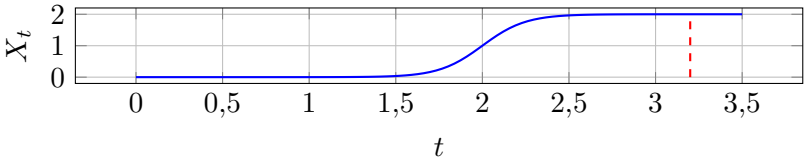

¡La población se vuelve infinita en tiempo finito con probabilidad 1!

Modelos de Lenguaje (LLMs): idea básica

Generación de texto

Los modelos como GPT pueden verse, de manera simplificada, como sistemas que pasan de un contexto a otro:

- estados = secuencias o contextos de tokens,
- transiciones = probabilidad o intensidad del siguiente token,
- evolución = actualización sucesiva del contexto.

Modelos de Lenguaje (LLMs): grafo de transición

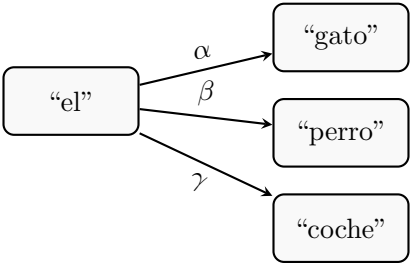

Modelos de Lenguaje (LLMs): atención y tiempos

Interpretación cualitativa

- Tiempos de atención $\leftrightarrow$ tiempos de salto.
- Mecanismo de atención $\leftrightarrow$ pesos o tasas de transición.
- Estabilidad de la generación $\leftrightarrow$ comportamiento estacionario.

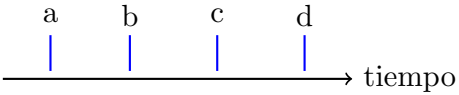

Procesos de Decisión Markovianos (MDP)

Aprendizaje por refuerzo

- Q-learning: estima recompensas y decisiones futuras.
- Políticas óptimas: seleccionan acciones que modifican la dinámica.
- Exploración vs. explotación: balance entre probar y estabilizarse.

MDP: esquema de estados y acciones

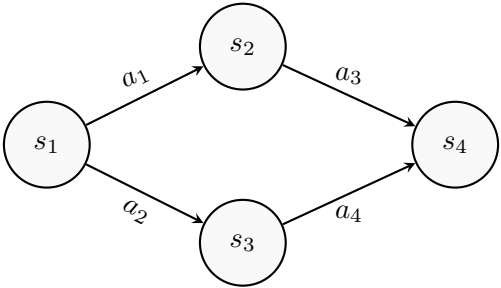

MDP: Bellman en tiempo continuo

Ecuación de Bellman

$$V(x) = \max_a \left\{ r(x,a)\Delta t + e^{-\beta \Delta t} \mathbb{E}[V(x')] \right\}$$

En el límite $\Delta t \to 0$:

$$\beta V(x) = \max_a \left\{ r(x,a) + \mathcal{A}_a V(x) \right\},$$

donde $\mathcal{A}_a$ es el generador asociado a la acción a.

Redes de Neuronas Espike (SNN)

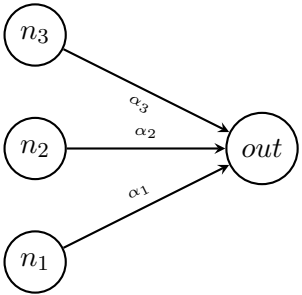

Modelado con procesos de nacimiento

- Potencial de membrana = estado
- Llegada de spikes = nacimientos
- Disparo = muerte (reset)

Tasas de disparo

$$\lambda_n = \text{tasa de entrada}$$

$$\mu_n = \text{tasa de disparo}$$

$$\mathbb{P}\{\text{disparo}\} = \frac{\mu_n}{\lambda_n + \mu_n}$$

Sistemas de Recomendación

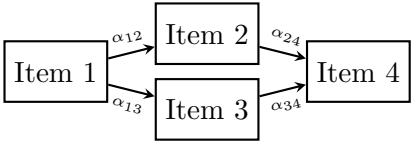

Filtrado colaborativo

- Usuarios = cadenas de Markov
- Transiciones = preferencias
- Recomendaciones = estados más probables

Tiempos medios de recomendación

$$b(x) = \frac{1}{\alpha(x)} + \sum_{y \neq x,z} \frac{\alpha(x,y)}{\alpha(x)} b(y)$$

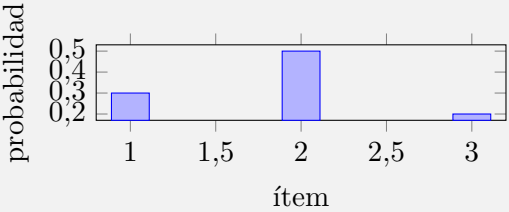

Ecuaciones backward

Condicionando en el primer intervalo:

$$p_{t+\Delta t}(x,y) = \sum_z p_{\Delta t}(x,z)p_t(z,y).$$

Usando probabilidades infinitesimales:

$$p_{t+\Delta t}(x,y) = (1-\alpha(x)\Delta t)p_t(x,y) + \sum_{z\neq x} \alpha(x,z)\Delta t\, p_t(z,y) + o(\Delta t).$$

Tomando $\Delta t \to 0$:

$$\frac{\partial}{\partial t}p_t(x,y) = -\alpha(x)p_t(x,y) + \sum_{z\neq x} \alpha(x,z)p_t(z,y).$$

En forma matricial: $\dfrac{d}{dt}\mathbf{P}_t = \mathbf{A}\mathbf{P}_t$.

Ecuaciones forward

Condicionando en el último intervalo:

$$p_{t+\Delta t}(x,y) = \sum_z p_t(x,z)p_{\Delta t}(z,y).$$

Usando probabilidades infinitesimales:

$$p_{t+\Delta t}(x,y) = p_t(x,y)(1-\alpha(y)\Delta t) + \sum_{z\neq y} p_t(x,z)\alpha(z,y)\Delta t + o(\Delta t).$$

Tomando $\Delta t \to 0$:

$$\frac{\partial}{\partial t}p_t(x,y) = -\alpha(y)p_t(x,y) + \sum_{z\neq y}\alpha(z,y)p_t(x,z).$$

En forma matricial: $\dfrac{d}{dt}\mathbf{P}_t = \mathbf{P}_t\mathbf{A}$.

Comparación

Backward	**Forward**
$\frac{d}{dt}\mathbf{P}_t = \mathbf{A}\mathbf{P}_t$	$\frac{d}{dt}\mathbf{P}_t = \mathbf{P}_t\mathbf{A}$
Condiciona en X_0	Condiciona en X_t
Siempre válidas	Requieren regularidad

Para espacios finitos, ambas tienen la misma solución:

$$\mathbf{P}_t = e^{t\mathbf{A}}.$$

$$\xrightarrow[\text{forward}]{\overset{\text{backward}}{e^{t\mathbf{A}}}}$$

Resumen visual

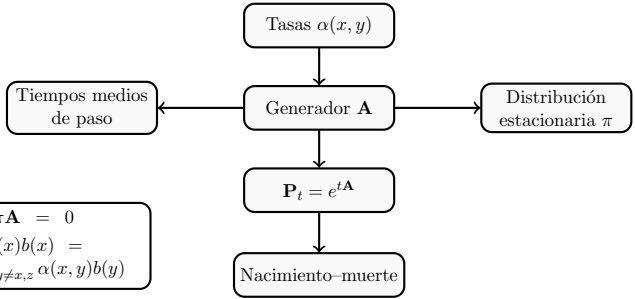

$$\begin{aligned} \pi\mathbf{A} &= 0 \\ \alpha(x)b(x) &= \\ 1 + \textstyle\sum_{y \neq x,z} \alpha(x,y)b(y) \end{aligned}$$

Aplicaciones en IA - Resumen

Aplicación IA	**Concepto CTMC**
Modelos de lenguaje	Transiciones entre tokens y tiempos de atención
Aprendizaje por refuerzo	MDP en tiempo continuo
Redes SNN	Nacimiento y muerte de spikes
Sistemas de recomendación	Tiempos medios de paso
Optimización	Distribución estacionaria y estabilidad

Ventajas del modelado en tiempo continuo

Ventajas principales

- Captura dinámicas asíncronas.
- Modela eventos en tiempo real.
- Generaliza procesos discretos.
- Permite análisis de convergencia y estabilidad.